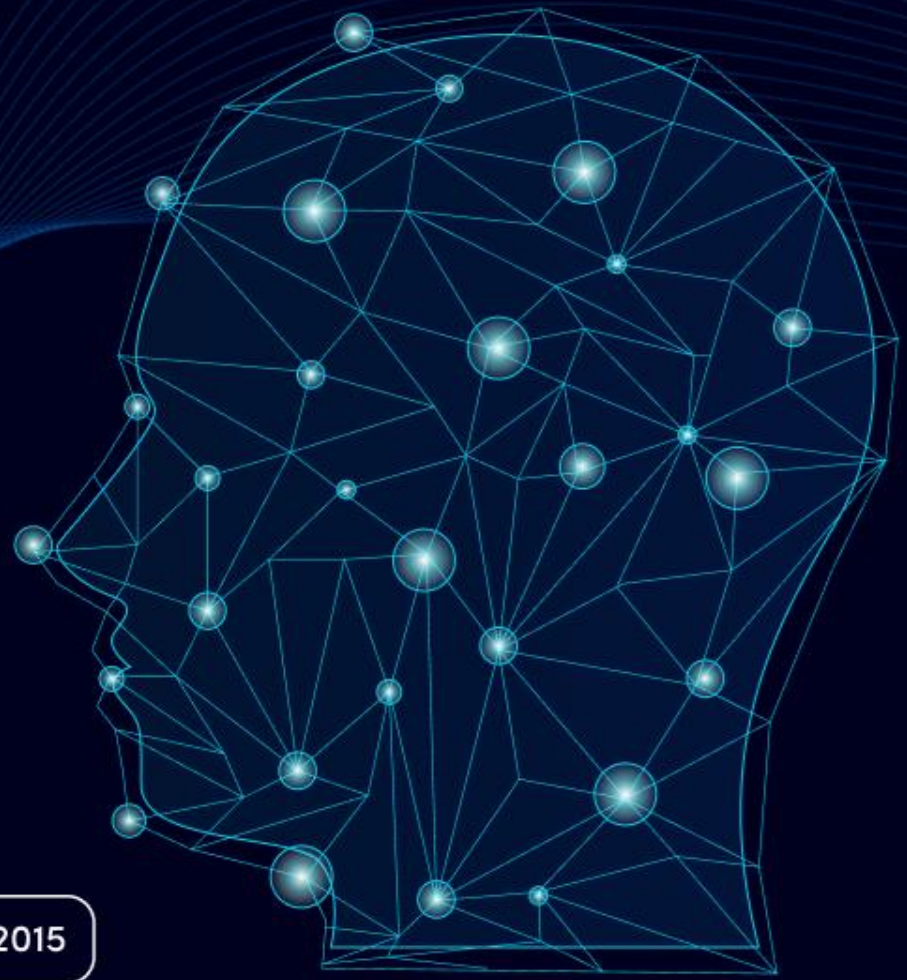
FUTURA
ANALITICA AVANZADA

PROGRAMA

Data Science for Business

Aprendizaje práctico y aplicado, con certificación ISO 9001 que garantiza calidad y excelencia



Mentores Top

Aprendizaje **100% aplicado**

Certificación **ISO 9001:2015**

BIENVENIDOS

FUTURA

DATA Y ANALITICA AVANZADA

Nos comprometemos con ayudarte a **impulsar** tu carrera profesional y tu empresa.

+20
Empresas satisfechas

+10
Mentores expertos

PROGRAMA
Data Science For Business

Reglas



Por favor, al ingresar a la sala MEET, usa tu **nombre y apellido** al inicio para identificarte



Se **puntual** en cada sesión.



Para estar más concentrados, es recomendable **mantener el micrófono en silencio** durante la sesión.



Usaremos el **chat para las preguntas**. Si necesitas hablar, puedes encender el micrófono cuando sea necesario



Completa las **tareas asignadas** a tiempo

Requisitos mínimo para obtener la certificación

Calificación

Asistencia	20%
Quiz de clase	30%
Trabajo Final Módulo	50%

Agenda

1. Observando datos multivariados
2. Análisis de componentes principales
3. Análisis de correspondencia multiple



ANALÍTICA AVANZADA

Observando datos multivariados_

Exploración analítica completa

Inteligencia visual

Estos métodos buscan efectos especiales en los datos, indican valores atípicos, identifican patrones, diagnostican modelos y, en general, exploran fenómenos novedosos y quizás inesperados.

¿Qué debemos graficar?

Existen muchas posibilidades interesantes, **incluyendo gráficos dinámicos**, pero la exploración gráfica de datos usualmente comienza con algunos métodos más simples y conocidos. Las **vistas marginales univariadas de datos multivariados** pueden obtenerse, por ejemplo, mediante **histogramas, gráficos de tallo y hoja, o diagramas de caja**. Sin embargo, lo más importante para explorar datos multivariados son los gráficos que permiten evaluar las **relaciones entre variables**.



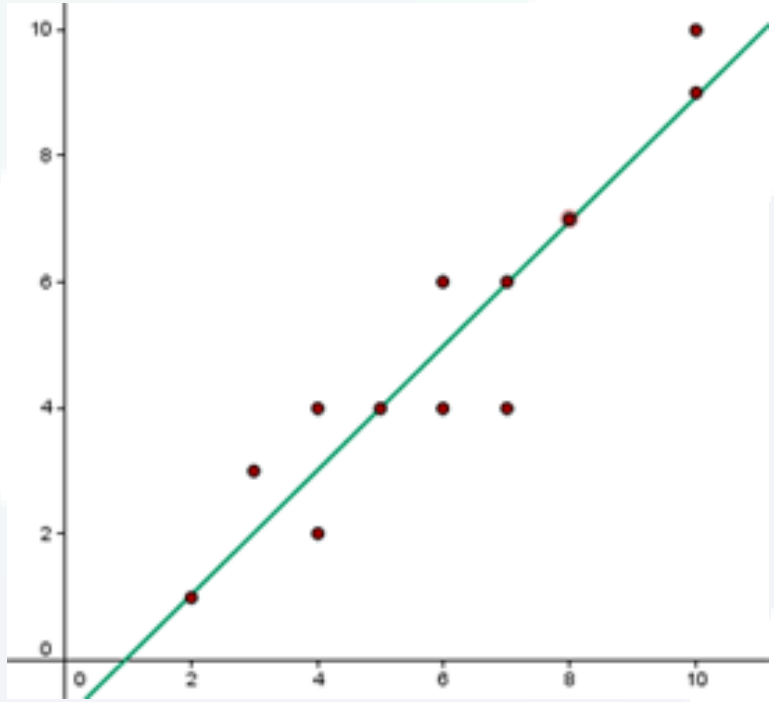
Exploración analítica completa

Inteligencia visual

Diagramas de dispersión y más

El gráfico relacional, en su forma más simple, el **diagrama de dispersión** y sus variantes, es el más grande de todos los diseños gráficos. Vincula al menos dos variables, alentando e incluso instando al espectador a evaluar la posible relación causal entre las variables representadas.

Confronta teorías causales que afirman que *x* causa *y* con evidencia empírica sobre la relación real entre *x* e *y*.



Inteligencia visual

Dataset: Polution

El cuadro (a) muestra el diagrama de dispersión de la Mortalidad frente al SO_2.

El cuadro (b) muestra el mismo diagrama con la adición del ajuste de regresión lineal simple de la Mortalidad sobre el SO_2.

Ambos gráficos sugieren un posible vínculo entre el aumento del nivel de dióxido de azufre y el incremento en la mortalidad.

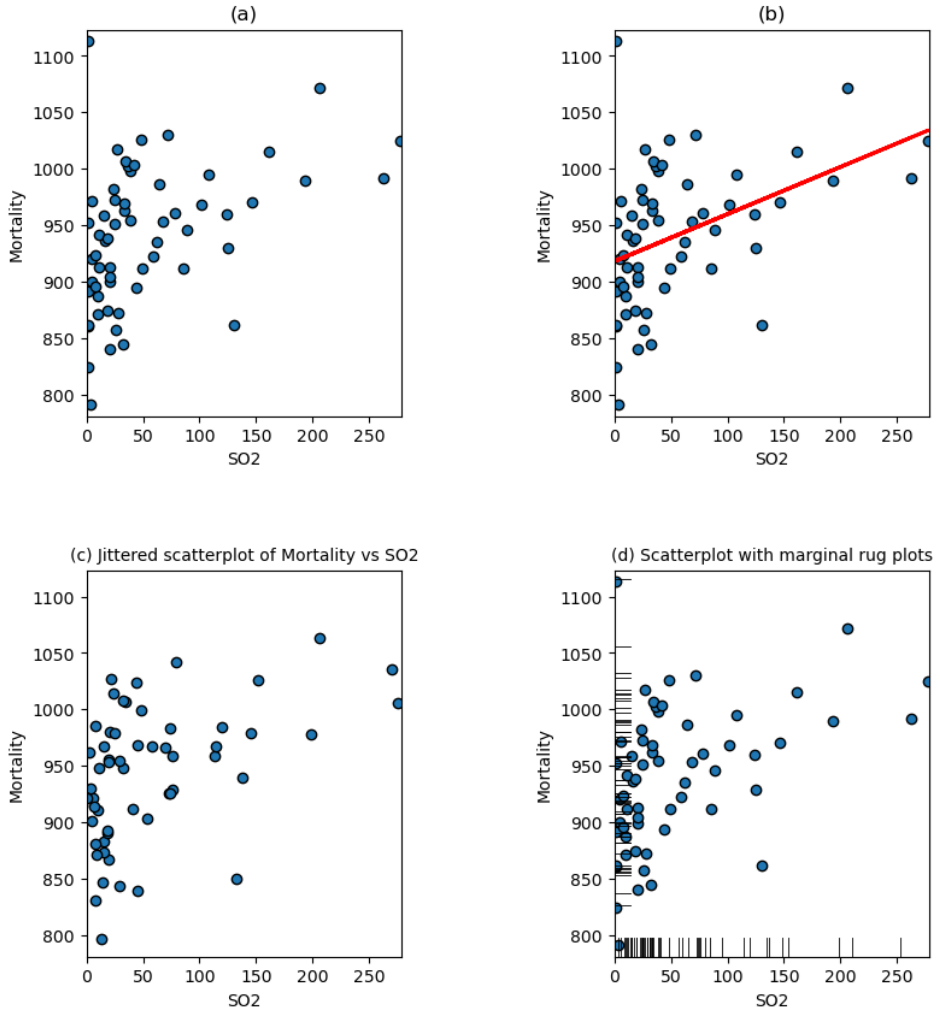
Si nos fijamos en un gráfico de dispersión podrá haber **superposición**.

Este problema puede superarse, al menos parcialmente, mediante el uso de "*jitter*", es decir, añadiendo una pequeña cantidad de ruido a cada observación antes de graficarla.

El cuadro (c) muestra el diagrama de la (a) después de aplicar jitter.

Finalmente, en la Figura 2.1(d), el diagrama bivariado de ambas variables se enmarca con una representación de la **distribución marginal** de cada variable.

Combinar distribuciones marginales y conjuntas en una misma visualización suele ser una buena práctica en el análisis de datos.



Inteligencia visual

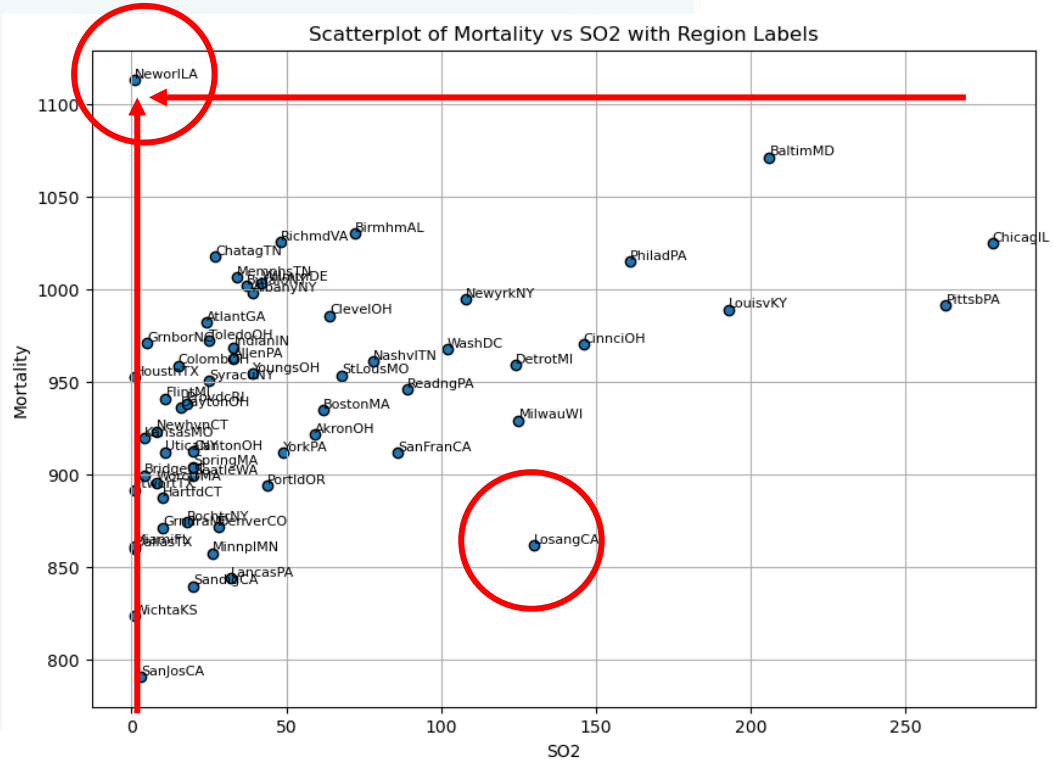
Dataset: Polution ¿Outliers?

La figura resalta algunas regiones con combinaciones inusuales de valores de **contaminación y mortalidad**.

Por ejemplo, **nwLA** tiene un valor de SO_2 casi nulo, pero una mortalidad muy alta. ¿Quizás se trata de un área con mayor prevalencia de ancianos?

Que puede estar pasando en **LosangCA (Los ángeles)?**

- Tal vez sea un valor atípico?
- O, tal vez sólo esta variable no explica la Mortalidad y se debe incluir alguna otra?



Inteligencia visual

Dataset: Polution ¿Outliers?

Examinar un diagrama de dispersión que incluya un **ajuste ponderado localmente** puede ser un buen antídoto contra el ajuste irreflexivo de líneas rectas por mínimos cuadrados.

En la Figura (b) se añadió un **ajuste de regresión lineal simple** al diagrama de dispersión de **Mortalidad frente a SO_2**.

Esta adición suele ser muy útil para evaluar con mayor precisión la relación entre ambas variables. Aún más útil es añadir tanto el **ajuste de regresión lineal como un ajuste de regresión ponderada localmente (o ajuste *lowess*)** al diagrama de dispersión.

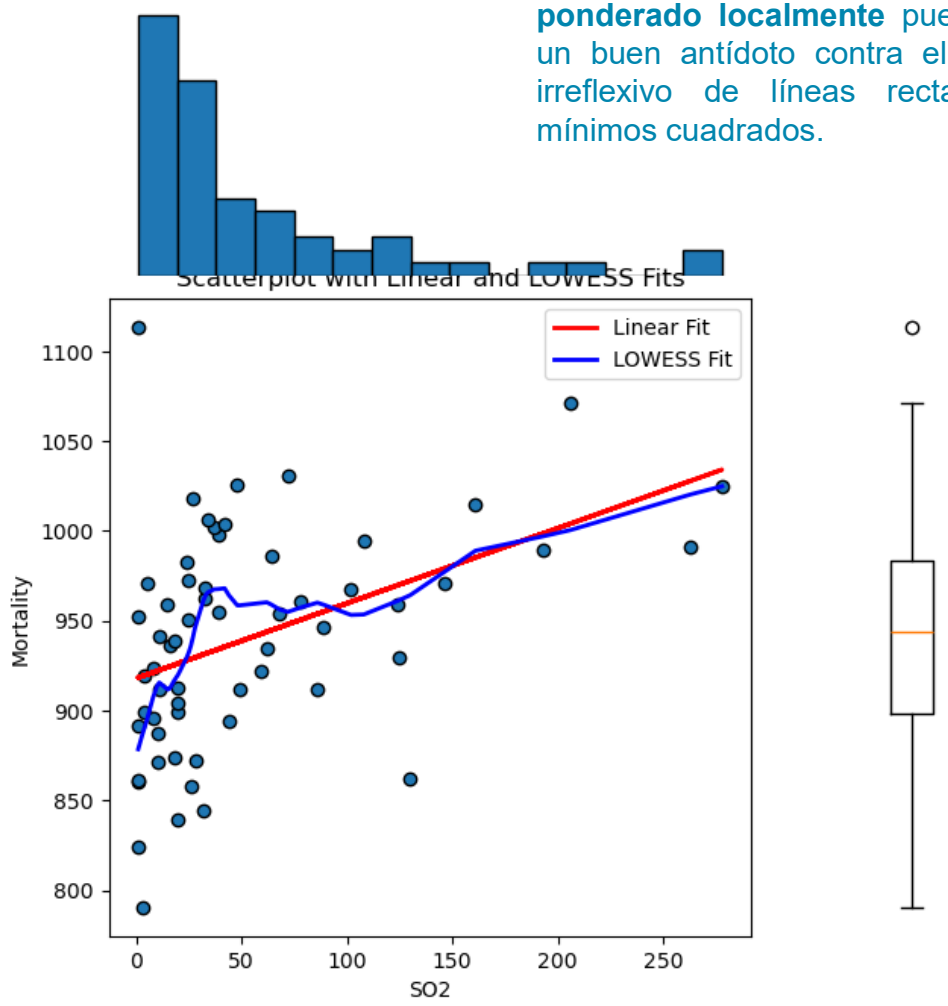
Tales ajustes están esencialmente **están diseñados para usar los propios datos para sugerir el tipo de ajuste necesario**. El modelo asumido es:

$$y_i = g(x_i) + \varepsilon_i,$$

donde **g** es una función "suave" (*smooth*) y los $\boldsymbol{\varepsilon_i}$ son variables aleatorias con media cero y varianza constante.

Los valores ajustados $\hat{\mathbf{y}}_i$ se utilizan para estimar $g(x_i)$ en cada punto x_i mediante el ajuste de polinomios usando mínimos cuadrados ponderados, con **mayores pesos para los puntos cercanos a x_i** y **menores pesos para los más lejanos**.

El diagrama resultante se muestra en la figura. Aquí, aparte de una pequeña "oscilación" (wobble) para los valores de dióxido de azufre entre 0 y 100, el ajuste lineal y el ajuste ponderado localmente son muy similares.



Inteligencia visual

Dataset: Polution ¿Outliers?

La envolvente convexa en datos bivariados

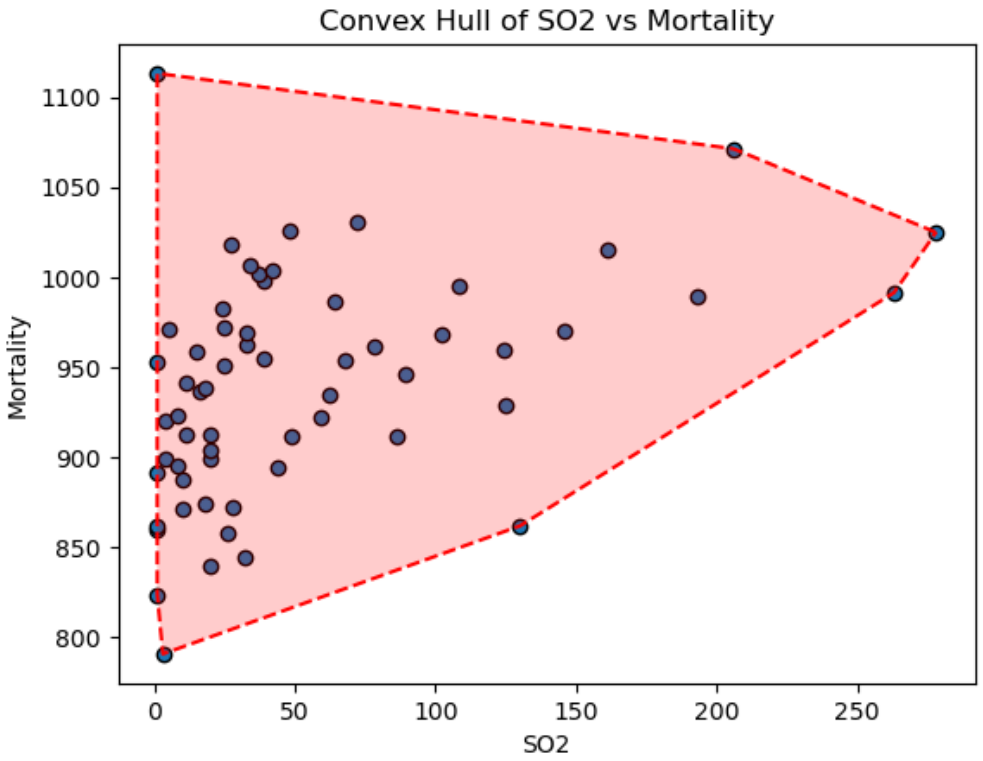
El **casco convexo** (o *convex hull*) es el polígono más pequeño que encierra todos los puntos de un conjunto de datos bivariados. Se utiliza para mejorar la estimación de la correlación entre dos variables.

Puntos clave:

- **Los diagramas de dispersión** ayudan a detectar valores atípicos que pueden distorsionar la correlación.
- **Recortar el casco convexo** (eliminar puntos extremos) puede reducir el efecto de outliers sin alterar la forma de la distribución.
- Esto permite obtener una **estimación más robusta** del coeficiente de correlación.
- Se calcula la correlación antes y después de eliminar los puntos sobre el casco convexo para evaluar su impacto.

```
# Imprimir resultados
print(f"Correlación con todos los puntos: {corr_total:.3f}")
print(f"Correlación excluyendo el casco convexo: {corr_sin_hull:.3f}")
```

```
Correlación con todos los puntos: 0.426
Correlación excluyendo el casco convexo: 0.437
```



El cambio en la correlación tras eliminar los puntos que definen la **envolvente convexa es muy pequeño**, sorprendentemente pequeño, considerando que algunas de las observaciones que la definen están **relativamente alejadas del cuerpo principal de los datos**.

Inteligencia visual

Dataset: Polution ¿Dependencia?

¿Debemos medir el grado de dependencia entre dos variables continuas**?**

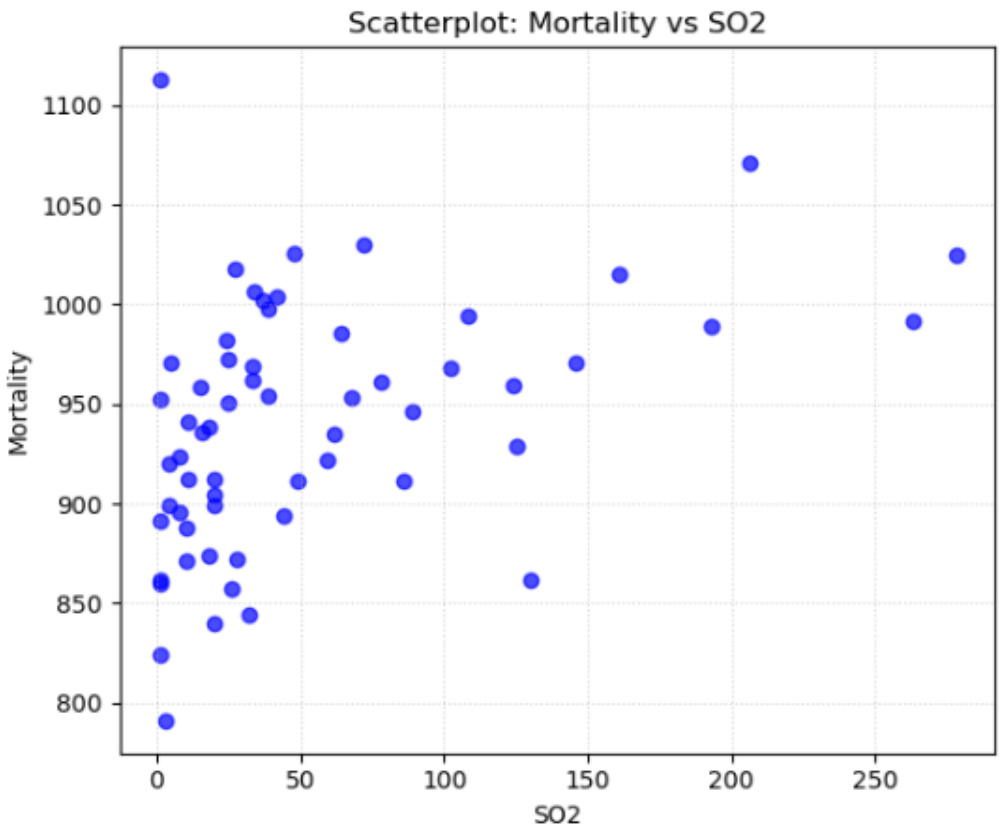
El **Chi-Plot** es una herramienta gráfica diseñada para **detectar dependencias** entre dos variables continuas cuando el diagrama de dispersión tradicional no es suficientemente revelador.

¿Por qué usar un Chiplot?

- **Evalúa independencia** entre dos variables continuas.
- Mejora la interpretación cuando el *scatterplot* muestra una nube aparentemente aleatoria de puntos.
- Responde a la limitación del ojo humano para detectar relaciones sutiles.

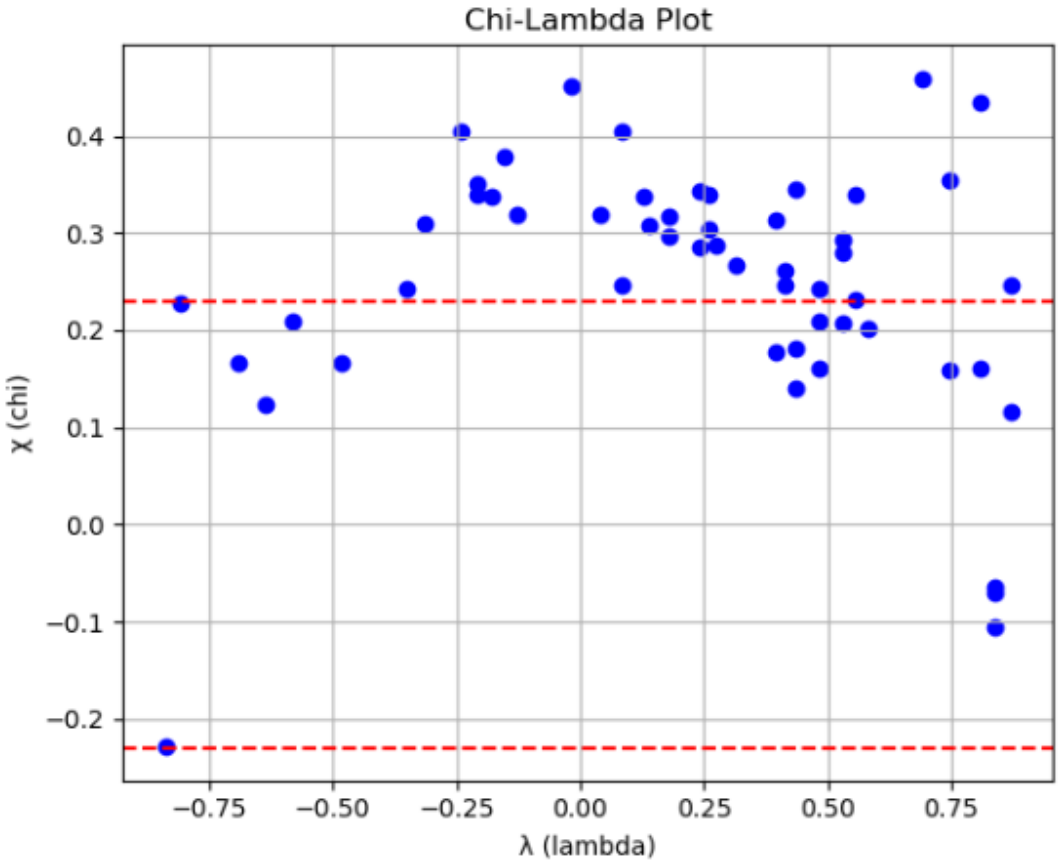
Principio de funcionamiento:

- Parte del supuesto de **independencia estadística**.
- En un Chi-Plot, **la independencia se representa visualmente** por una **banda horizontal** con puntos distribuidos uniformemente.
- **Ausencia o exceso de puntos fuera de esta banda** indica dependencia entre variables.



Inteligencia visual

Dataset: Polution ¿Dependencia?



Observación en el Chi-Plot	Interpretación
Puntos distribuidos uniformemente	Las variables parecen **independientes**
Concentración o vacíos fuera de la banda	Indican **dependencia estadística**
Ausencia de puntos en la banda central	Evidencia clara de **no independencia**

Consideraciones clave:

No evalúa causalidad, **solo dependencia**.
Útil como complemento a:

- Diagrama de dispersión
- Correlación de Pearson/Spearman

Es especialmente valioso cuando:

- Hay muchas observaciones
- La relación no es lineal
- Hay outliers

Inteligencia visual

Dataset: Polution ¿Boxplot Bivariados?

El **boxplot bivariado** es una extensión del boxplot tradicional para analizar **dos variables al mismo tiempo:**

- Visualizar la **distribución conjunta** de dos variables.
- Detectar **valores atípicos** (*outliers*).
- Evaluar la **correlación** entre las variables.

¿Cómo funciona?

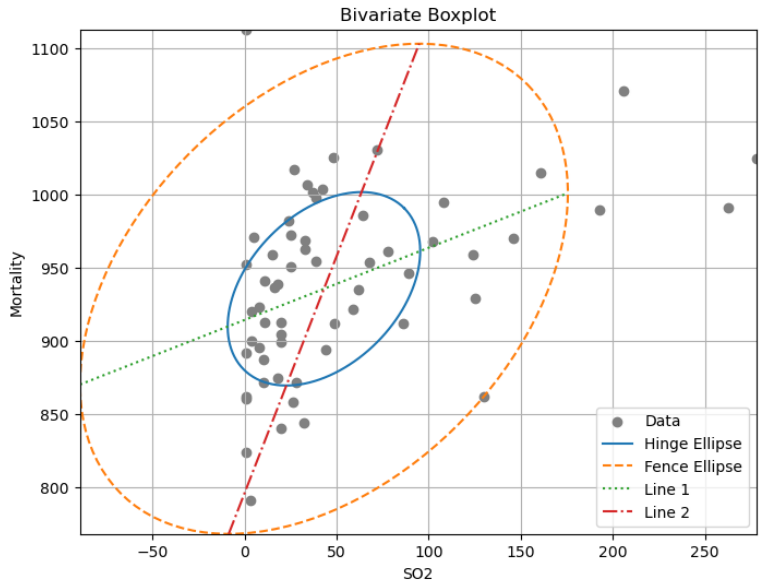
1. Centro robusto: Se calcula una estimación robusta de la **media bivariada** (usando biweight o medidas resistentes).
2. Escalas y correlación: También se estiman de forma robusta la **escala** (similar a la desviación estándar) de cada variable y su **correlación**.
3. Elipses concéntricas:
    Hinge (bisagra): Una elipse que abarca aproximadamente el **50% central** de los datos.
    Fence (cerco): Una elipse externa que marca el **límite de valores normales**. Los puntos fuera de esta elipse se consideran **atípicos**.
4. Líneas de regresión resistentes:
    Se trazan dos líneas: una para **Y sobre X** y otra para **X sobre Y**.
    El **punto de intersección** de estas líneas es el **centro estimado** de la distribución.
    El **ángulo entre las líneas** indica el nivel de correlación:
        Ángulo pequeño → correlación alta.
        Ángulo cercano a 90° → correlación baja.

Correlación (r)	Descripción	Ángulo aproximado entre líneas
r ≈ 1 o r ≈ –1	Correlación muy alta	Pequeño (cerca de 0°)
r ≈ ±0.8	Alta	~20°–30°
r ≈ ±0.5	Moderada	~45°
r ≈ ±0.2	Baja	~60°–70°
r ≈ 0	Sin correlación	~90° (las líneas casi se cruzan ortogonalmente)

Inteligencia visual

Dataset: Polution ¿Boxplot Bivariados?

[22]:
```
data = df[['so2', 'mortality']].to_numpy()
bvbox(data, d=7, method="robust", xlab="SO2", ylab="Mortality", title="Bivariate Boxplot")
```



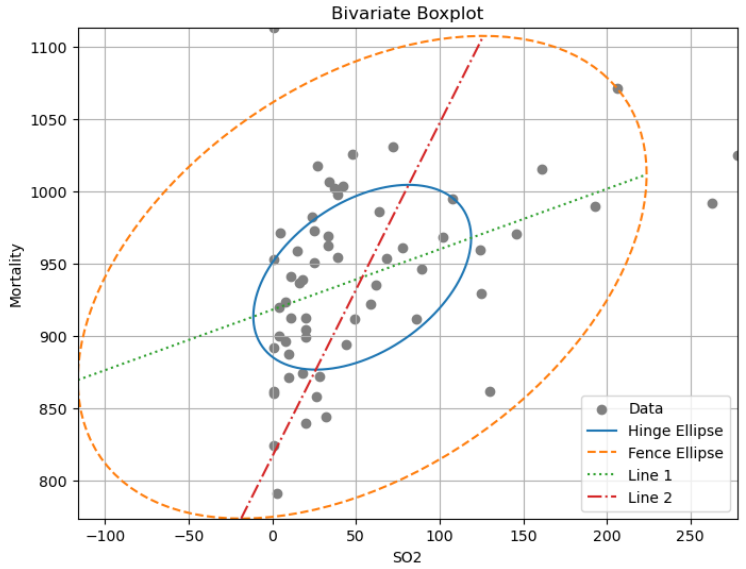
[24]:
```
outliers = bvbox(data, d=7, method="robust", xlab="SO2", ylab="Mortality", title="Bivariate Boxplot", return_outliers=True, df=df)
print(outliers)
```

```
          precipitation  temperature1  temperature7  age  household  \
Region
BaltimMD             43            35            77  7.6       3.44
ChicagIL             33            26            76  8.6       3.20
LouisvKY             30            35            71  8.3       3.37
NeworlLA             54            54            81  7.4       3.36
PittsbPA             36            29            72  9.5       3.32

          education  housing  population  noncauc  whitecollar  income  \
Region
BaltimMD        9.6     84.6        6441     24.4         43.7    14.3
ChicagIL       10.9     83.4        6122     16.3         44.9    10.7
LouisvKY        9.9     77.4        4474     13.1         42.6    17.7
NeworlLA        9.7     72.8        3172     31.4         45.5    24.2
PittsbPA       10.6     77.6        3437      8.1         45.5    13.8

          hydrocarbon  nox  so2  humidity  mortality
Region
BaltimMD           43   38  206        55   1071.289
ChicagIL           88   63  278        58   1024.885
LouisvKY           38   37  193        57    989.265
NeworlLA           20   17    1        62   1113.156
PittsbPA           45   59  263        56    991.290
```

[23]:
```
bvbox(data, d=7, method="classic", xlab="SO2", ylab="Mortality", title="Bivariate Boxplot")
```



[41]:
```
outliers = bvbox(data, d=7, method="classic", xlab="SO2", ylab="Mortality", title="Bivariate Boxplot", return_outliers=True, df=df)
print(outliers)
```

```
          precipitation  temperature1  temperature7  age  household  \
Region
ChicagIL             33            26            76  8.6       3.20
NeworlLA             54            54            81  7.4       3.36
PittsbPA             36            29            72  9.5       3.32

          education  housing  population  noncauc  whitecollar  income  \
Region
ChicagIL       10.9     83.4        6122     16.3         44.9    10.7
NeworlLA        9.7     72.8        3172     31.4         45.5    24.2
PittsbPA       10.6     77.6        3437      8.1         45.5    13.8

          hydrocarbon  nox  so2  humidity  mortality
Region
ChicagIL           88   63  278        58   1024.885
NeworlLA           20   17    1        62   1113.156
PittsbPA           45   59  263        56    991.290
```

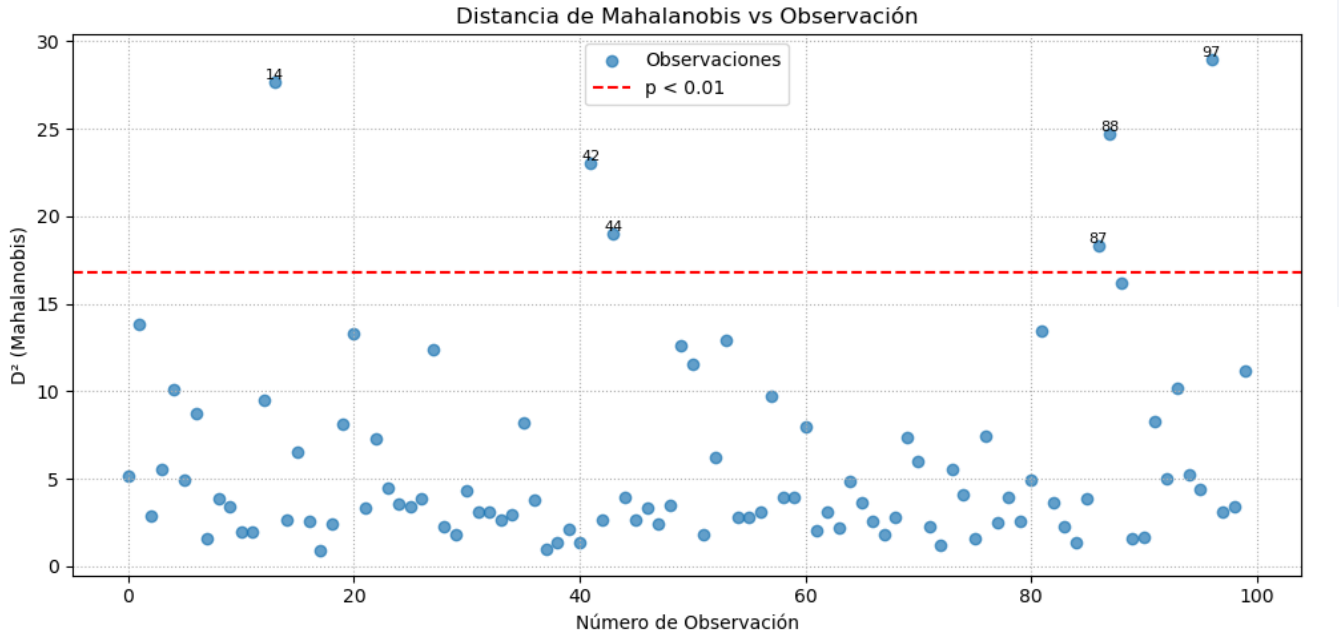
Inteligencia visual
Y el análisis Multivariante?

Caso: Retribución de altos directivos

Un investigador desea saber cuáles son las causas que explican la distinta remuneración de los altos directivos de las empresas. Dispone de los datos de 100 altos directivos.

Variable	Descripción
SYS	Sueldos y salarios del directivo.
EDAD	Edad del directivo
EXP_PTO	Experiencia como alto directivo en cualquier empresa (años)
EXP_EMP	Experiencia en la empresa. Años
VENTAS	Ventas de la empresa. Millones de Euros.
BENEF	Beneficio de la empresa. Millones de euros.

```
outliers = plot_mahalanobis_distances(df, alpha=0.01)
print("Outliers identificados:\n", outliers)
```



Inteligencia visual
Y el análisis Multivariante?

DBSCAN

- **DBSCAN** es un algoritmo de clustering basado en densidad.
- Agrupa puntos que están densamente distribuidos en el espacio de características.
- No requiere que especifiques el número de clusters (a diferencia de K-means).
- **Identifica outliers** como puntos que no pertenecen a ningún cluster (también llamados *ruido* o *noise*).

eps (ε) – Radio de Vecindad
Es la distancia máxima para considerar que dos puntos están "cerca".
Define el tamaño de la vecindad de cada punto.

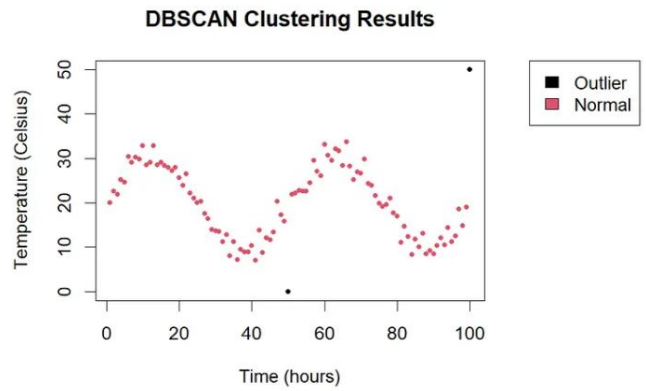
minPts (mínimo de puntos)
Número mínimo de puntos dentro del radio eps para formar una región densa (un cluster).

¿Cómo DBSCAN Detecta Outliers?

- DBSCAN explora cada punto y evalúa si tiene suficientes vecinos (minPts) en su vecindad (eps).
- Si no los tiene y no está conectado a ningún core point, se clasifica como ruido (outlier).
- Resultado: cada punto se etiqueta con un número de cluster o con -1 (outlier).

Ventajas de DBSCAN en la Detección de Outliers

- No necesita conocer el número de clusters previamente.
- Puede detectar outliers en forma natural, sin entrenamiento supervisado.
- Es robusto ante ruido y funciona bien con clusters de forma arbitraria.



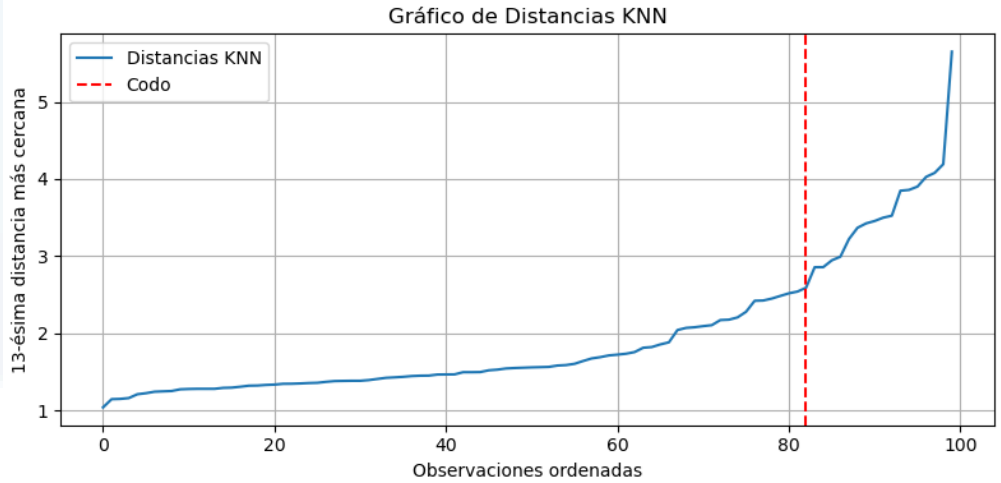
Inteligencia visual
Y el análisis Multivariante?

Caso: Retribución de altos directivos

Un investigador desea saber cuáles son las causas que explican la distinta remuneración de los altos directivos de las empresas. Dispone de los datos de 100 altos directivos.

Variable	Descripción
SYS	Sueldos y salarios del directivo.
EDAD	Edad del directivo
EXP_PTO	Experiencia como alto directivo en cualquier empresa (años)
EXP_EMP	Experiencia en la empresa. Años
VENTAS	Ventas de la empresa. Millones de Euros.
BENEF	Beneficio de la empresa. Millones de euros.

```
minPts sugerido: 13
eps sugerido: 2.54
```




```
Se detectaron 6 outliers:
```

CASO	SYS	EDAD	EXP_PTO	EXP_EMP	VENTAS	BENEF	cluster
14	4657	60	38	11.0	11572	1618	-1
21	1331	56	33	4.0	18807	942	-1
42	600	52	12	2.0	21351	101	-1
82	4039	55	32	17.0	12651	715	-1
87	3409	64	30	30.0	12021	-99	-1
88	4530	50	27	9.0	3077	98	-1

ANALÍTICA AVANZADA

Gracias

Team

Futura Data &
Analítica Avanzada