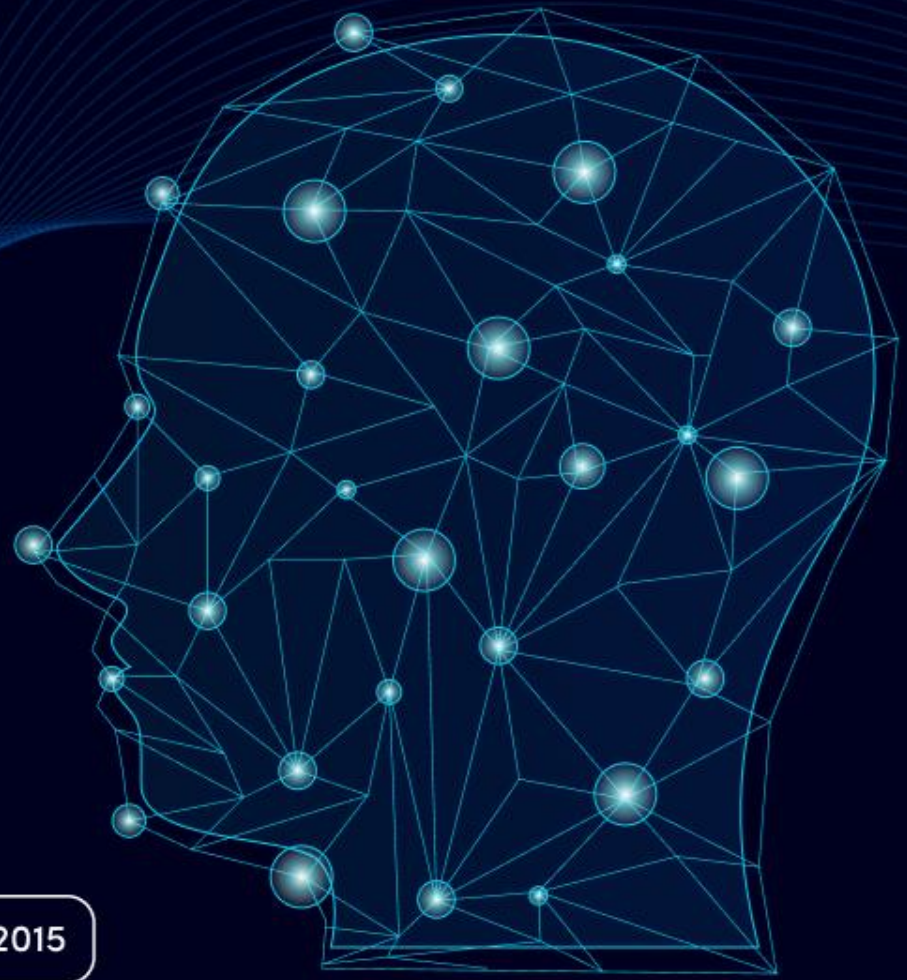
FUTURA
ANALITICA AVANZADA

PROGRAMA

Data Science for Business

Aprendizaje práctico y aplicado, con certificación ISO 9001 que garantiza calidad y excelencia



Mentores Top

Aprendizaje **100% aplicado**

Certificación **ISO 9001:2015**

BIENVENIDOS

FUTURA

DATA Y ANALITICA AVANZADA

Nos comprometemos con ayudarte a **impulsar** tu carrera profesional y tu empresa.

+20
Empresas satisfechas

+10
Mentores expertos

PROGRAMA
Data Science For Business

Reglas



Por favor, al ingresar a la sala MEET, usa tu **nombre y apellido** al inicio para identificarte



Se **puntual** en cada sesión.



Para estar más concentrados, es recomendable **mantener el micrófono en silencio** durante la sesión.



Usaremos el **chat para las preguntas**. Si necesitas hablar, puedes encender el micrófono cuando sea necesario



Completa las **tareas asignadas** a tiempo

Requisitos mínimo para obtener la certificación

Calificación

Asistencia	20%
Quiz de clase	30%
Trabajo Final Módulo	50%

Agenda

1. Observando datos multivariados
2. Análisis de componentes principales
3. Análisis de correspondencia multiple



ANALÍTICA AVANZADA

Reducción de Dimensionalidad (PCA)_

Reducción dimensionalidad

¿Para qué se debe reducir la dimensión de una matriz?

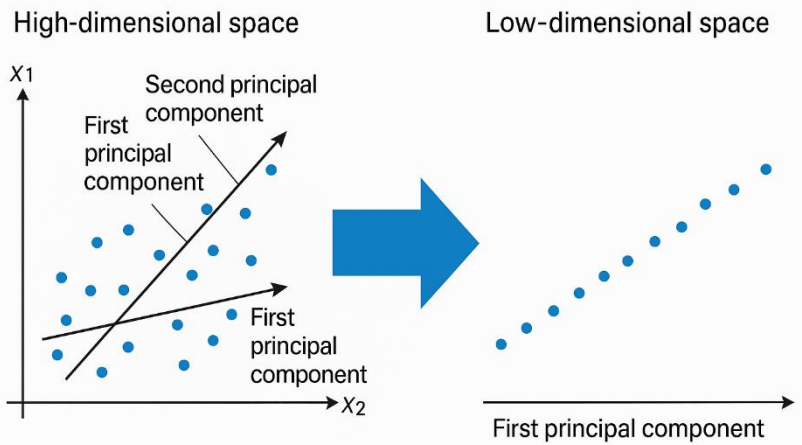
1. **Simplificación**:
Reduce la complejidad de los modelos y mejora su interpretabilidad.

2. Visualización:
Permite representar datos multivariados en 2D o 3D para identificar patrones, grupos o anomalías.

3. Reducción de ruido:
Al eliminar variables irrelevantes o redundantes, se mejora la calidad del análisis.

4. Aceleración del cómputo:
Menos variables implican menor tiempo de procesamiento, útil para grandes datasets.

5. Mejorar el desempeño de modelos:
Algunos algoritmos (como KNN o clustering) sufren con alta dimensionalidad (*curse of dimensionality*). Reducir dimensiones mejora sus resultados.



Manipulación de Datos

Análisis de Componentes Principales

El objetivo básico del análisis de componentes principales (PCA, por sus siglas en inglés) es describir la **variación en un conjunto de variables correlacionadas**, $x_1, x_2, ..., x_q$ en términos de un nuevo conjunto de variables no correlacionadas, $y_1, y_2, ..., y_q$, cada una de las cuales es una combinación lineal de las variables x.

Características clave:

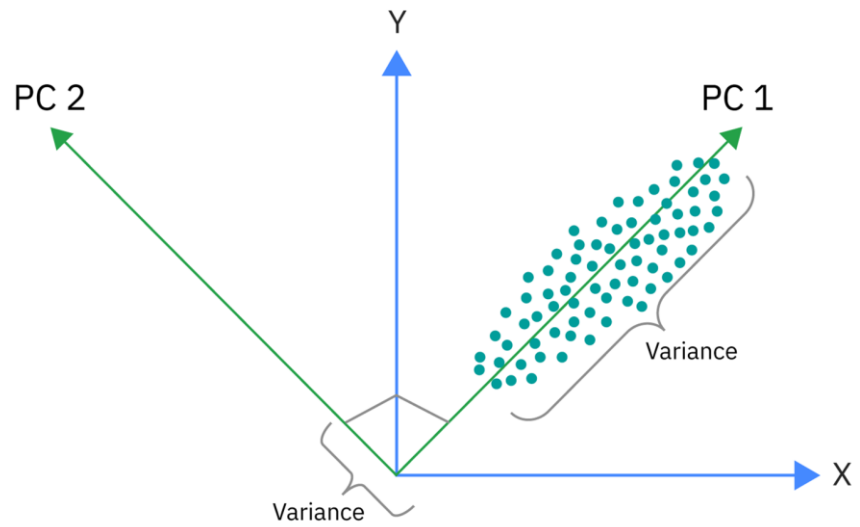
- El primer componente explica la mayor parte de la variación total.
- Cada componente posterior explica la mayor parte posible del residuo, manteniéndose ortogonal (no correlacionado) con los anteriores.
- Los primeros componentes suelen capturar una gran proporción de la información útil.

Aplicaciones comunes:

- Construcción de índices de desempeño (people analytics, economía).
- Reducción de variables para análisis de regresión o ANOVA multivariado.
- Identificación de patrones subyacentes (forma vs tamaño, severidad vs patrón de síntomas).
- Representación gráfica de datos complejos.

Ventajas:

- Simplifica datos sin perder mucha información.
- Mejora la interpretación y visualización.
- Mitiga problemas de multicolinealidad en modelos predictivos.



Análisis de Componentes Principales

Resumen Matemático Simplificado

1. Definiciones básicas:
Sea $\mathbf{x} \in \mathbb{R}^q$ un vector columna de ***q*** variables originales.
El **componente principal j-ésimo** se define como:

$$y_j = \mathbf{a}_j^T \mathbf{x}$$

$\mathbf{a}_j$ vector de pesos (coeficientes) que define la combinación lineal

2. Restricción fundamental:
Se impone que:

$$\mathbf{a}_j^T \mathbf{a}_j = 1$$

Esto fija la longitud del vector a 1 (vector unitario)
Evita inflar o reducir artificialmente la varianza del componente

3. Cálculo de los componentes:
Si se usa matriz de covarianza **S:**

$$\mathbf{S}\mathbf{a}_j = \lambda_j \mathbf{a}_j$$

λ_j autovalor asociado a $\mathbf{a}_j$
Los autovectores de **S** definen los componentes

4. Varianza Explicada

Varianza del componente $\mathrm{Var}(y_j) = \lambda_j$

Proporción explicada $P_j = \frac{\lambda_j}{\sum_{i=1}^{q} \lambda_j}$

Varianza total $\sum \lambda = traza\ (\mathbf{S})$

5. Correlación entre Variable y Componente

$$\mathrm{Cov}(x_j, y_j) = \lambda_j a_{ji}$$

Correlación: $r_{x_i,y_j} = \frac{a_{ji}\sqrt{\lambda_j}}{s_i}$

Si los datos son estandarizados ($s_i = 1$)

$$r_{x_i,y_j} = a_{ji}\sqrt{\lambda_j}$$

Análisis de Componentes Principales
Caso de Uso

Caso: Indicadores económicos y sociales en 96 países

Un investigador desea saber cuáles son las causas que explican el distinto grado de desarrollo entre países. Dispone de los datos de 96 países.

Variable	Descripción
X1	Tasa anual de crecimiento de la población
X2	Tasa de mortalidad infantil por cada 1000 nacidos vivos
X3	Porcentaje de mujeres en la población activa
X4	PNB en 1995 (en millones de dólares)
X5	Producción de electricidad (en millones kW/h)
X6	Líneas telefónicas por cada 1000 habitantes
X7	Consumo de agua per cápita
X8	Proporción de la superficie del país cubierta por bosques
X9	Proporción de deforestación anual
X10	Consumo de energía per cápita
X11	Emisión de CO_2 per cápita.

Análisis de Componentes Principales
Caso de Uso

Caso: Indicadores económicos y sociales en 96 países

Un investigador desea saber cuáles son las causas que explican el distinto grado de desarrollo entre países. Dispone de los datos de 96 países.

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9	PC10	PC11
X1	-0.314119	-0.348357	0.073525	-0.440287	0.329721	0.183924	0.162897	0.094820	0.521812	0.346746	0.100628
X2	-0.392395	0.041362	0.177593	-0.133985	-0.083405	0.086564	0.639804	0.323078	-0.290316	-0.389592	-0.174871
X3	0.116546	0.582836	-0.166863	0.058650	-0.186541	-0.168356	0.531087	-0.052099	0.235998	0.428547	0.167868
X4	0.295394	0.176908	0.533430	-0.262482	0.141107	-0.046534	-0.149021	0.449132	-0.369957	0.349115	0.152474
X5	0.258965	0.173564	0.614388	-0.173896	0.075220	-0.028219	0.108275	-0.503439	0.306813	-0.337704	-0.123664
X6	0.446083	0.027191	-0.151772	0.049598	0.054165	-0.024422	-0.000850	0.569751	0.447331	-0.209977	-0.449926
X7	0.092411	-0.320610	0.370243	0.736031	-0.026710	0.309409	0.235767	0.059625	0.083582	0.205618	0.070678
X8	0.005693	0.457427	-0.164803	0.040249	0.415317	0.753565	-0.080604	-0.042754	-0.074385	-0.086712	0.014937
X9	-0.243652	0.154082	0.029614	0.336503	0.732615	-0.508942	0.011233	0.016075	-0.018686	-0.032098	-0.072596
X10	0.415030	-0.232863	-0.206087	-0.067302	0.231004	-0.058065	0.271123	0.050236	-0.043398	-0.361474	0.679125
X11	0.374531	-0.291687	-0.206318	-0.148435	0.240288	0.028092	0.335282	-0.309780	-0.376662	0.287794	-0.467376

Análisis de Componentes Principales
Caso de Uso

Como interpretamos cada componente?

```
Cargas corregidas de las variables (PC1, PC2):
          PC1       PC2
X1  -0.633891 -0.486493
X2  -0.791852  0.057764
X3   0.235190  0.813951
X4   0.596103  0.247059
X5   0.522589  0.242388
X6   0.900193  0.037973
X7   0.186484 -0.447743
X8   0.011488  0.638812
X9  -0.491689  0.215181
X10  0.837527 -0.325201
X11  0.755801 -0.407351

 Interpretación de PC1:
- ↑ X6 contribuye fuertemente a PC1
- ↑ X10 contribuye fuertemente a PC1
- ↓ X2 contribuye fuertemente a PC1
- ↑ X11 contribuye fuertemente a PC1

 Interpretación de PC2:
- ↑ X3 contribuye fuertemente a PC2
- ↑ X8 contribuye fuertemente a PC2
- ↓ X1 contribuye fuertemente a PC2
- ↓ X7 contribuye fuertemente a PC2
```

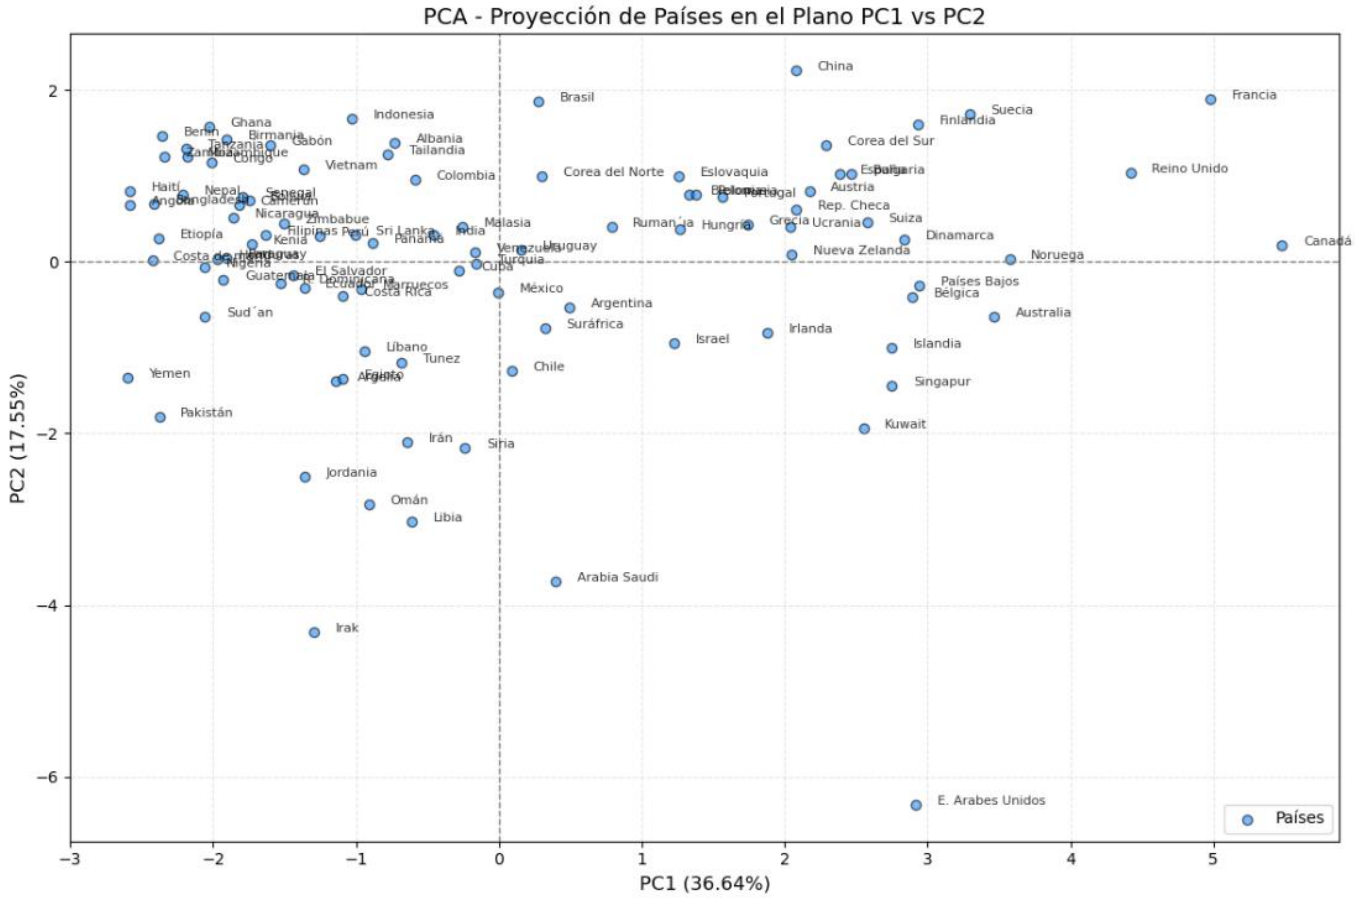
Variable	Descripción
X1	Tasa anual de crecimiento de la población
X2	Tasa de mortalidad infantil por cada 1000 nacidos vivos
X3	Porcentaje de mujeres en la población activa
X4	PNB en 1995 (en millones de dólares)
X5	Producción de electricidad (en millones kW/h)
X6	Líneas telefónicas por cada 1000 habitantes
X7	Consumo de agua per cápita
X8	Proporción de la superficie del país cubierta por bosques
X9	Proporción de deforestación anual
X10	Consumo de energía per cápita
X11	Emisión de CO_2 per cápita

Las Variables X_2, X_6, X_{10} y X_{11} son las que más contribuyen en la primera componente, se interpreta como ***índice de riqueza o desarrollo.***

Las Variables X_1, X_3, X_7 y X_8 son las que más contribuyen en la segunda componente, se interpreta como ***índice de sostenibilidad***

Análisis de Componentes Principales
Caso de Uso

Qué observaciones (Países) se asocian más a cada componente?



Países con mayor y menor score en PC1:

	País	PC1
15	Canadá	5.479460
36	Francia	4.976956
74	Reino Unido	4.419963
65	Noruega	3.574937
5	Australia	3.464706
82	Suecia	3.296123
42	Países Bajos	2.941124
35	Finlandia	2.932011
9	Benin	-2.354767
68	Pakistán	-2.376832
33	Etiopía	-2.377576
7	Bangladesh	-2.409545
20	Costa de marfil	-2.423421
1	Angola	-2.581830
41	Haití	-2.581832
93	Yemen	-2.599022

Países con mayor y menor score en PC2:

	País	PC2
24	China	2.227754
36	Francia	1.892712
12	Brasil	1.870947
82	Suecia	1.716084
46	Indonesia	1.662780
35	Finlandia	1.605099
38	Ghana	1.578746
9	Benin	1.471089
48	Irán	-2.105181
79	Siria	-2.165205
52	Jordania	-2.504545
67	Omán	-2.818931
56	Libia	-3.028626
2	Arabia Saudi	-3.723023
47	Irak	-4.314617
30	E. Arabes Unidos	-6.323873

Según este índice, **Canadá, Francia, Reino Unido, Noruega y Australia** serían los países con mayor grado de desarrollo, mientras que Yemen, Haití y Angola serían los de menor grado. Por otro lado, **Irak, Arabia Saudí y Emiratos Árabes** son los países con un mayor valor en la segunda componente principal.

ANALÍTICA AVANZADA

Gracias

Team

Futura Data &
Analítica Avanzada