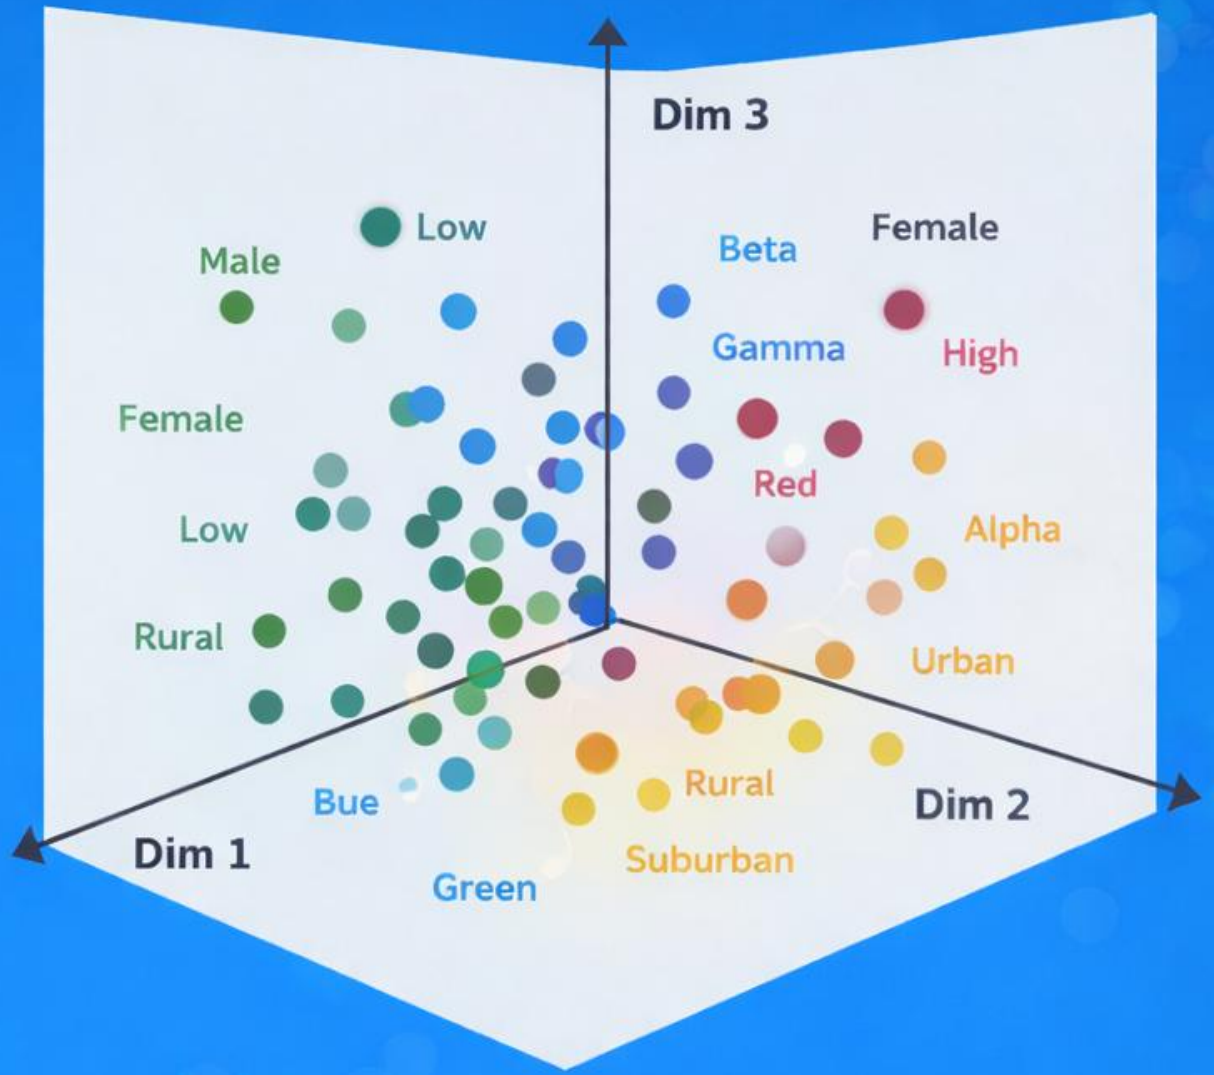
CORRESPONDENCIA MÚLTIPLE (MCA)

ATAJO ESTADÍSTICO PARA ENTENDER RELACIONES MULTIVARIABLES



MCA

Análisis de correspondencia múltiple

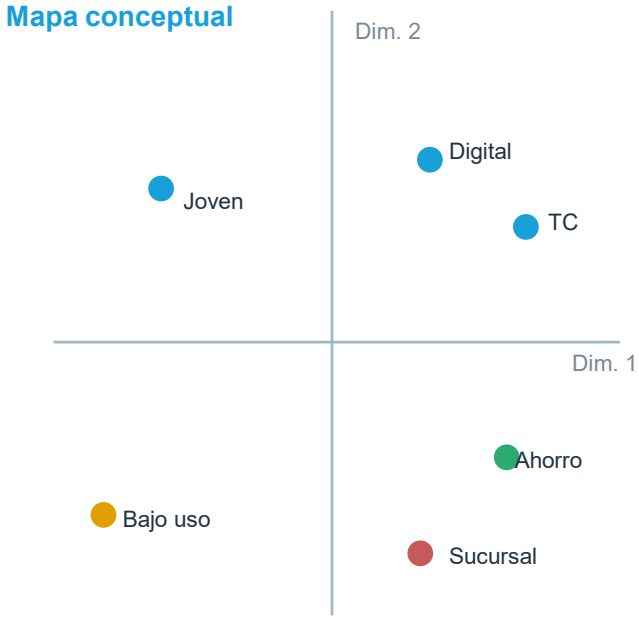
De tablas dispersas y cruces 2 a 2 a una lectura multivariable, visual e interpretable.

Problema | Solución MCA | Intuición matemática | Casos

Objetivo de la sesión

Mostrar por qué el análisis categórico tradicional se vuelve difícil cuando crecen las variables y cómo MCA resume relaciones múltiples en pocas dimensiones para generar mejores insights y decisiones.

Mapa conceptual



El mapa MCA aproxima categorías que tienden a aparecer juntas.

ANALÍTICA AVANZADA

Problema_

Como normalmente se analiza hoy

Problema

Análisis univariado

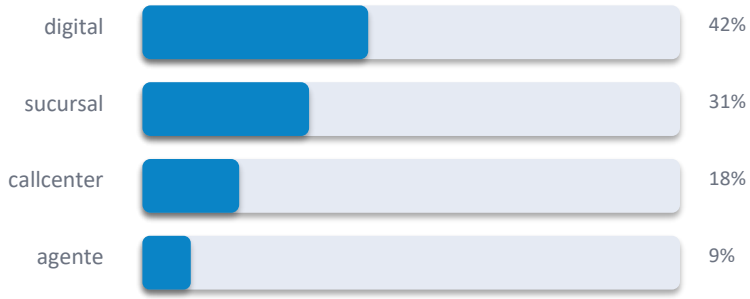
Ver distribuciones una variable a la vez. Aquí todo va bien.

```
# Distribución de cada variable
for col in df.columns:
    df[col].value_counts().plot(kind="bar")
    plt.title(col); plt.show()
```

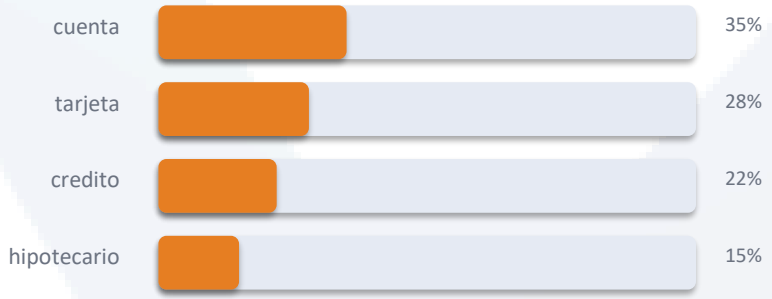
Segmento



Canal (distribución)



Producto



✅ Esto funciona perfecto. Conozco cada variable, frecuencias, rarezas. Sin drama.

Problema

Quiero entender relaciones… ¿y ahora qué?

Terminé el univariado. Necesito saber qué categorías se asocian.

Pregunta 1: ¿Qué combino primero?

Tengo 10 variables. ¿Canal × Segmento? ¿Producto × Edad? La elección ya introduce sesgo.

Pregunta 2: ¿Cómo enlazo todo?

Vi que canal y segmento se asocian, y que producto y edad también. Pero ¿cómo se conectan las cuatro juntas? Eso no lo dice ningún cruce 2×2.

Pregunta 3: ¿Hay perfiles ocultos?

¿Existe un grupo donde joven + digital + tarjeta + ingreso bajo van juntos? No tengo herramientas para verlo.

Problema

Análisis Bivariado

La herramienta fundamental: cruzar dos variables y contar frecuencias.

```
# Crosstab básico
pd.crosstab(
    df["segmento"], df["canal"],
    margins=True)
```

	digital	sucursal	callcenter	agente	Total
mass	2,100	1,800	1,200	700	5,800
premium	1,500	600	500	200	2,800
pyme	600	700	80	20	1,400
Total	4,200	3,100	1,780	920	10,000

¿Qué veo aquí?

- ✓ Premium se concentra más en digital
- ✓ Pyme prefiere sucursal
- ✓ Mass está disperso en todos los canales

📊 Hasta aquí funciona. Pero esto es solo 1 de 45 cruces posibles con 10 variables. Y solo veo frecuencias absolutas.

⚠️ Las frecuencias brutas pueden engañar. Si mass tiene más clientes, siempre tendrá más en cada canal. Necesito porcentajes.

Problema
Análisis Bivariado

Convertir conteos a proporciones para comparar perfiles de fila.

```
# Porcentajes por fila
pd.crosstab(df["segmento"],
    df["canal"], normalize="index")
```

	digital	sucursal	callcenter	agente
mass	36.2%	31.0%	20.7%	12.1%
premium	53.6%	21.4%	17.9%	7.1%
pyme	42.9%	50.0%	5.7%	1.4%

Premium: 53.6% es digital — dominancia clara del canal digital.

Pyme: 50% en sucursal — perfil claramente presencial.

Mass: distribuido — no hay un canal dominante claro.

🎯 Mejor. Pero esto sigue siendo solo segmento × canal. ¿Y si agrego producto, edad, score? No puedo hacer un crosstab de 5+ variables.

Problema
Análisis Bivariado

El analista experimentado aplica un test de independencia para validar la asociación.

```
from scipy.stats import chi2_contingency

tabla = pd.crosstab(df['segmento'],
                    df['canal'])
chi2, p, dof, exp = chi2_contingency(tabla)
```

RESULTADO

248.3	< 0.001	6
χ^2	p-value	gl

✅ p < 0.001 → Segmento y canal no son independientes.
La asociación es estadísticamente significativa.

⚠️ Chi² solo dice "hay asociación" — no dice cuál ni dónde.
Para eso necesito residuos estandarizados.

Hice esto para 1 par. Con 10 variables necesito 45 tests.
Y luego interpretar 45 resultados con corrección por múltiples comparaciones.

Chi-cuadrado responde si hay fuego, pero no te da el mapa del incendio.

Problema

Como normalmente se analiza hoy

El problema no es solo calcular; es sintetizar muchas relaciones sin perder contexto.

Flujo habitual de trabajo

1	2	3	4
Elegir par de variables	Tabla de contingencia	Chi-cuadrado y resíduos	Barplot y nota

Y luego repetir... para cada par relevante.
El volumen de comparaciones crece rápidamente

Cada celda potencialmente implica una tabla, un test y un gráfico.

	Canal	Edad	Ticket	NPS	Región	Freq
Canal		bar	tab	chi2	chi2	bar
Edad			chi2	chi2	bar	tab
Ticket				bar	tab	chi2
NPS					chi2	chi2
Región						bar
Freq						

Con p variables categóricas, el número de cruces crece como

$$p(p-1)/2$$

8 variables = 28 comparaciones

- Complicado determinar relaciones globales.
- Tablas dinámicas y cortes extensos.
- Difícil comparar cuando cambian los volúmenes.

Resultado habitual: se detectan asociaciones locales, pero cuesta explicar el sistema completo.

ANALÍTICA AVANZADA

Solución_

Lo que MCA nos ayuda a ver

Solución

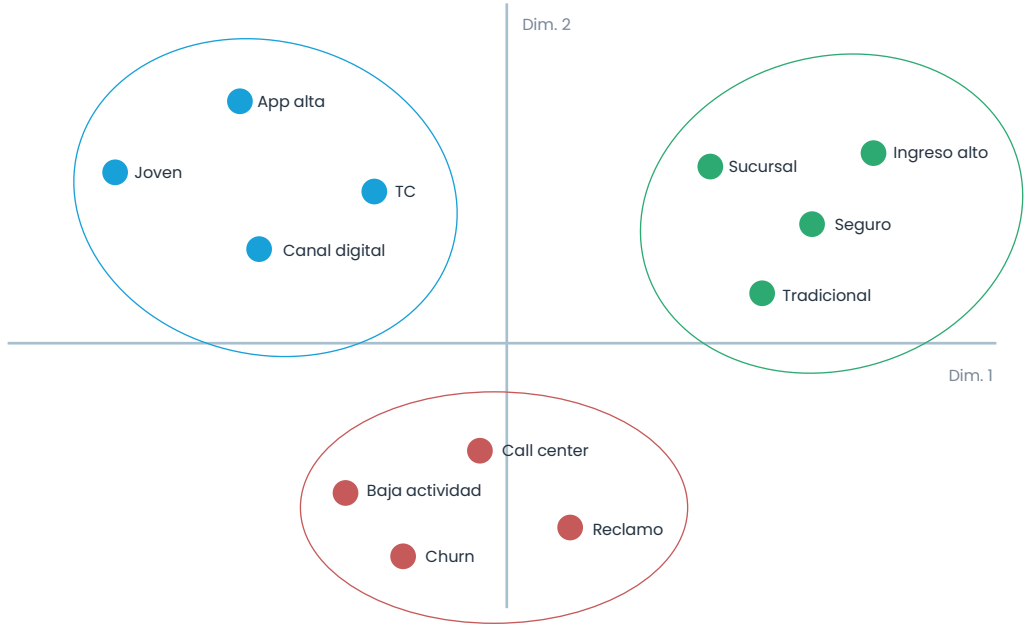
Lo que MCA nos ayuda a ver

La idea central: pasar de múltiples cruces aislados a un solo mapa geométrico que resume asociaciones categóricas.

Qué resuelve

- Reduce la sobrecarga de análisis 2 a 2
- Resume relaciones múltiples en pocas dimensiones
- Permite detectar segmentos y perfiles latentes
- Produce gráficos comunicables para audiencias no técnicas
- Ayuda a decidir con evidencia estructural y no intuición aislada

Mapa MCA (ejemplo conceptual)



Categorías cercanas suelen compartir patrón de ocurrencia; las alejadas describen perfiles distintos.

Mensaje clave: MCA no reemplaza el criterio analítico; lo organiza en una estructura visual única.

Solución

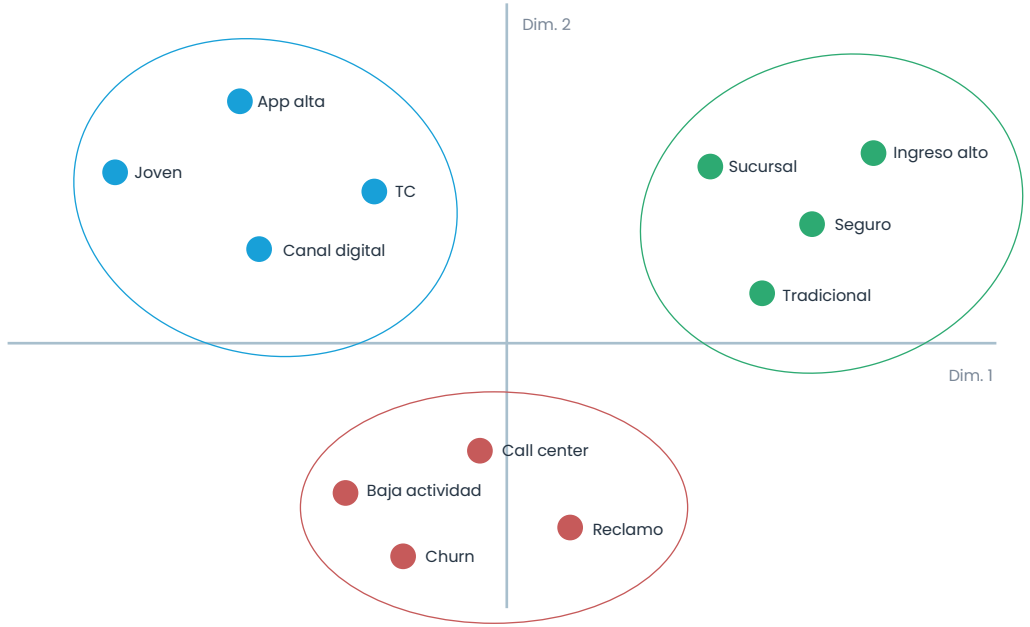
Lo que MCA nos ayuda a ver

La idea central: pasar de múltiples cruces aislados a un solo mapa geométrico que resume asociaciones categóricas.

¿Cómo se interpreta bien?

Proximidad	Categorías con perfiles similares en el resto de variables.
Oposición	Ejes que separan perfiles dominantes
Contribución	¿Qué categorías construyen cada dimension?
Calidad	Qué tan bien queda representado un punto en 2D

Mapa MCA (ejemplo conceptual)



Categorías cercanas suelen compartir patrón de ocurrencia; las alejadas describen perfiles distintos.

Mensaje clave: MCA no reemplaza el criterio analítico; lo organiza en una estructura visual única.

ANALÍTICA AVANZADA

Comparativa_

Enfoque actual vs MCA

Comparativa

Enfoque actual vs MCA

La comparación no es solo técnica; cambia el tiempo de trabajo, los insights y el tipo de decisión.

10 variables
45 cruces potenciales

1 modelo + validación
1 mapa + top contribuciones

Criterio	Enfoque actual (2x2)	MCA
Tiempos	Escala con $p(p-1)/2$ cruces, **más ida y vuelta para sintetizar.**	1 modelo + validaciones + lectura guiada de ejes y contribuciones.
Análisis	Hallazgos locales; **depende de que pares miro primero.**	**Panorama conjunto;** segmentos y tensiones aparecen en el mismo mapa.
Decisiones	**Mayor riesgo de sesgo** por volumen, ruido y selección manual.	Decisiones apoyadas en **estructura global** y evidencia visual interpretable.

MCA no elimina el analisis bivariado; **lo prioriza**.
Primero vemos la pelicula completa y luego bajamos al detalle donde importa.

Con la misma informacion, MCA cambia el nivel de sintesis y reduce sesgos de lectura.

ANALÍTICA
AVANZADA

Intuición estadística_

Matemática detrás del MCA

Intuición estadística

La matemática detrás del MCA

Piensa en MCA como una **extensión del razonamiento geométrico de PCA**, pero **para variables categóricas** codificadas en una matriz indicadora.

1. Matriz indicadora

1	0	1	0	0
0	1	0	1	0
1	0	0	0	1

Cada fila es un individuo y cada columna una categoría (0/1).

2. Frecuencias

$$P = \frac{1}{n} X$$

perfiles / masas

Se normaliza para trabajar con perfiles y masas relativas.

3. Centrado / pesos

$$S = D_r^{-1/2}(P - rc^T)D_c^{-1/2}$$

distancia χ^2

Se compara lo observado vs lo esperado bajo independencia.

4. Descomposición

$$S = U\Sigma V^T$$

ejes latentes

La descomposición en valores singulares encuentra ejes latentes que capturan la inercia explicada

5. Coordenadas

$$F = D_r^{-1/2}U\Sigma$$
$$G = D_c^{-1/2}V\Sigma$$

mapa final

Se proyectan individuos y categorías en pocas dimensiones.

Conexión correcta con PCA

- PCA trabaja sobre variables continuas y desvíos respecto a medias.
- MCA trabaja sobre categorías y desvíos respecto a independencia.
- En ambos casos, SVD genera ejes latentes ordenados por varianza/inercia.

Qué significa la inercia

- Cantidad de asociación estructural capturada por cada eje.
- No es “varianza” literal, pero cumple un rol análogo para resumir estructura.
- Dim 1 y Dim 2 sirven si concentran una porción interpretable de esa inercia.

Resumen

De una nube de tablas **pasamos a un espacio reducido** donde las asociaciones quedan “ordenadas” por importancia estructural.

Intuición estadística

Gráficas y métricas importantes en MCA

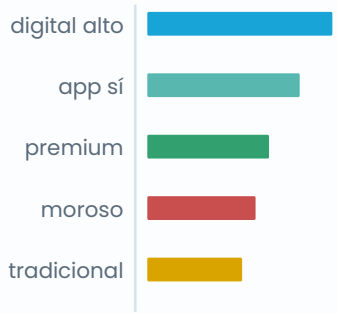
No basta con mostrar el mapa. Hay que justificar **qué eje explica**, qué **categorías mandan** y cuáles sí **están bien representadas**.

1. Mapa de categorías



- un mapa para detectar perfiles que co-ocurren
- interpretar mejor el plano con categorías lejos del origen
- no inferir “causalidad”; sólo estructura asociativa

2. Contribución por dimensión



Lectura: si una categoría tiene alta contribución, ayuda a “nombrar” la dimensión.

3. Calidad de representación (cos2)



- cos2 alto = el punto vive bien en el plano
- cos2 bajo = mejor no forzar interpretación visual

4. Check rápido de lectura

- explicar ejes con categorías de alta contribución
- revisar masas si hay categorías muy raras
- usar cos2 antes de interpretar cercanías
- si un punto queda pegado al origen, discrimina poco

En una buena lectura MCA, el mapa se acompaña de contribuciones, cos2 y criterio para nombrar ejes.

ANALÍTICA AVANZADA

Casos prácticos_

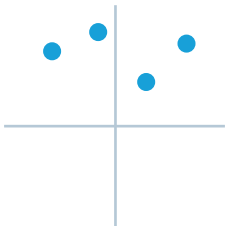
Casos prácticos

Dónde esta lectura visual genera valor

El mismo lenguaje gráfico sirve para negocio, riesgo, experiencia, retención y propensión.

Banca

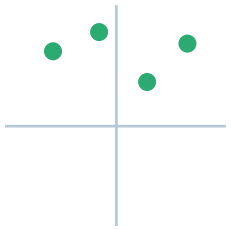
Canal, producto, perfil, mora



Detectar perfiles de venta y riesgo por segmento.

Retail

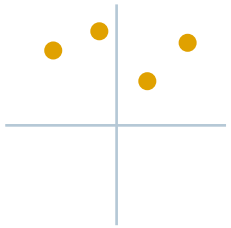
Categoría, ticket, frecuencia, promo



Entender qué combinaciones definen shoppers distintos.

Seguros

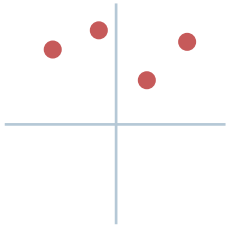
Cobertura, siniestro, canal, antigüedad



Separar clientes sensibles a precio vs protección.

Fuga / propensión

Uso digital, reclamo, contacto, churn



Priorizar acciones de retención o next best action.

Qué mirar en las gráficas MCA

- Cercanía entre categorías
- Oposición entre perfiles
- Contribuciones a las dimensiones
- Calidad de representación
- Clusters interpretables

La promesa no es solo visualizar bonito; es condensar evidencia para accionar mejor.

Otras técnicas

Aplicación de otras técnicas de reducción

MCA convive con otras tecnicas; la eleccion depende del tipo de dato y de la pregunta.

Tecnica	Entrada	Que resume	Cuando usar	Visual tipico
PCA	Variables numericas	Varianza y factores latentes	Medidas continuas y muchas columnas correlacionadas	Plano de componentes / loadings
MCA	Variables categoricas	Asociaciones entre modalidades	Encuestas, perfiles, tipologias y segmentacion	Mapa factorial de categorias
MDS	Matriz de distancias o similitudes	Proximidades preservadas en pocas dimensiones	Percepción de marca, preferencias, proximidad competitiva.	Mapa de proximidad

Regla practica

```
Numeros -> PCA | Categorias -> MCA | Distancias predefinidas -> MDS
```

ANALÍTICA AVANZADA

Gracias

Team

Futura Data &
Analítica Avanzada