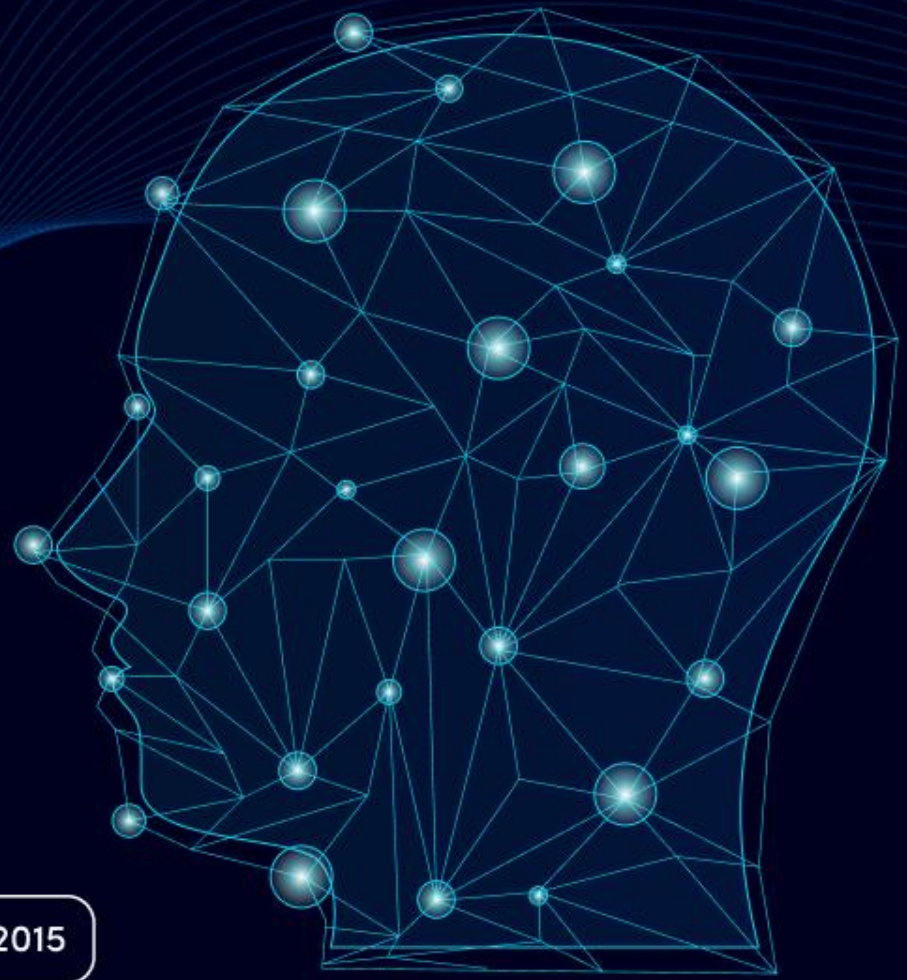
FUTURA
ANALITICA AVANZADA

PROGRAMA

Data Science for Business

Aprendizaje práctico y aplicado, con certificación ISO 9001 que garantiza calidad y excelencia



Mentores Top

Aprendizaje **100% aplicado**

Certificación **ISO 9001:2015**

BIENVENIDOS

FUTURA

DATA Y ANALITICA AVANZADA

Nos comprometemos con ayudarte a **impulsar** tu carrera profesional y tu empresa.



+20
Empresas satisfechas

+10
Mentores expertos

PROGRAMA
Data Science For Business

Reglas



Por favor, al ingresar a la sala MEET, usa tu **nombre y apellido** al inicio para identificarte



Se **puntual** en cada sesión.



Para estar más concentrados, es recomendable **mantener el micrófono en silencio** durante la sesión.



Usaremos el **chat para las preguntas**. Si necesitas hablar, puedes encender el micrófono cuando sea necesario



Completa las **tareas asignadas** a tiempo

Requisitos mínimo para obtener la certificación

Calificación

Asistencia	20%
Quiz de clase	30%
Trabajo Final Módulo	50%

ANALÍTICA AVANZADA

MÓDULO 2 · ESTADÍSTICA

SESIÓN 3

Probabilidad Aplicada_

Distribuciones reales · TLC

Lo que sabrás reconocer y decidir al terminar esta sesión

Objetivos de la Sesión 4

01

Reconocer la distribución detrás de tus datos

Identificar la huella de Bernoulli, Binomial, Poisson, Normal, Log-normal y Exponencial en problemas reales, sin derivar fórmulas.

02

Modelar antes de calcular

Elegir qué distribución usar según la pregunta de negocio: tasa, conteo, tiempo, monto, promedio.

03

Entender el TLC sin demostrarlo

Saber por qué los promedios se vuelven Normales aunque los datos originales no lo sean — y por qué esto habilita la inferencia.

04

Conectar probabilidad con decisión

Pasar de "esta es la distribución" a "esta es la recomendación de negocio" en cuatro casos sectoriales.

Caso de apertura · Reunión del CRO con su equipo de risk analytics

BancoSur · Reporte de portfolio Q1

"¿Estamos bien o estamos en problemas?" — Marta Echevarría, CRO

DEFAULT RATE	FRAUDES / DÍA	TICKET PROMEDIO PRÉSTAMO	TIEMPO MEDIO A DEFAULT	DÍAS-MORA PROMEDIO
2.8%	**4.2**	**S/ 18,400**	**14 meses**	**23 d**
+0.3 pp vs Q4	*promedio mensual*	*media muestral*	*desde originación*	*agregado mensual*

LA PREGUNTA DE LA CRO

"Necesito que me digan, en 30 minutos: ¿el 2.8% de default es preocupante o es ruido normal? ¿Los 4.2 fraudes diarios significan que tenemos un problema o estamos dentro de lo esperable? ¿Por qué el ticket promedio sigue subiendo si el portfolio es estable? ¿Cuánto vive en promedio un crédito antes de caer? Y por qué los días-mora son tan parecidos mes a mes."

LO QUE VAMOS A HACER HOY

Cada uno de estos 5 KPIs vive en una distribución diferente. Hoy vas a aprender a reconocer cuál es cuál, y, al cierre de la sesión, vamos a volver a este mismo dashboard con la respuesta para Marta.

Repaso veloz antes de entrar en las cinco distribuciones

¿Qué es una distribución, en términos de negocio?

LO QUE YA VIMOS

Variable aleatoria

Una variable cuyo valor depende del azar. Cada cliente paga un ticket distinto, cada llamada al call center llega en un momento distinto, cada préstamo se default-ea o no.

La distribución es el "molde"

Le dice a la variable aleatoria qué valores son frecuentes, cuáles son raros, y con qué probabilidad ocurren. Sin distribución, una variable aleatoria es solo ruido.

Esperanza E[X] y varianza Var(X)

El "centro" y la "dispersión" de la distribución, ahora aplicados al modelo teórico.

LO QUE TOCA HOY

Cinco moldes, cinco preguntas

En la práctica, el 80% de los problemas de negocio caen en uno de cinco moldes. Reconocer cuál aplica es la diferencia entre modelar bien y estimar al ojo.

- Bernoulli / Binomial · el sí/no
- Poisson · conteos por unidad de tiempo
- Log-normal · montos asimétricos
- Exponencial · tiempo entre eventos
- Normal · promedios y mediciones

No vas a derivar fórmulas. Vas a aprender a oler cuál distribución está detrás de tus datos.

El mapa de la sesión · una distribución por pregunta de negocio

Cinco huellas, cinco distribuciones

CUANDO VES…	ES HUELLA DE…	PREGUNTA TÍPICA
% de "sí/no" sobre N intentos	**Binomial**	*"¿El lift de 2.8% → 3.1% es real o es ruido?"*
Conteos de eventos por unidad de tiempo (sin tope superior natural)	**Poisson**	*"¿Cuántos agentes necesito para cubrir el pico?"*
Algo positivo, asimétrico, con cola larga a la derecha	**Log-normal**	*"¿Por qué la media de tickets está sobreestimada?"*
Tiempo entre eventos o hasta que algo ocurre	**Exponencial**	*"¿Cuánto vive un cliente antes de hacer churn?"*
Promedios de muchas observaciones, mediciones físicas	**Normal**	*"¿Por qué el ticket promedio mensual es tan estable?"*

Si te llevas una sola cosa de hoy, es esta tabla. Te va a servir el lunes.

El modelo más simple · un solo intento, dos resultados

Bernoulli · el sí/no

LA IDEA

Un experimento con dos resultados posibles: éxito (1) con probabilidad p, fracaso (0) con probabilidad 1−p.

ÉXITO
p

FRACASO
1 − p

PARÁMETRO ÚNICO

p = probabilidad de éxito

$$E[X] = p \qquad Var(X) = p(1-p)$$

Cada cliente que entra a tu landing es una variable Bernoulli: compra (1) o no compra (0). El p del negocio es la tasa de conversión.

EN NEGOCIO

BANCA

Cada solicitud de crédito: ¿se aprueba o no? p = tasa de aprobación.

RETAIL

Cada visita al carrito: ¿convierte o no? p = conversión del checkout.

TELCO

Cada cliente en fin de contrato: ¿renueva o no? p = retention rate.

GAMING

Cada sesión de juego: ¿genera revenue o no? p = monetización por sesión.

Cuando repites un Bernoulli n veces, suma los éxitos

Binomial · ¿cuántos sí en N intentos?

FÓRMULA

$$P(X = k) = C(n, k) \cdot p^k \cdot (1 - p)^{(n - k)}$$

EN LENGUAJE NATURAL

Si haces n intentos independientes y cada uno tiene probabilidad p de éxito, la Binomial te dice cuán probable es obtener exactamente k éxitos. No vas a calcularla a mano — Excel (=BINOM.DIST), Python (scipy.stats.binom) y SQL la resuelven. Lo que sí importa: reconocer cuándo aplica.

EN NEGOCIO

BANCA

De 1,000 solicitudes mensuales, ¿cuál es la probabilidad de tener entre 25 y 35 defaults si la tasa esperada es 3%?

RETAIL

De 50,000 visitas a la landing, ¿es el lift de 2.8% → 3.1% real o cae dentro del ruido binomial?

TELCO

De 5,000 contratos por vencer, ¿cuántas renovaciones esperar si el retention rate histórico es 87%?

GAMING

De 200 jugadores nuevos, ¿cuál es la probabilidad de retener al menos 60 al cabo de 7 días?

$P(25 < X < 35)$

El caso clásico · A/B test de conversión

Binomial en acción · ¿el lift es real o es ruido?

EL PROBLEMA

Tu equipo de marketing corre un A/B test. La versión A convirtió 2.8% (control) y la versión B convirtió 3.1% (tratamiento). El director quiere lanzar B mañana. Antes de firmar, tu pregunta: ¿este 0.3 pp de diferencia es real o cae dentro del ruido aleatorio?

⚠ NO CONCLUYENTE

CON 1,000 USUARIOS POR BRAZO

A: 28 conversiones · B: 31 conversiones

Diferencia: 3 conversiones extras.
Dentro del rango de ruido binomial esperado.
No puedes concluir nada.

✓ LIFT REAL

CON 50,000 USUARIOS POR BRAZO

A: 1,400 conversiones · B: 1,550 conversiones

Diferencia: 150 conversiones extras.
Fuera del rango de ruido binomial.
El lift es real, lanza B.

LO QUE TE LLEVAS

La Binomial te da el rango de variabilidad esperable bajo azar. Si la diferencia entre A y B cae dentro de ese rango, no es señal, es ruido. Esto es la base intuitiva del poder estadístico que veremos formalmente en Sesión 4.

Para conteos de eventos raros que ocurren independientemente en el tiempo

Poisson · ¿cuántas veces ocurre algo en un intervalo?

LA IDEA

Cuentas cuántos eventos ocurren en un intervalo (de tiempo, espacio o cualquier unidad). Los eventos son independientes, raros y ocurren a una tasa promedio λ constante.

EJEMPLOS REALES

· Llamadas que entran al call center entre las 9 y 10 AM
· Fraudes detectados por día
· Quejas recibidas por canal en un mes
· Errores de servidor por hora

PARÁMETRO ÚNICO

λ = tasa promedio de ocurrencia

$$E[X] = \lambda \qquad Var(X) = \lambda$$

La media y la varianza son iguales, propiedad única de Poisson. Si en tus datos σ^2 es mucho mayor que $\bar{x}$, lo que tienes NO es Poisson (es sobre-dispersión, otra distribución).

EN NEGOCIO

BANCA

Fraudes detectados por día en el portfolio (λ ≈ 4.2/día en BancoSur).

RETAIL

Devoluciones por hora en customer service (λ ≈ 12/hora en pico).

TELCO

Reclamos por dropped calls por torre por día (planeamiento de red).

GAMING

Jackpots por máquina por mes (λ ≈ 2.3 — para forecast de pagos).

La probabilidad de exactamente k eventos en un intervalo

Poisson · fórmula

FÓRMULA

$$P(X = k) = (\lambda^k \cdot e^{(-\lambda)}) / k!$$

EN LENGUAJE NATURAL

Dado que tu sistema produce eventos a tasa λ por unidad de tiempo, la fórmula te dice cuán probable es ver exactamente k eventos en ese intervalo. Excel (=POISSON.DIST), Python (scipy.stats.poisson), SQL Server: todos la calculan. Lo que importa en negocio: si λ = 4.2 fraudes/día, ¿qué probabilidad hay de tener un día con 10 fraudes? Si es baja, ese día es alerta — no ruido.

EN NEGOCIO

BANCA

¿Probabilidad de que mañana se detecten ≥ 8 fraudes, dado λ = 4.2/día? P ≈ 5%. Si pasa, no es ruido.

RETAIL

¿Cuántos agentes asignar al checkout para tener 95% de prob. de atender todas las consultas/hora?

TELCO

¿Cuántas torres backup necesito si los fallos siguen Poisson con λ = 0.3/mes?

GAMING

¿Cuál es el peor mes esperable en pagos de jackpot (P95 de la Poisson) para hacer reserva?

El caso clásico · dimensionamiento de capacidad operativa

Poisson en acción · ¿cuántos agentes para SLA 95%?

EL PROBLEMA

Tu call center recibe en promedio 30 llamadas/hora (λ = 30). El SLA contractual exige atender al menos el 95% de las llamadas dentro de la hora. La pregunta: ¿con cuántos agentes operar? Cada agente atiende ~6 llamadas/hora.

AGENTES	CAPACIDAD (LLAMADAS/HORA)	P(ATENDER 95%) BAJO POISSON	VEREDICTO
5	30 (justo en la media)	*~50%*	**Inaceptable**
6	36	*~85%*	**Bajo SLA**
7	42	*~98%*	**CUMPLE 95%**
8	48	*~99.8%*	**Sobredimensionado**

LO QUE TE LLEVAS

Dimensionar a la media es perder el SLA el 50% del tiempo. La Poisson te dice cuánto buffer necesitas. Misma lógica para servers, cajeros, técnicos en campo, stock de seguridad.

La distribución de "lo positivo asimétrico" · la que más se confunde con Normal

Log-normal · cuando la media miente

LA IDEA

Si log(X) es Normal, entonces X es Log-normal. En la práctica: cualquier cosa positiva que crece multiplicativamente (no aditivamente). Muchos valores pequeños, pocos valores grandes, cola larga a la derecha que no termina.

SEÑALES EN TUS DATOS

· Media > Mediana (siempre, en log-normal)
· Asimetría positiva fuerte
· Cola larga con outliers que NO son errores
· log(X) se ve como una campana de Gauss

DOS PARÁMETROS

μ y σ del log(X), no del dato directo

$$E[X] = exp(\mu + \sigma^2/2)$$

$$Mediana = exp(\mu)$$

La media siempre es MAYOR que la mediana — y la diferencia crece con σ. Por eso reportar "ticket promedio" en log-normal sobreestima al cliente típico.

EN NEGOCIO

BANCA

Monto de los préstamos otorgados (muchos pequeños, pocos hipotecarios grandes).

RETAIL

Ticket de compra por cliente (mayoría < S/ 100, cola larga de B2B).

TELCO

Consumo de datos por usuario (power users en la cola derecha).

GAMING

Revenue por sesión (la mayoría pequeñas, high-rollers en la cola).

Por qué "ticket promedio S/ 142" no es lo que el ejecutivo cree

Log-normal en acción · la media siempre sobreestima

EL PROBLEMA

El CMO reporta "ticket promedio S/ 142, +3.2% vs Q4". Cuando descargas los datos y miras la distribución, descubres que el 80% de los clientes tienen ticket bajo S/ 100. ¿Quién es entonces el "cliente promedio" del S/ 142? La distribución es log-normal — y la media te está mintiendo.

Lo que dice el dashboard

TICKET PROMEDIO (MEDIA)

S/ 142

Lo que reporta el CMO.
Jalado por la cola de B2B.

El cliente real

TICKET MEDIANO (P50)

S/ 89

El cliente "del medio".
37% menor que la media.

El comportamiento típico

TICKET MODAL (PICO)

S/ 52

El monto más frecuente.
Lo que la mayoría compra.

LO QUE TE LLEVAS

Si reportas "media" en una distribución log-normal, le mientes al ejecutivo. La mediana es la métrica honesta del cliente típico. Pregunta de oro: ¿qué tan diferente es la media de la mediana? Si difieren mucho, hay cola larga, hay log-normal, y la decisión cambia. Esto conecta directo con la asimetría de Sesión 1.

El modelo del "tiempo hasta que algo pasa"

Exponencial · cuánto vive antes de morir

LA IDEA

Mide el tiempo entre dos eventos consecutivos (o hasta que ocurre el primero). Es la "hermana continua" de la Poisson: si los eventos llegan según Poisson con tasa λ, el tiempo entre eventos es Exponencial con la misma λ.

PROPIEDAD CLAVE · SIN MEMORIA

La probabilidad de que un cliente haga churn en el próximo mes NO depende de cuántos meses ya lleva contigo. Bajo Exponencial, el pasado no informa el futuro.

PARÁMETRO ÚNICO

λ = tasa de ocurrencia

$$E[X] = 1 / \lambda$$

"Tiempo promedio entre eventos"

Si BancoSur tiene 4.2 fraudes/día (Poisson, λ=4.2), entonces el tiempo medio entre fraudes es 1/4.2 ≈ 5.7 horas. Misma λ, dos lecturas distintas.

EN NEGOCIO

BANCA

Tiempo desde originación hasta default (14 meses promedio en BancoSur).

RETAIL

Tiempo entre compras de un cliente recurrente (recency en RFM).

TELCO

Tiempo de vida del cliente antes de churn (LTV depende de 1/λ).

GAMING

Tiempo entre jackpots por máquina (reservas y comunicación al jugador).

La distribución que aparece en todas partes — y por qué

Normal · la campana universal

LA IDEA

Distribución simétrica en forma de campana. Media = mediana = moda. Definida totalmente por dos parámetros: el centro (μ) y la dispersión (σ).

LA REGLA 68-95-99.7

· 68% de los datos cae en μ ± 1σ
· 95% cae en μ ± 2σ
· 99.7% cae en μ ± 3σ

Por eso "tres sigmas" es alerta en control de calidad.

DOS PARÁMETROS

$$X \sim N(\mu, \sigma^2)$$

$$E[X] = \mu \qquad Var(X) = \sigma^2$$

Cuidado: muchos KPIs de negocio NO son Normal (revenue, tickets, tiempos — son log-normal o exponencial). La Normal aparece sobre todo en errores de medición, control de calidad, y — el caso mágico — en los PROMEDIOS muestrales (TLC, próximo slide).

EN NEGOCIO

BANCA

Errores de medición en sistema de scoring (residuales del modelo).

RETAIL

Peso/volumen de productos en línea de producción (control de calidad).

TELCO

Latencia agregada por hora a lo largo del día (cuando se promedia).

GAMING

Días-mora promedio mensual (agregación que NORMALIZA la log-normal).

El resultado más profundo y útil de toda la estadística

Teorema del Límite Central · el puente a la inferencia

EL ENUNCIADO, EN UNA FRASE

Tomas muestras de cualquier distribución — bimodal, log-normal, exponencial, lo que sea — y calculas la media de cada muestra. A medida que el tamaño n de las muestras crece, la distribución de esas medias se vuelve Normal. SIEMPRE. Sin importar de dónde venían los datos originales.

Tickets de retail

Log-normal

Toma 100 tickets, saca media. Repite 1000 veces.

↓

La distribución de las medias → Normal

Tiempo entre churn

Exponencial

Toma 100 tiempos, saca media. Repite 1000 veces.

↓

La distribución de las medias → Normal

Conversión A/B test

Binomial

Toma 100 visitantes, saca tasa. Repite 1000 veces.

↓

La distribución de las tasas → Normal

POR QUÉ ESTO IMPORTA

El TLC es la razón por la que podemos hacer inferencia sin saber qué distribución tienen los datos. Mientras trabajemos con promedios y n sea suficiente, la teoría Normal aplica. Esto habilita TODO lo que veremos en Sesiones 4 y 5: intervalos de confianza, pruebas de hipótesis, A/B testing.

La forma matemática del TLC

TLC · enunciado formal

FÓRMULA

$$\bar{X} \sim N(\mu, \sigma^2 / n) \quad cuando\ n \to \infty$$

EN LENGUAJE NATURAL

Si X1, X2, …, Xn son variables independientes con media μ y varianza σ² finitas, entonces la media muestral $\bar{X}$ converge en distribución a una Normal con media μ y varianza σ²/n. ¿Qué significa "n suficiente"? En la práctica: n ≥ 30 funciona para distribuciones moderadamente asimétricas; n ≥ 100 si la cola es muy larga (log-normal severa); con Bernoulli/Binomial, n·p y n·(1−p) ≥ 10.

EN NEGOCIO

BANCA

Por eso el default rate mensual agregado es estable (es media de muchas Bernoullis).

RETAIL

Por eso el ticket promedio mensual es Normal aunque los tickets individuales sean log-normal.

TELCO

Por eso el ARPU agregado por segmento se modela bien con Normal — aunque cada cliente sea distinto.

GAMING

Por eso los KPIs agregados mensuales son estables — la varianza individual se promedia.

Cierre · de regreso al dashboard que abrimos la sesión

BancoSur · ahora con las distribuciones detrás

DEFAULT RATE

2.8%

BINOMIAL

¿Real o ruido?
Depende de n. Con 10K solicitudes, la varianza esperada de la tasa es ±0.2pp. 2.8% vs 2.5% Q4 está al borde — necesita análisis.

FRAUDES / DÍA

4.2

POISSON

¿Cuántos esperar?
95% de los días entre 0 y 9 fraudes. Un día con 12+ es señal real, no ruido.

TICKET PROMEDIO PRÉSTAMO

S/ 18,400

LOG-NORMAL

La media miente.
Mediana real ≈ S/ 8,200. El "promedio" lo levantan los hipotecarios. Reportar mediana.

TIEMPO MEDIO A DEFAULT

14 meses

EXPONENCIAL

Hazard rate constante.
1/14 ≈ 7% mensual de probabilidad de default — independiente de cuántos meses lleva el crédito.

DÍAS-MORA PROMEDIO

23 d

NORMAL (vía TLC)

Es estable porque es agregado.
Días-mora individuales son log-normal; el promedio mensual es Normal por TLC. Por eso es consistente.

Marta tiene respuestas: en treinta minutos pasamos de "no sé si esto es bueno o malo" a "esto sí, esto no, y esto lo reportamos distinto".

Lo que te llevas, ordenado

Cierre · Sesión 4

01 La distribución es un molde, no una fórmula

Tu trabajo no es derivar PMFs. Es reconocer qué molde calza con tus datos.

02 Cinco distribuciones, ~80% de problemas reales

Binomial, Poisson, Log-normal, Exponencial, Normal. Memoriza la tabla del slide 9.

03 En log-normal, la media miente

Si reportas promedio en datos asimétricos, sobrestimas al cliente típico. Reporta mediana.

04 Poisson y Exponencial son hermanas

Misma λ, dos lecturas: conteos por intervalo (Poisson) o tiempo entre eventos (Exponencial).

05 El TLC habilita la inferencia

Aunque los datos no sean Normales, los promedios sí lo son. Por eso Sesión 4 va a funcionar.

06 La pregunta correcta antes de calcular

"¿De qué distribución vienen mis datos?" — antes de elegir media, IC, o test estadístico.

SESIÓN 5 → Inferencia: muestreo, intervalos de confianza, pruebas de hipótesis, A/B testing aplicado.

GRACIAS

Probabilidad aplicada · Sesión 4 · Módulo 2

Data Science for Business · Futura Analítica Avanzada

