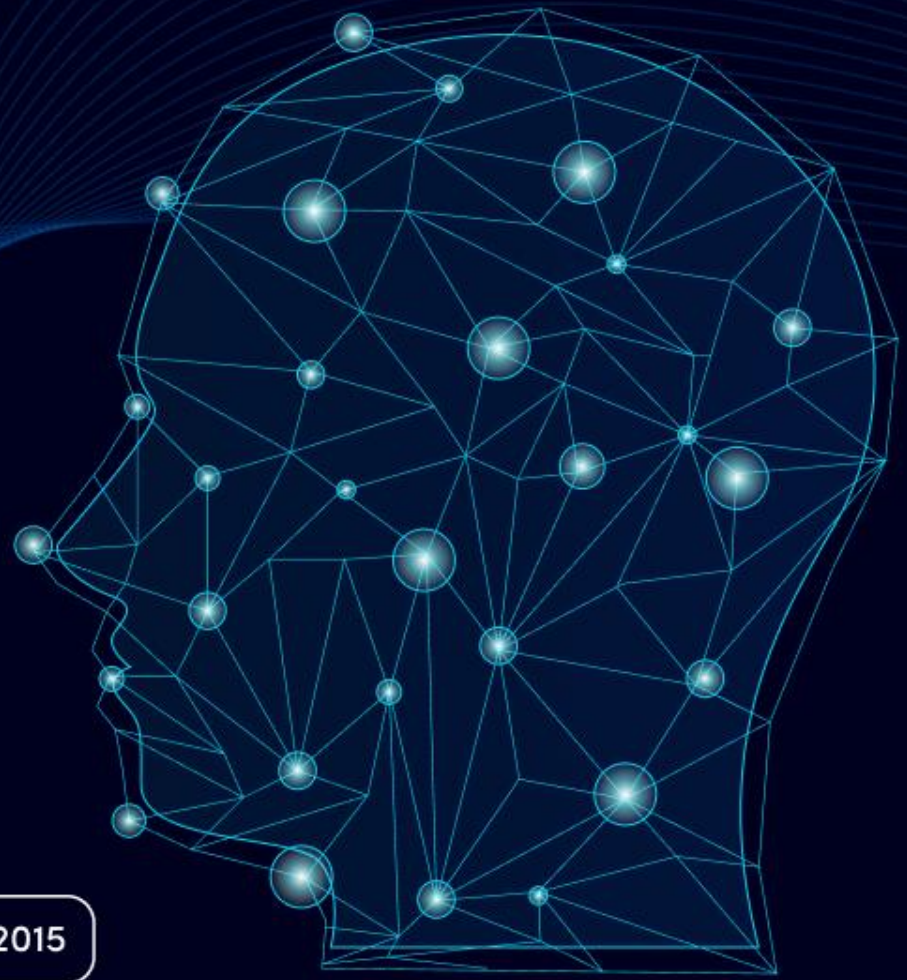
FUTURA
ANALITICA AVANZADA

PROGRAMA

Data Science for Business

Aprendizaje práctico y aplicado, con certificación ISO 9001 que garantiza calidad y excelencia



Mentores Top

Aprendizaje **100% aplicado**

Certificación **ISO 9001:2015**

BIENVENIDOS

FUTURA

DATA Y ANALITICA AVANZADA

Nos comprometemos con ayudarte a **impulsar** tu carrera profesional y tu empresa.



+20
Empresas satisfechas

+10
Mentores expertos

PROGRAMA
Data Science For Business

Reglas



Por favor, al ingresar a la sala MEET, usa tu **nombre y apellido** al inicio para identificarte



Se **puntual** en cada sesión.



Para estar más concentrados, es recomendable **mantener el micrófono en silencio** durante la sesión.



Usaremos el **chat para las preguntas**. Si necesitas hablar, puedes encender el micrófono cuando sea necesario



Completa las **tareas asignadas** a tiempo

Requisitos mínimo para obtener la certificación

Calificación

Asistencia	20%
Quiz de clase	30%
Trabajo Final Módulo	50%

ANALÍTICA AVANZADA

MÓDULO 2 · ESTADÍSTICA

SESIÓN 4

Inferencia Estadística_

De la muestra a la población · decidir con datos



Lo que sabrás decidir y comunicar al terminar esta sesión

Objetivos de la Sesión 5

01

Estimar parámetros desconocidos con honestidad

Pasar de "la muestra dice X" a "la población está en X ± Y con 95% de confianza" — y saber cuándo esa estimación es confiable.

02

Probar hipótesis con criterio estadístico

Decidir si una diferencia observada es real o ruido — usando p-valor y nivel de significancia, sin abusar de ellos.

03

Aplicar A/B testing con poder estadístico

Diseñar y leer experimentos: tamaño de muestra, poder, errores tipo I y II — los conceptos que distinguen análisis serio de marketing intuitivo.

04

Elegir la prueba adecuada para tu pregunta

Cuándo usar t, cuándo ANOVA, cuándo Chi², cuándo Mann-Whitney — el mapa de decisión que evita el error metodológico más común.

BancoSur · tres semanas después

Volvemos a BancoSur. Marta ya tiene las distribuciones detrás de cada KPI. Pero ahora vienen decisiones más concretas — y para decidir hace falta más que reconocer la distribución.

ESTIMACIÓN

¿Cuál es el verdadero default rate del portfolio? Mi muestra dice 2.8%, pero, ¿cuánto puedo confiar en ese número?

HIPÓTESIS

El default subió de 2.5% (Q4) a 2.8% (Q1). ¿Es real el deterioro, o es solo variabilidad muestral?

COMPARACIÓN

Tenemos 4 sucursales. ¿Hay alguna con default significativamente mayor a las demás? ¿O todas son iguales en riesgo?

INDEPENDENCIA

En el portfolio, ¿la mora depende del tipo de producto? ¿O es independiente, todos los productos defaultean parejo?

LO QUE VAMOS A HACER HOY

Cuatro preguntas, cuatro herramientas: Intervalos de Confianza, Pruebas de Hipótesis, ANOVA y Chi-Cuadrado. Al cierre, Marta tendrá respuestas concretas y defendibles para llevar al directorio.

Fundamentos

Inferencia Estadística





Población

Es el conjunto completo de todos los elementos, individuos, u objetos que comparten una o más características específicas y que son de interés para un estudio

Estadístico

Es un valor numérico que se calcula a partir de los datos de una muestra y se utiliza para estimar un parámetro poblacional

Estimador

Sea $X_1, X_2, \ldots, X_n$ una muestra aleatoria simple proveniente de una población con función de distribución F_θ, donde θ es un parámetro desconocido.

Definición: Un **estimador** de θ es una función medible

$$\hat{\theta} = T(X_1, X_2, \ldots, X_n)$$

definida sobre el espacio muestral, cuyo propósito es aproximar el valor verdadero del parámetro θ.

Dado que T depende de variables aleatorias, el estimador $\hat{\theta}$ es también una **variable aleatoria** y posee una **distribución de muestreo**.

Estimador

Inferencia Estadística

Sea $X_1, X_2, \ldots, X_n$ una muestra aleatoria del gasto de clientes en un casino, y sea μ la media poblacional desconocida.

La **media muestral** se define como:

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i,$$

y constituye un **estimador** de la media poblacional μ.

Ejemplo numérico: Si la muestra es

$$X = \{10, 15, 20, 25, 30\},$$

entonces

$$\hat{\mu} = \bar{X} = \frac{10 + 15 + 20 + 25 + 30}{5} = 20.$$

Así, el valor 20 es la *estimación puntual* de μ, obtenida mediante el estimador $\bar{X}$.

Técnicas de estimador de parámetros

- **Método de los Momentos (MM):** Determina el estimador igualando los momentos poblacionales teóricos con sus contrapartes empíricas.
- **Máxima Verosimilitud (MLE):** El estimador se obtiene maximizando la función de verosimilitud $L(\theta)$, que mide la plausibilidad de los datos dados los parámetros.
- **Mínimos Cuadrados (OLS):** El estimador minimiza la suma de cuadrados de los residuos,

$$\sum_{i=1}^{n}(y_i-\theta)^2 \quad \text{o} \quad \|y-X\beta\|^2$$

- **Método Bayesiano (MAP):** El estimador maximiza la densidad posterior $p(\theta \mid x)$, integrando información previa y evidencia observada.
- **Estimadores UMVUE:** Selecciona, entre los insesgados, aquel con varianza mínima según el criterio de Lehmann–Scheffé.
- **Bootstrap:** Utiliza remuestreo F_n para obtener estimadores ajustados y cuantificar su variabilidad sin asumir distribuciones paramétricas.

Propiedades de los estimadores

Sea $\hat{\theta} = T(X_1, \ldots, X_n)$ un estimador del parámetro poblacional θ.

- **Insesgadez:** Un estimador es insesgado si su esperanza coincide con el parámetro:

$$\mathbb{E}[\hat{\theta}] = \theta.$$

- **Consistencia:** $\hat{\theta}$ es consistente si converge en probabilidad al valor real del parámetro al aumentar el tamaño muestral:

$$\hat{\theta} \xrightarrow{p} \theta \quad \text{cuando } n \to \infty.$$

- **Eficiencia:** Entre los estimadores insesgados, $\hat{\theta}$ es eficiente si presenta la mínima varianza:

$$\mathrm{Var}(\hat{\theta}) \leq \mathrm{Var}(\tilde{\theta}) \quad \forall\, \tilde{\theta} \text{ insesgado.}$$

- **Suficiencia:** Un estadístico T es suficiente para θ si contiene toda la información relevante de la muestra respecto a θ, de modo que:

$$f(x_1, \ldots, x_n \mid T = t, \theta) = f(x_1, \ldots, x_n \mid T = t).$$

- **Completitud:** Un estadístico suficiente T es completo si todo estimador insesgado cuya esperanza es cero para todo θ debe ser casi seguro igual a cero.

Sesgo

Inferencia Estadística

Sea $\hat{\theta} = T(X_1, \ldots, X_n)$ un estimador del parámetro poblacional θ. La **definición formal del sesgo** del estimador se expresa como:

$$\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta.$$

Interpretación:

- Si $\text{Bias}(\hat{\theta}) = 0$, el estimador es **insesgado**.
- Si $\text{Bias}(\hat{\theta}) > 0$, el estimador tiende a **sobreestimar** el parámetro.
- Si $\text{Bias}(\hat{\theta}) < 0$, el estimador tiende a **subestimar** el parámetro.

De forma equivalente puede escribirse:

$$\mathbb{E}[\hat{\theta}] = \theta + \text{Bias}(\hat{\theta}),$$

lo que muestra la relación directa entre la esperanza del estimador, el parámetro y su sesgo.

Hipótesis

Inferencia Estadística

La definición de una hipótesis es bastante general, pero el punto importante es que una hipótesis hace una afirmación sobre la población

H0: Es una afirmación que indica la ausencia de efecto o diferencia. Es la hipótesis que se asume como verdadera al comienzo del análisis y que se intenta refutar.

Hipótesis nula → H_0, H_1 ← Hipótesis alterna

H1: Es la afirmación que se considera si la hipótesis nula es rechazada.

El objetivo de una prueba de hipótesis es decidir, basándose en una muestra, cuál de dos hipótesis complementarias es verdadera.

Contraste de Hipótesis

Inferencia Estadística

χ

Estadístico de prueba

Se determina en base a los datos y H0



Tipos de error

Tipo 1 Es el error que se comete cuando se rechaza la hipótesis nula (H0) siendo esta verdadera.

Tipo 2 Es el error que se comete cuando no se rechaza la hipótesis nula (H0) siendo esta falsa

α

Nivel de Significancia

Es la probabilidad de cometer un error tipo I

Se puede determinar si el estadístico de prueba tiene una distribución conocida

p_{valor}

Es la probabilidad de observar un resultado al menos tan extremo como el observado, bajo la suposición de que H0 es verdadera

Decisión

$p_{\text{valor}} < \alpha$

Basada en la comparación del estadístico de prueba con un valor crítico o del p-valor con α.

Contraste de Hipótesis

Inferencia Estadística

¿Cómo tomamos una decisión?

Determinar el nivel de significancia α

1%



Medicina

5%



Negocios e investigación social

0.1%



Aplicaciones con alta sensibilidad

Decisión

Se rechaza H0

$$p_{\text{valor}} < \alpha$$

No se rechaza H0

$$p_{\text{valor}} \geqslant \alpha$$

Tipos de errores

Sea H_0 la hipótesis nula y H_1 la hipótesis alternativa. En un contraste estadístico pueden ocurrir dos tipos de errores:

Error Tipo I (falso positivo): Consiste en *rechazar H_0 cuando en realidad es verdadera*. Su probabilidad se define como:

$$\alpha = \mathbb{P}(\text{Rechazar } H_0 \mid H_0 \text{ es verdadera}),$$

y se denomina **nivel de significancia**.

Error Tipo II (falso negativo): Consiste en *no rechazar H_0 cuando H_1 es verdadera*. Su probabilidad se define como:

$$\beta = \mathbb{P}(\text{No rechazar } H_0 \mid H_1 \text{ es verdadera}),$$

y la cantidad $1 - \beta$ se denomina **potencia de la prueba**.

En inferencia estadística, se busca diseñar pruebas que mantengan α controlado y minimicen β, maximizando así la potencia de detección de efectos reales.

Tipos de errores

Recuerda que la conclusión nos da solo evidencia **significativa** (o no) a un x% de nivel de significancia para rechazar (o no) la hipótesis nula.

Tipos de inferencia

Inferencia Paramétrica: Consiste en realizar inferencias sobre parámetros θ de una familia conocida de distribuciones F_θ. Se asume que los datos provienen de un modelo probabilístico específico (por ejemplo, Normal, Binomial, Poisson), lo que permite utilizar estimadores y pruebas basados en expresiones cerradas.

$$X_1, \ldots, X_n \sim F_\theta \quad \text{con forma funcional conocida.}$$

Inferencia No Paramétrica: Realiza inferencias sin asumir una forma funcional concreta para la distribución poblacional; en su lugar, utiliza propiedades generales de la muestra o distribuciones empíricas. Los métodos no dependen de parámetros específicos y son robustos ante desviaciones del modelo.

$$F \text{ desconocida} \quad \Rightarrow \quad \text{inferencia basada en } F_n \text{ (distribución empírica).}$$

Comparación: La inferencia paramétrica es más eficiente bajo supuestos correctos, mientras que la no paramétrica es más flexible y robusta ante violaciones de normalidad u otras restricciones del modelo.

Ejemplos de inferencia paramétrica

Contexto: Una empresa desea determinar si el **gasto promedio semanal** de sus clientes es diferente de 200 soles.

Supuesto del modelo: Se asume que los datos provienen de una distribución Normal:

$$X_1, X_2, \ldots, X_n \sim \mathcal{N}(\mu, \sigma^2),$$

donde μ es la media poblacional desconocida y σ^2 la varianza.

Hipótesis del contraste:

$$H_0 : \mu = 200, \qquad H_1 : \mu \neq 200.$$

Estadístico de prueba (t de Student):

$$T = \frac{\bar{X} - 200}{S/\sqrt{n}} \sim t_{n-1} \quad \text{bajo } H_0,$$

donde S es la desviación estándar muestral.

Regla de decisión: Rechazar H_0 si:

$$|T| > t_{\alpha/2, n-1}.$$

Interpretación: Si $|T|$ excede el umbral crítico, existe evidencia estadística de que el gasto promedio es distinto de 200 soles.
Motivo por el cual es paramétrica: Se parte de un modelo probabilístico específico (Normal), y el estadístico tiene una distribución teórica exacta (t-Student).

Ejemplos de inferencia no paramétrica

Contexto: Se evalúa si el nivel de **satisfacción de clientes** difiere entre dos sucursales (A y B). Los datos son ordinales: Muy Bajo, Bajo, Medio, Alto, Muy Alto.

Motivación no paramétrica: Los datos no cumplen supuestos de normalidad ni escala numérica continua; por tanto, no se puede usar t-test.

Prueba utilizada: Mann–Whitney U (Wilcoxon de rangos para muestras independientes).

Hipótesis del contraste:

$$H_0 : F_A = F_B \quad \text{(las distribuciones poblacionales son iguales)},$$
$$H_1 : F_A \neq F_B.$$

Construcción del estadístico: Se combinan ambas muestras, se asignan rangos y se calculan:

$$U_A = n_A n_B + \frac{n_A(n_A+1)}{2} - R_A, \qquad U_B = n_A n_B + \frac{n_B(n_B+1)}{2} - R_B, \qquad U = \min(U_A, U_B).$$

Regla de decisión: Rechazar H_0 si:

$$U < U_\alpha.$$

Interpretación: Un valor pequeño de U indica diferencias sistemáticas en los rangos y, por ende, en las distribuciones de satisfacción entre las sucursales.
Motivo por el cual es no paramétrica: No requiere supuestos sobre la forma de F; se basa únicamente en los rangos muestrales y la distribución empírica.

Prueba Chi-Cuadrado de independecia

Inferencia Estadística

Objetivo: Evaluar si existe asociación entre dos variables categóricas mediante el análisis de una tabla de contingencia.

Hipótesis:

H_0 : Las variables son independientes $\qquad$ H_1 : Las variables no son independientes.

Estadístico de prueba:

$$\chi^2 = \sum_{i=1}^{r} \sum_{j=1}^{c} \frac{(O_{ij} - E_{ij})^2}{E_{ij}},$$

donde O_{ij} son las frecuencias observadas y

$$E_{ij} = \frac{(n_{i\cdot})(n_{\cdot j})}{n}$$

son las frecuencias esperadas bajo independencia.

Distribución bajo H_0:

$$\chi^2 \sim \chi^2_{(r-1)(c-1)}.$$

Criterio de decisión: Rechazar H_0 si

$$\chi^2_{\text{obs}} > \chi^2_{\alpha,(r-1)(c-1)}.$$

Prueba ANOVA

Inferencia Estadística

Objetivo: Evaluar si las medias de una variable cuantitativa difieren entre k grupos o tratamientos independientes.

Hipótesis:

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k, \qquad H_1 : \exists\, i, j : \mu_i \neq \mu_j.$$

Modelo estadístico:

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij},$$

donde:

- Y_{ij} = observación del grupo i
- μ = media global

Estadístico ANOVA:

Distribución bajo H_0:

$$F \sim F_{(k-1),(n-k)}.$$

Regla de decisión: Rechazar H_0 si:

$$F_{\text{obs}} > F_{\alpha,(k-1),(n-k)}.$$

Supuestos:

- Normalidad en cada grupo.
- Homocedasticidad: $\sigma_1^2 = \cdots = \sigma_k^2$.
- Independencia de observaciones.

Pruebas de Normalidad

H_0 : La muestra proviene de una distribución normal, H_1 : La muestra no proviene de una distribución normal.

A partir de un estadístico de prueba con distribución conocida bajo H_0, se determina si la evidencia muestral permite rechazar H_0 con un nivel de significancia α.

Pruebas de normalidad.

- **Shapiro–Wilk:** Contrasta H_0: "la muestra proviene de una normal". Alta potencia, recomendado para $n < 2000$.
- **Kolmogorov–Smirnov (K–S):** Compara la CDF empírica con la CDF teórica normal con parámetros conocidos. No válido si μ y σ son estimados.
- **Lilliefors:** Versión corregida del K–S para el caso en que μ y σ se estiman de la muestra. Adecuado para análisis exploratorio.
- **Anderson–Darling:** Contrasta normalidad con énfasis en colas. Mayor sensibilidad a colas pesadas, útil en riesgo y datos financieros.

Conclusiones

- La inferencia estadística permite generalizar conclusiones de la muestra hacia la población.
- Todo procedimiento inferencial se basa en supuestos que deben ser verificados.
- La inferencia orienta las decisiones de negocio, no las reemplaza.

GRACIAS

Inferencia Estadística · Sesión 4 · Módulo 2

Data Science for Business · Futura Analítica Avanzada

