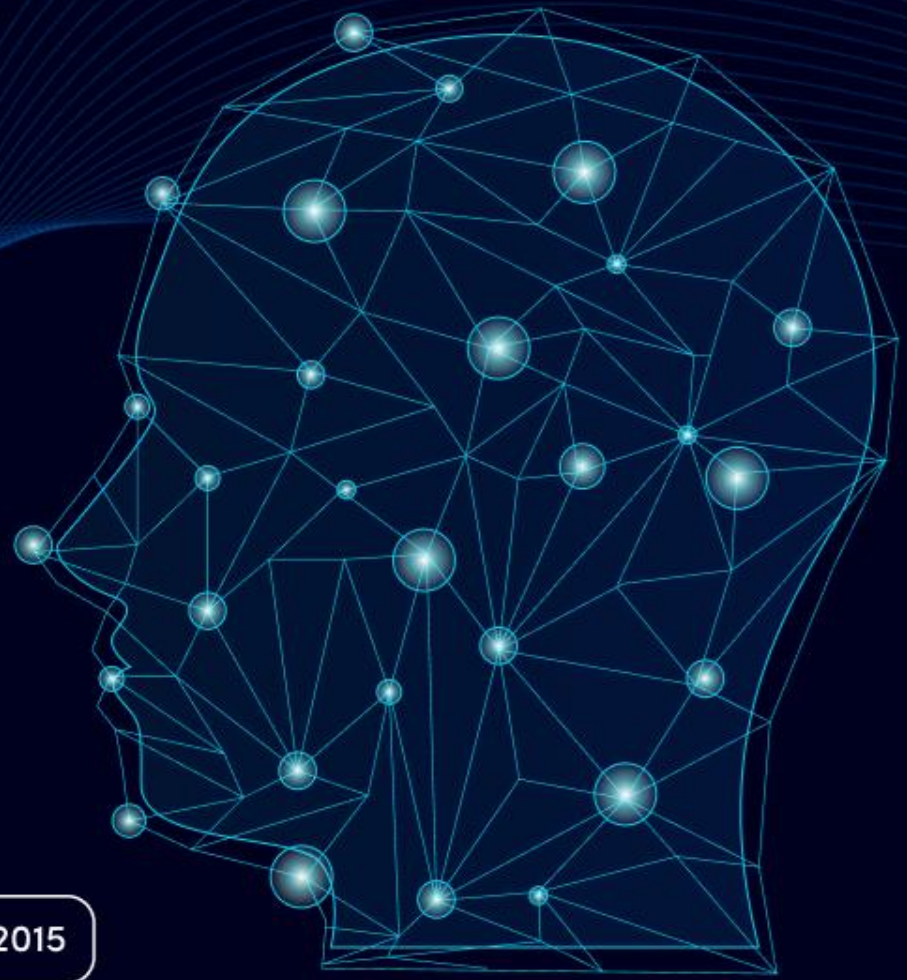
FUTURA
ANALITICA AVANZADA

PROGRAMA

Data Science for Business

Aprendizaje práctico y aplicado, con certificación ISO 9001 que garantiza calidad y excelencia



Mentores Top

Aprendizaje **100% aplicado**

Certificación **ISO 9001:2015**

FUTURA
ANALITICA AVANZADA

BIENVENIDOS

FUTURA

DATA Y ANALITICA AVANZADA

Nos comprometemos con ayudarte a **impulsar** tu carrera profesional y tu empresa.

+20
Empresas satisfechas

+10
Mentores expertos

PROGRAMA
Data Science For Business

Reglas



Por favor, al ingresar a la sala MEET, usa tu **nombre y apellido** al inicio para identificarte



Se **puntual** en cada sesión.



Para estar más concentrados, es recomendable **mantener el micrófono en silencio** durante la sesión.



Usaremos el **chat para las preguntas**. Si necesitas hablar, puedes encender el micrófono cuando sea necesario



Completa las **tareas asignadas** a tiempo

Requisitos mínimo para obtener la certificación

Calificación

Asistencia	20%
Quiz de clase	30%
Trabajo Final Módulo	50%

Agenda

1. Observando datos multivariados
2. Análisis de componentes principales
3. Análisis de correspondencia multiple



ANALÍTICA AVANZADA

Procesamiento de datos y Feature Engineer_



1. Terminología básica
2. Proceso de Modelamiento de Datos
3. Preprocesamiento de datos: Partición train-test-validación
4. Análisis de componentes Principales (PCA)
5. Weight of Evidence (WoE)
6. Balanceo de datos
7. Entendimiento del Overfitting y Underfitting

Procesamiento de Datos

Terminología básica

- **Conjunto de Datos (Data Set):** El total del conjunto de datos (filas y columnas) al cual se quiere desarrollar un modelo de Machine Learning con el fin de representar la realidad lo mejor posible. Contiene variables independientes y dependientes.

- **Variables Independientes (Features, V.I.):** Aquellas columnas del Data Set que serán usadas por el algoritmo para generar un modelo que prediga lo mejor posible las variables dependientes.

- **Variables Dependientes (Labels, Target, V.D.):** Columna(s) del Data Set que corresponde a una correlación de V.I. y que debe ser predicha por el futuro modelo.

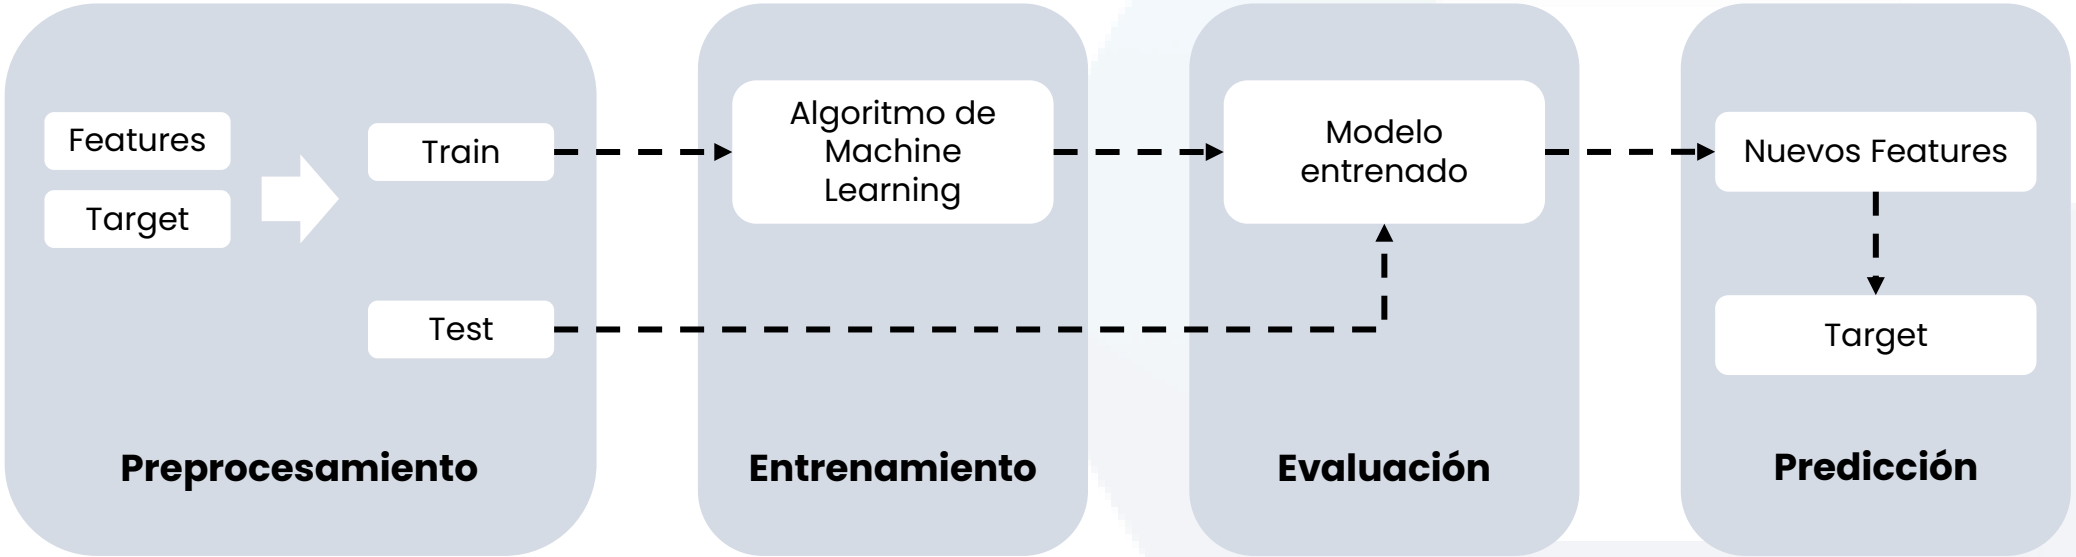
- **Conjunto de Datos de Entrenamiento (Training Set):** Subconjunto del Data Set que será utilizado para entrenar el modelo que se pretende generar.

- **Conjunto de Datos del Test (Test Set):** Subconjunto del Data Set que se le pasará al modelo una vez haya sido entrenado para comprobar, mediante el uso de diferentes métricas, sus indicadores más importantes de calidad.

- **Conjunto de datos de Validación (Validación Set):** Subconjunto del Data Set que se utilizará para medir el rendimiento global del modelo y su monetización en las posteriores campañas comerciales.

Procesamiento de Datos

Modelado de Datos



Procesamiento de Datos

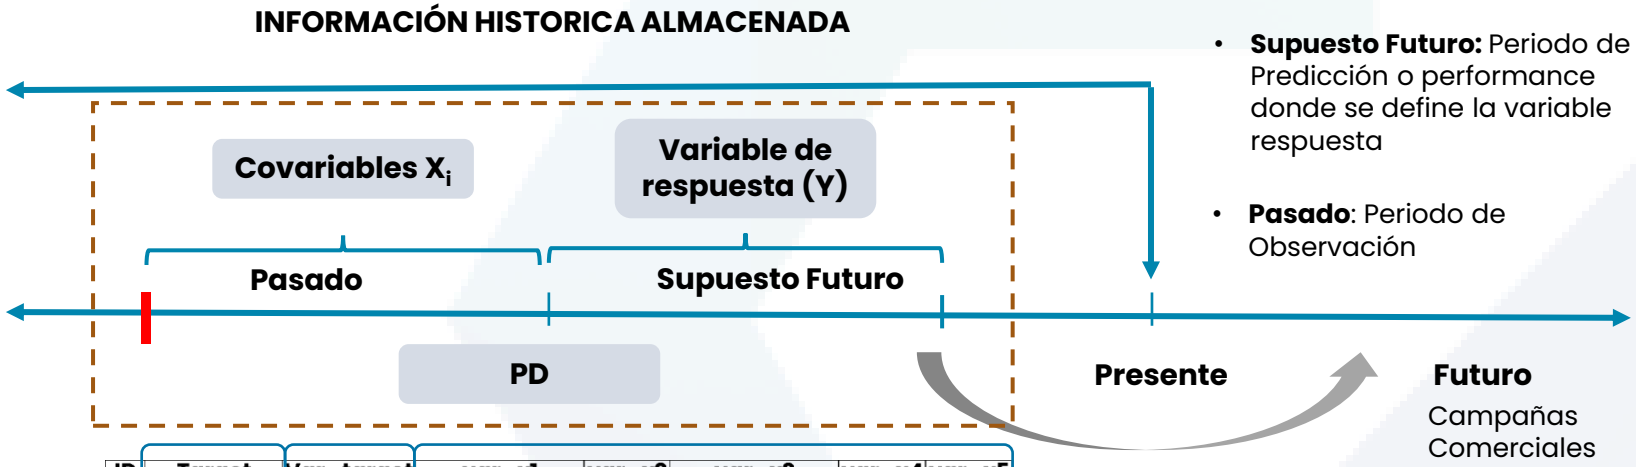
Modelado de Datos

Aprendizaje supervisado

Enfoque temporal

Línea de tiempo

Enfoque Matricial



- **Supuesto Futuro:** Periodo de Predicción o performance donde se define la variable respuesta
- **Pasado**: Periodo de Observación

ID	Target	Var_target	var_x1	var_x2	var_x3	var_x4	var_x5
1	Segmento1	1	0.033948813	330	458.393	1	1
2	Segmento3	3	0.287918593	330	455.092	0	2
3	Segmento2	2	0.162012134	411	787.183	0	10
4	Segmento1	1	0.096877545	638	254.671	1	7
5	Segmento3	3	0.10687976	49	28.667	1	8
6	Segmento2	2	0.635429046	807	899.554	1	8
7	Segmento1	1	0.59563992	832	859.258	1	0
8	Segmento3	3	0.426708219	866	115.184	1	4
9	Segmento2	2	0.523748321	198	890.931	1	6
10	Segmento1	1	0.720498495	815	141829	1	10
11	Segmento3	3	0.280009143	828	839.920	0	1

Población Objetivo

Variables de respuesta (Y)

Covariables x_i

Métrica Var target $F(var_x_i)$

Procesamiento de Datos

Partición train – test -validación

División en entrenamiento y prueba

¿Cómo podemos saber si nuestro modelo va a predecir/clasificar fuera de la data de entrenamiento?

¿Cómo sabemos si no estamos sobreajustando a la data de entrenamiento?

¿Cómo podemos evitar los efectos de la estacionalidad?

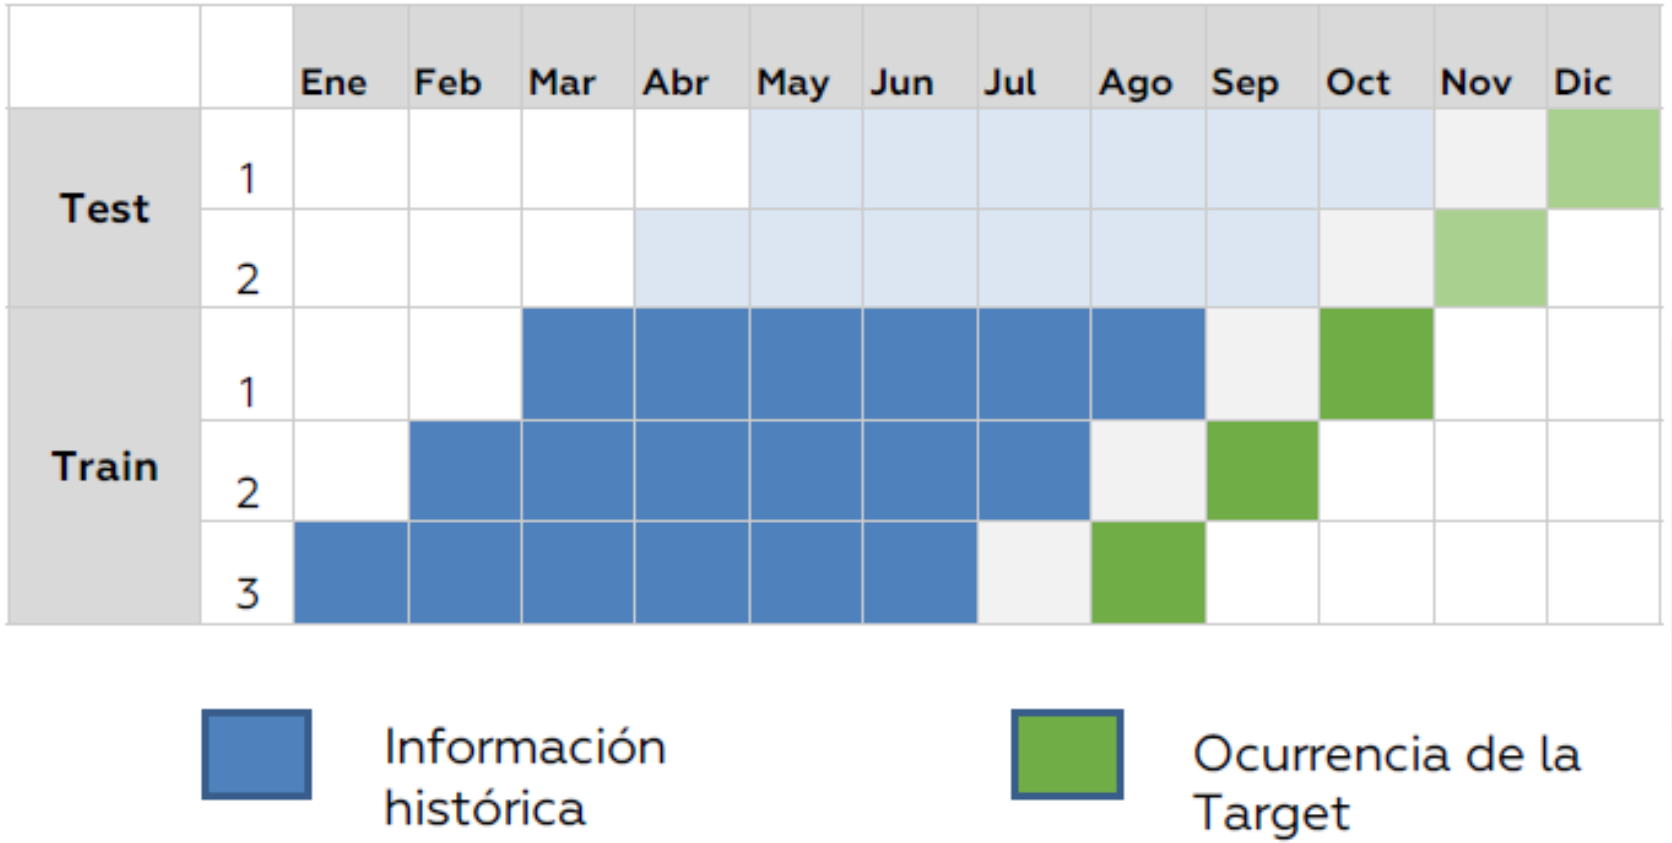


Podemos utilizar la data de un año completo para entrenar el modelo y como prueba, “fuera de tiempo” utilizar data de los siguientes tres o seis meses

Procesamiento de Datos

Partición train – test -validación

División en entrenamiento y prueba



Procesamiento de Datos

Partición train – test -validación

División en entrenamiento y prueba

COSECHAS : VARIOS PERIODOS DE ANALISIS

MES	No Fuga	Fuga	Stock
ene-20	90.000	10.000	100.000
feb-20	80.000	20.000	100.000
mar-20	95.000	5.000	100.000
abr-20	96.000	4.000	100.000
may-20	96.000	4.000	100.000

Desarrollo

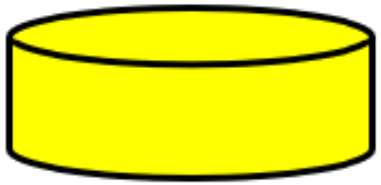
ENTRENAMIENTO		TEST	
No Fuga	**Fuga**	No Fuga	**Fuga**
63.000	**7.000**	27.000	**3.000**
56.000	**14.000**	24.000	**6.000**
66.500	**3.500**	28.500	**1.500**
67.200	**2.800**	28.800	**1.200**
67.200	**2.800**	28.800	**1.200**

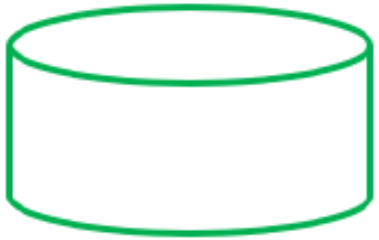
DATA DE VALIDACIÓN			
jun-20	96.000	4.000	100.000
jul-20	96.000	4.000	100.000

Backtest

DATA DE ENTRENAMIENTO **319900** **30100** — No Fuga / Fuga

DATA DE TEST **137100** **12900** — No Fuga / Fuga







Partición train – test - validación

Creación de nuevas Features

Usualmente las variables que tenemos disponibles en nuestra base de datos no son suficientes para el desarrollo de nuestro modelo predictivo.

¿Podemos crear nuevas variables a partir de las variables iniciales?

Ejemplo:

- Promedio de saldo por mes en los últimos **x** meses.



¿Nuestro cliente recibe su sueldo en soles o dólares?

¿Nuestro cliente suele realizar compras con su tarjeta de crédito en soles o dólares?

¿Paga mensualmente algún crédito en dólares?

Transformaciones: *Logaritmos, exponenciación, radicación, normalización, estandarización…*

Procesamiento de Datos

Partición train – test - validación

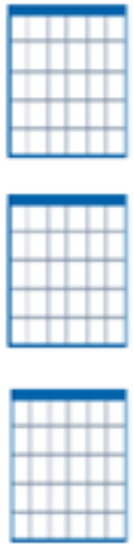
Creación de nuevas Features

Fuente de datos

Ejemplo



DataSetHR Analytics



Covariables

X1 = avg_training_score

X2 = length_of_service

X3 = previous_year_rating

Transformación de variables (Ingeniería de Variables)

$$x4 = \frac{linea_{t-1}}{Deuda_{máx}}$$ **Ratio**

$$x5 = \frac{deuda_{t-1} - deuda_{t-6}}{Deuda_{t-6}}$$ **Desviación**

$$x6 = \frac{x1^2, x1 * x2}{1}$$ **Iteraciones**

$$x7 = \frac{x1 - med(x1)}{Desv_{x1}}$$ **Transformaciones Lineales**

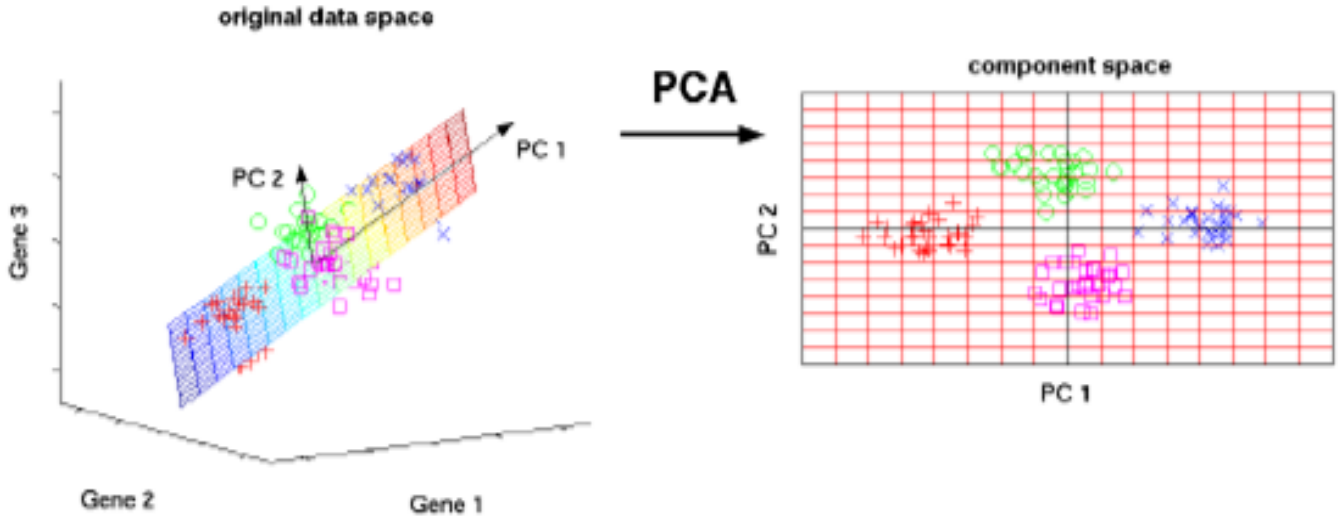
$$x8 = \log(x1)$$ **Transformaciones NO Lineales**



Procesamiento de Datos

Análisis de Componentes Principales (PCA)

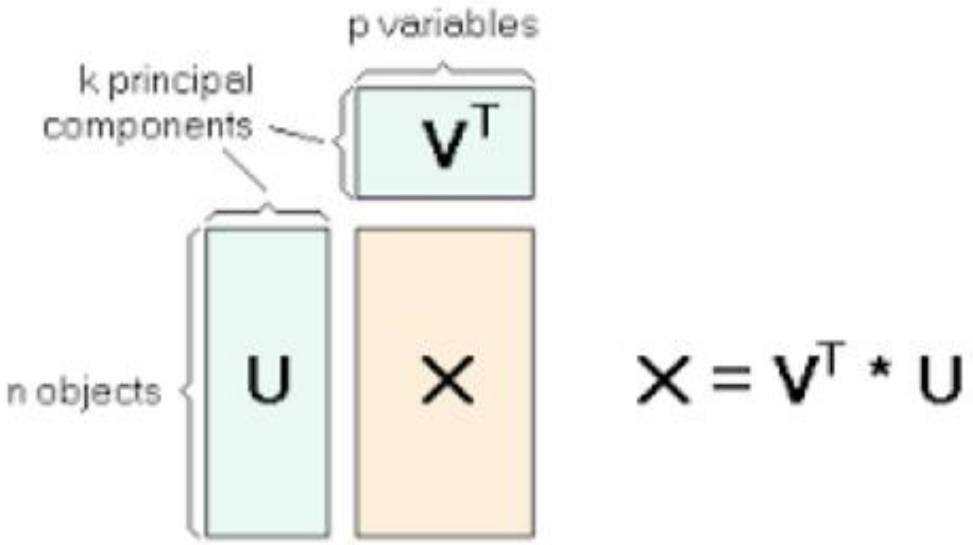
- En la construcción de métodos supervisados nos podemos encontrar con una gran cantidad de dimensiones, tanto en número de registros como en número de variables.
- La dimensionalidad de la información dificulta el procesamiento de algoritmos, nos quita interpretabilidad de la información y esconde relaciones existentes entre las variables.
- Una técnica que nos ayuda con lo antes descrito es el ANALISIS DE COMPONENTES PRINCIPALES como técnica de ingeniería de variables y de reducción de información.



Procesamiento de Datos

Análisis de Componentes Principales (PCA)

- Objetivo: Dada una matriz de datos de dimensiones *nxp* que representa los valores de ***p*** *variables en* ***n*** *individuos*, investigar si es posible representar los individuos mediante ***k*** variables ***(k<p)*** con poca (o ninguna) pérdida de información.



Procesamiento de Datos

Weight of Evidence (WoE)

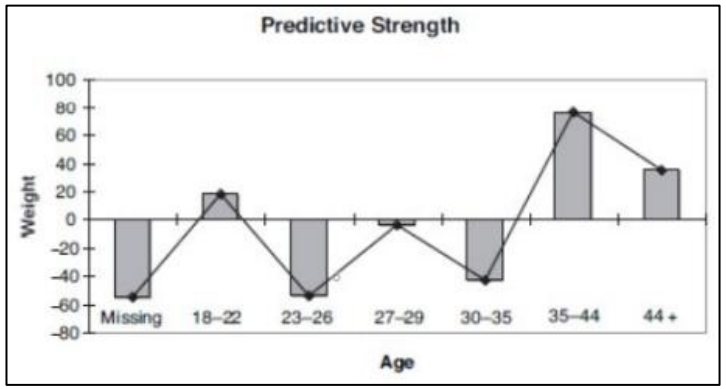
Es una técnica poderosa para realizar la transformación y selección de variables. Se usa ampliamente en el puntaje crediticio para medir la separación entre clientes buenos y malos (variables). Por lo tanto, está diseñado solamente para el modelo de regresión logística binaria.

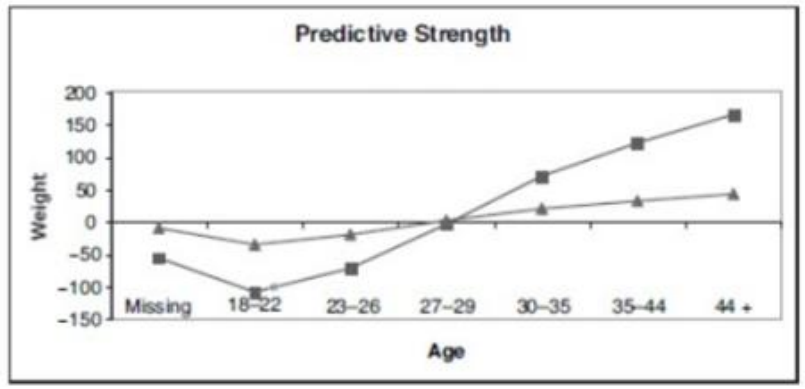
Ventajas

- ✓ Maneja los valores perdidos y los valores atípicos
- ✓ La transformación se basa en el valor logarítmico de distribución.
- ✓ Puede transformar una variable independiente para que establezca una relación monótona con la variable dependiente.

Desventajas

- ➢ Pérdida de información (variación) debido al agrupamiento en pocas categorías
- ➢ Es una medida "univariante" por lo que no tiene en cuenta la correlación entre variables independientes
- ➢ Es fácil manipular (sobreajustar) el efecto de las variables de acuerdo con cómo se crean las categorías.





Procesamiento de Datos

Weight of Evidence (WoE)

Creación de nuevas features: WOE

Range	Bins	Non events	Events	% of Non-Events	% of Events	WOE	IV
0-50	1	197	20	5%	6%	-0.0952	0.0005
51-100	2	450	34	12%	10%	0.2002	0.0045
101-150	3	492	39	13%	12%	0.1522	0.0029
151-200	4	597	51	16%	15%	0.0774	0.0009
201-250	5	609	54	17%	16%	0.0401	0.0003
251-300	6	582	55	16%	16%	-0.0236	0.0001
301-350	7	386	41	11%	12%	-0.1405	0.0022
351-400	8	165	23	5%	7%	-0.4123	0.0095
>401	9	184	21	5%	6%	-0.2123	0.0025
	Total	**3662**	**338**				**0.0234**

$$WoE = [ln(\frac{\text{Relative frequecy of Goods}}{\text{Relative frequecy of Bads}})] * 100$$

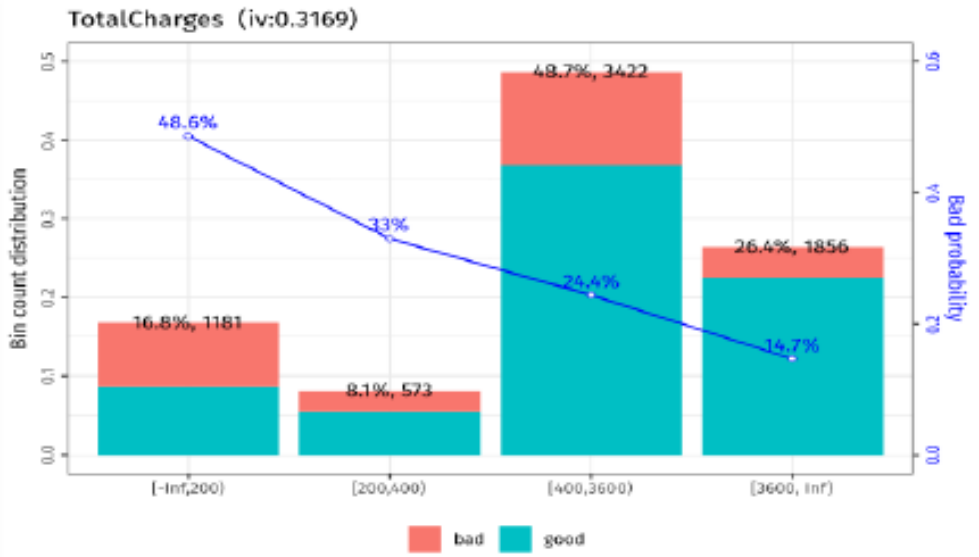
$$IV = \sum(DistributionGood_i - DistributionBad_i) * WoE_i$$

Procesamiento de Datos

Weight of Evidence (WoE)

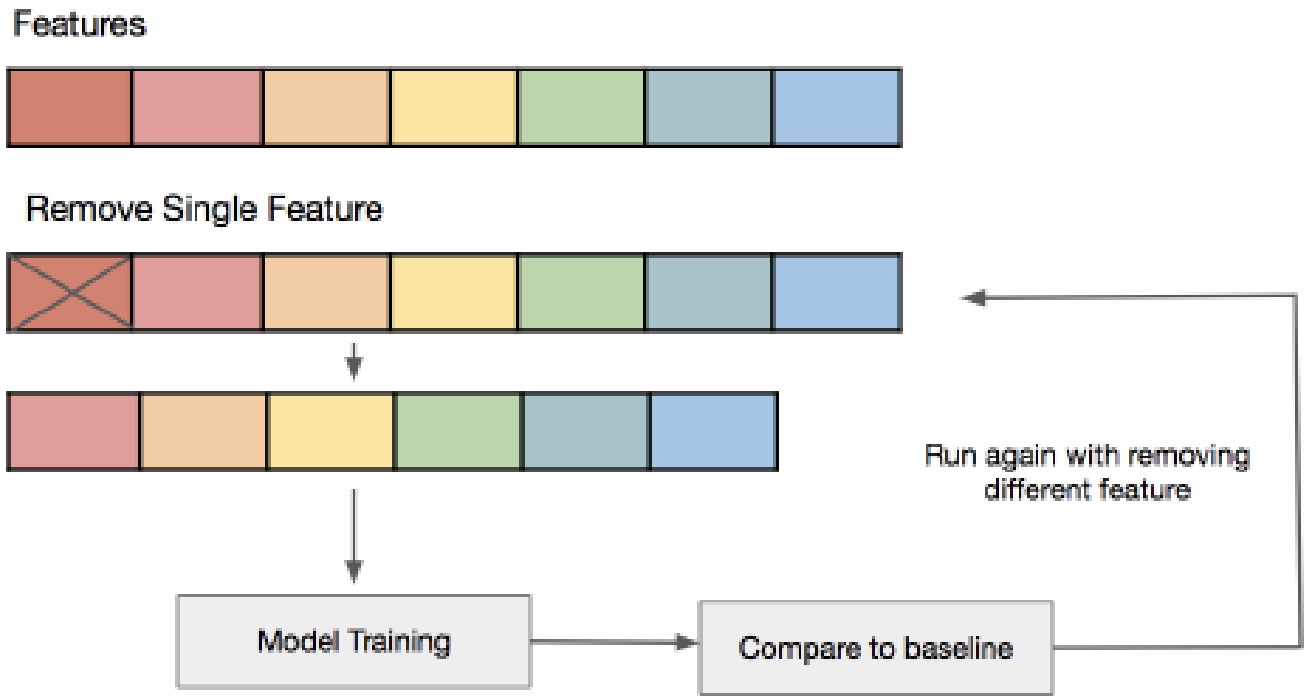
Creación de nuevas features: WOE

Variable o Feature	IV
previous_year_avg_score	62%
KPIs_met >80%	61%
avg_training_recod	45%
avg_score_2	35%
avg_training_score	35%
PCA_1	34%
previous_year_rating	24%
previous_year_rating_2	24%
awards_won?	24%
previous_year_length_serv	7%
length_service_avg_score	2%
education	1%
no_of_trainings	1%
gender	0%
department	0%
PCA_2	0%
age	0%
length_of_service	0%
length_of_service_2	0%
employee_id	0%
PCA_3	0%
region	0%
recruitment_channel	0%



Information Value (IV)	Predictive Power
< 0.02	useless for prediction
0.02 to 0.1	weak predictor
0.1 to 0.3	medium predictor
0.3 to 0.5	strong predictor
> 0.5	suspicious or too good to be true

Feature Selection



Feature Selection

- El número de V.I. o features en cantidades poco manejables es un problema con el que tenemos que lidiar, **dimensionalidad**.
- Necesitamos los modelos más simples con la máxima explicación, **parsimonia**.
- **"Garbage In , Garbage Out"**, no podemos ingresar variables que no aporten a la predicción.

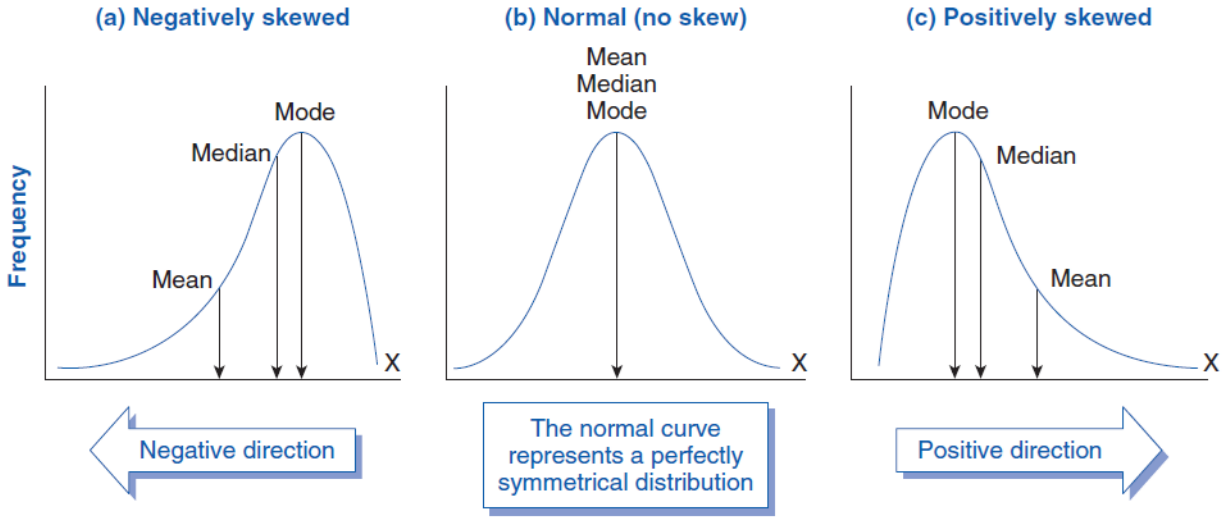


Procesamiento de Datos

Feature Selection

Análisis univariado

- De todas las variables que se ha generado ¿cuáles contienen información suficiente que representa la población?
- Debemos tener cuidado con aquellas variables que tengan un porcentaje muy alto de valores nulos o ceros.
- Debemos tener cuidado con aquellas variables que no presenten mayor varianza entre los distintos registros.



- Porcentajes de nulos, porcentajes de ceros
- **Medidas de centralidad:** media, mediana
- **Medidas de dispersión:** desviación estándar, coeficiente de variación.
- **Distribución:** percentiles, rango intercuartil

Feature Selection

Técnicas estadísticas

Coeficiente de Correlación de Pearson

$$r = \frac{\sum(x-\bar{x})(y-\bar{y})}{\sqrt{\sum(x-\bar{x})^2 \sum(y-\bar{y})^2}}$$

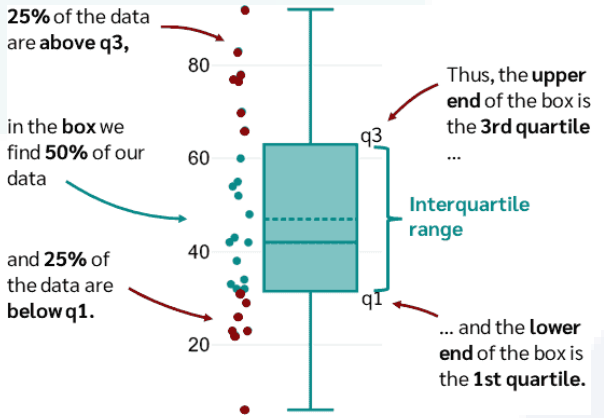
Coeficiente de Chi-2

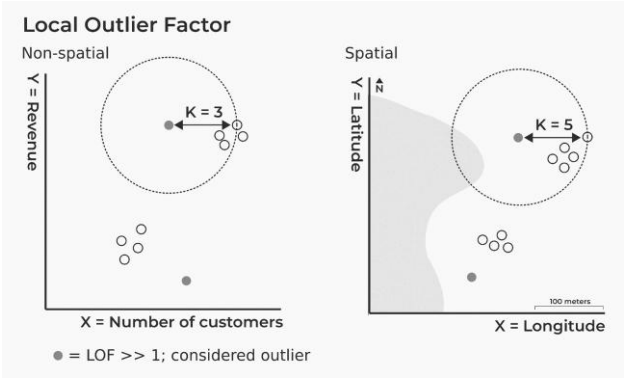
$$\chi_c^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

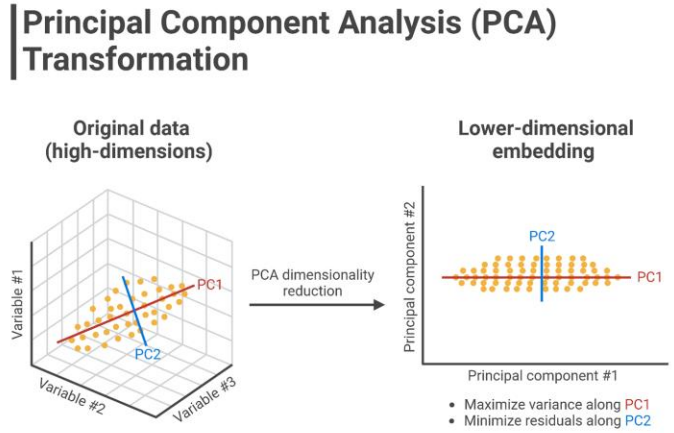
Feature engineering

Tratamiento de Datos

Tratamiento de Datos	Solución
Missing o Datos Nulos	**Imputación paramétrica** - Variables Cuantitativas: Mediana - Variables Cualitativas: Moda o Creiterio Experto **Imputación no paramétrica** - Imputación por K-NN y Random Forest
Tipos de Datos	Label Encoder - One Hot Encoder
Outliers o Valores Discordantes	ACP - Análisis de Componentes Principales Recodificación por árboles de Desición Estandarización de Variables Topear o Recorte por Percentiles







Feature engineering

Imputación de datos faltantes

- El método de imputación depende de la **naturaleza** de la variable.

Si hay valores nulos en la edad de clientes, ¿Qué valor debería imputar?
Si hay valores nulos en la cantidad de transacciones de un cliente, ¡Qué valor debería imputar?

	col1	col2	col3	col4	col5
0	2	5.0	3.0	6	NaN
1	9	NaN	9.0	0	7.0
2	19	17.0	NaN	9	NaN

mean()

	col1	col2	col3	col4	col5
0	2.0	5.0	3.0	6.0	7.0
1	9.0	11.0	9.0	0.0	7.0
2	19.0	17.0	6.0	9.0	7.0

Feature engineering

Imputación de datos faltantes

Variables numéricas

Media o mediana (cuidado con los valores extremos)

Variables categóricas

Moda

Otras técnicas

Utilizar valores promedios por grupos

Imputación por vecinos más cercanos

Games	Name	Sex	Height	Team	Sport
1984 Summer	Harri Hilmer Huhtala	M	187	Finland	Athletics
1912 Summer	Ladislav emla	M	NaN	Bohemia	Tennis
1972 Summer	Edvard Mikeyelyan	M	165	Soviet Union	Gymnastics
1980 Winter	Friedrich "Fritz" Fischer	M	181	West Germany	Biathlon
1992 Winter	Rachel Lynn Mayer (-Godino)	F	NaN	United States-2	Figure Skating
2008 Summer	Ioanna Samara	F	164	Greece	Rhythmic Gymnastics
1972 Summer	Paul Thijs	M	174	Belgium	Athletics
1988 Summer	Maria urinov	F	169	Czechoslovakia	Handball
2004 Summer	Corine Raux	F	164	France	Athletics
1972 Summer	Mara Teresa Ramrez Gmez	F	171	Mexico	Swimming

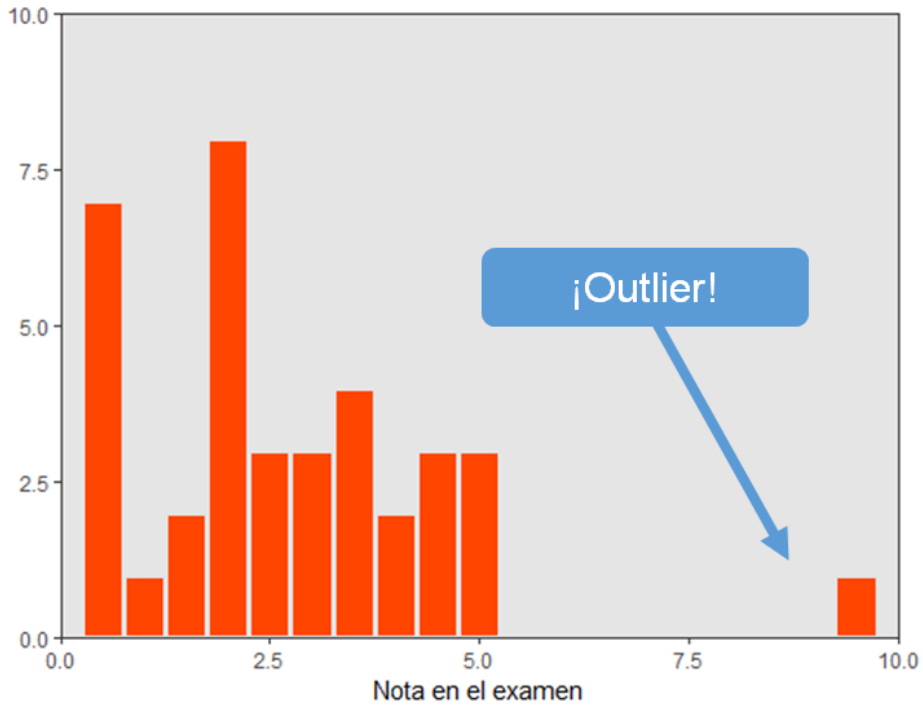
Feature engineering

Tratamiento de datos atípicos

Los valores atípicos pueden tener efectos negativos en el entrenamiento de modelos, principalmente aquellos que utilizan el cálculo de distancias para el aprendizaje

¿Cómo lidiar con valores extremos?

- **Eliminarlos:** se puede perder información
- **Marcarlos:** opción más segura
- **Reescalar:** reducir el efecto de los valores extremos



Feature engineering

Tratamiento de datos atípicos

Como identificar valores atípicos

Validación de valores correcto

- Validación de distribuciones con equipos de negocio
- Validación de que las variables tengan los rangos adecuados

y, ¿de forma automática?

- Observar los percentiles extremos:
  - Mínimos: 0, 2.5, 5, 10
  - Máximos: 90, 95, 97.5, 99, 100

	LoanAmount	LoanAmountTerm
count	592.000000	600.00000
mean	146.412162	342.00000
std	85.587325	65.12041
min	9.000000	12.00000
5%	56.000000	180.00000
10%	71.000000	294.00000
15%	84.650000	360.00000
20%	95.000000	360.00000
25%	100.000000	360.00000

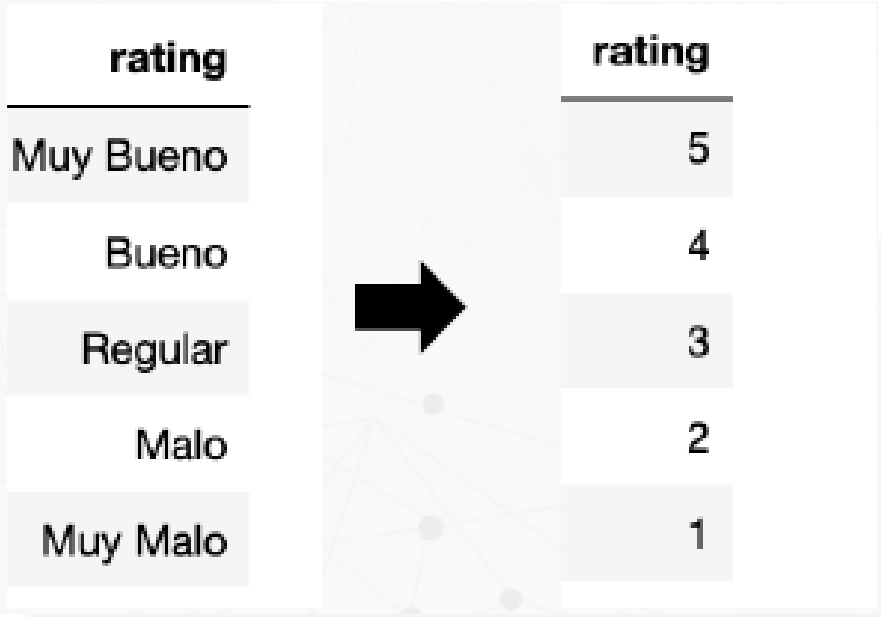
	ApplicantIncome	CoapplicantIncome
91%	9940.900000	3984.020000
92%	10397.240000	4230.560000
93%	11155.360000	4416.000000
94%	12110.000000	4596.100000
95%	14583.000000	4997.400000
96%	15364.320000	5397.040000
97%	16682.250000	5682.670000
98%	19666.040000	7198.560000
99%	32540.410000	8895.890000
max	81000.000000	41667.000000

Feature engineering
Labeling

Para convertir una variable categórica **ordinal** a numérica se utiliza **labeling.**

Este proceso se utiliza cuando existe una noción de distancia entre las categorías.

Se debe tener cuidado en que el orden de los números utilizado sea el mismo orden que representan las variables categóricas originales.



rating
Muy Bueno
Bueno
Regular
Malo
Muy Malo

rating
5
4
3
2
1

Feature engineering
One Hot Encoding

Cuando la variable categórica es **nominal**, se recomienda utilizar one-hot-encoding.

Label Encoding

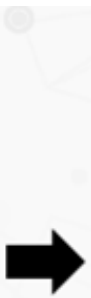
Food Name	Categorical #	Calories
Apple	1	95
Chicken	2	231
Broccoli	3	50

→

One Hot Encoding

Apple	Chicken	Broccoli	Calories
1	0	0	95
0	1	0	231
0	0	1	50

	department
0	Sales & Marketing
1	Operations
2	Sales & Marketing
3	Sales & Marketing
4	Technology
5	Analytics
6	Operations
7	Operations
8	Analytics
9	Sales & Marketing

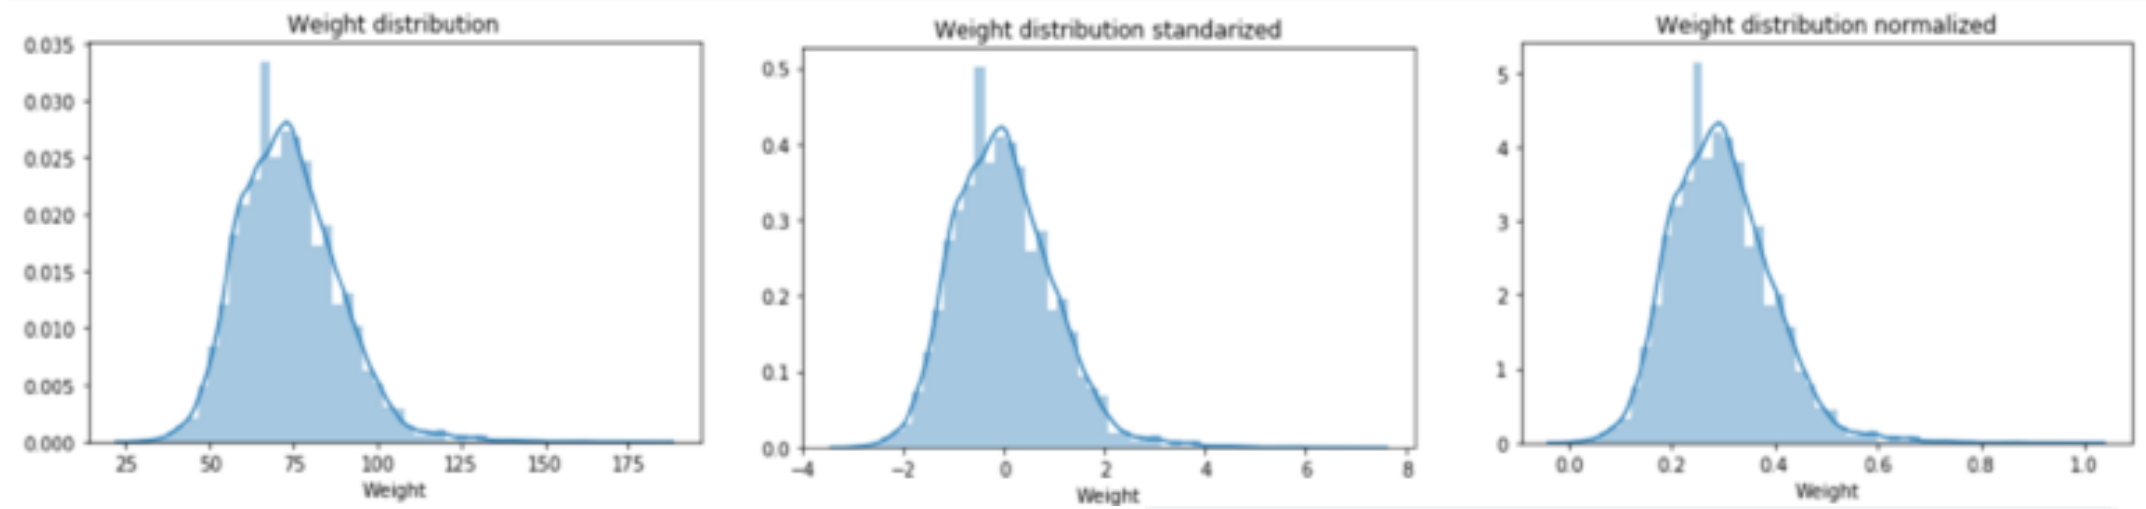


	department_Analytics	department_Operations	department_Sales & Marketing	department_Technology
0	0	0	1	0
1	0	1	0	0
2	0	0	1	0
3	0	0	1	0
4	0	0	0	1
5	1	0	0	0
6	0	1	0	0
7	0	1	0	0
8	1	0	0	0
9	0	0	1	0

Feature engineering

Escalamiento

Hace que las variables que ingresa al modelo se encuentran en la misma escala.
Se mantiene la distribución, pero con los valores transformados a una escala determinada



$$x_z = \frac{x - \mu}{\sigma}$$

$$x_n = \frac{x - min}{max - min}$$

Variable original x

Estandarización normal

Estandarización Min-Max

Feature engineering

Balanceo de Datos

Lidiando con Clases Desbalanceadas

- Se considera como **evento raro** cuando la categoría de interés de la variable Target tiene una frecuencia relativa de entre **0.1%** y **10%.**
- Este tipo de distribuciones dificulta la construcción de modelos, ya que la mayoría asume que es más probable que el evento de interés no ocurra.
- Lo anterior puede generar métricas de evaluación distorsionadas. Por ejemplo, un modelo con una proporción de target de **1%** en el que se clasifique a todos como **no-target**, tendrá un nivel de Accuracy de 99%.

Problema: La mayoría de las técnicas de machine learning van a ignorar y tener mala performance en la clase minoritaria cuando comúnmente esta es la clase de interés para el desarrollo del modelo.



Feature engineering

Balanceo de Datos

Lidiando con Clases Desbalanceadas

Los target raros o escasos se dan en diferentes situaciones como:

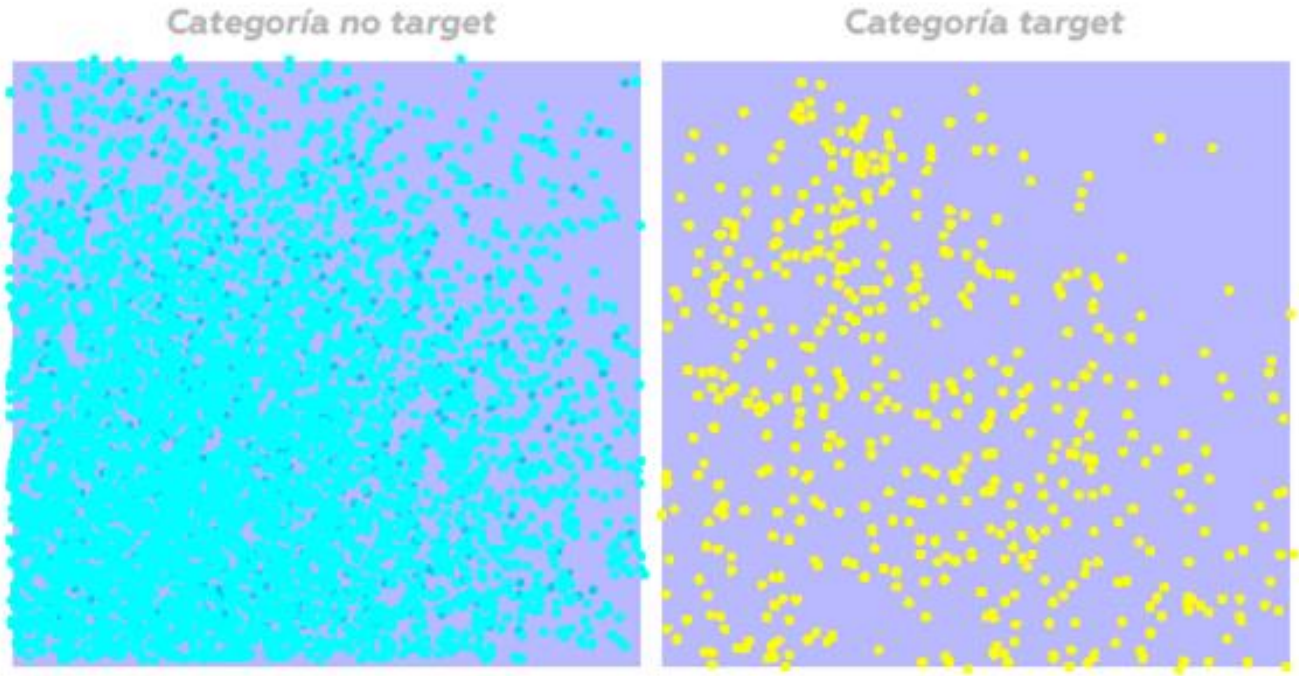
- **Cobro de pólizas de seguros:** La probabilidad de que un cliente tenga un incidente y cobre.
- **Modelos de venta de productos:** Para productos que no son muy masivos, los que son nuevos o los que se ofrecen en campaña Cross Sell y Up Sell.
- **Fuga de clientes:** La probabilidad de que un cliente abandone la empresa. En lagunas industrias la tasa de fuga es muy baja.
- **Detección de fallos en hardware.**
- **Identificación de comportamiento fraudulento:** Con el agregado que una vez que se desarrolla un modelo de fraude para alguna casuística, el fraude baja de incidencia y pueden aparecer otros.
- **Detección de intrusión de sistemas.**
- **Diagnósticos médicos:** Sobre todo para enfermedades con baja prevalencia.

Feature engineering

Balanceo de Datos

Muestreo de eventos raros

Una práctica habitual de modelización predictiva es construir modelos usando una muestra con una proporción del suceso primario diferente de la población de la población original



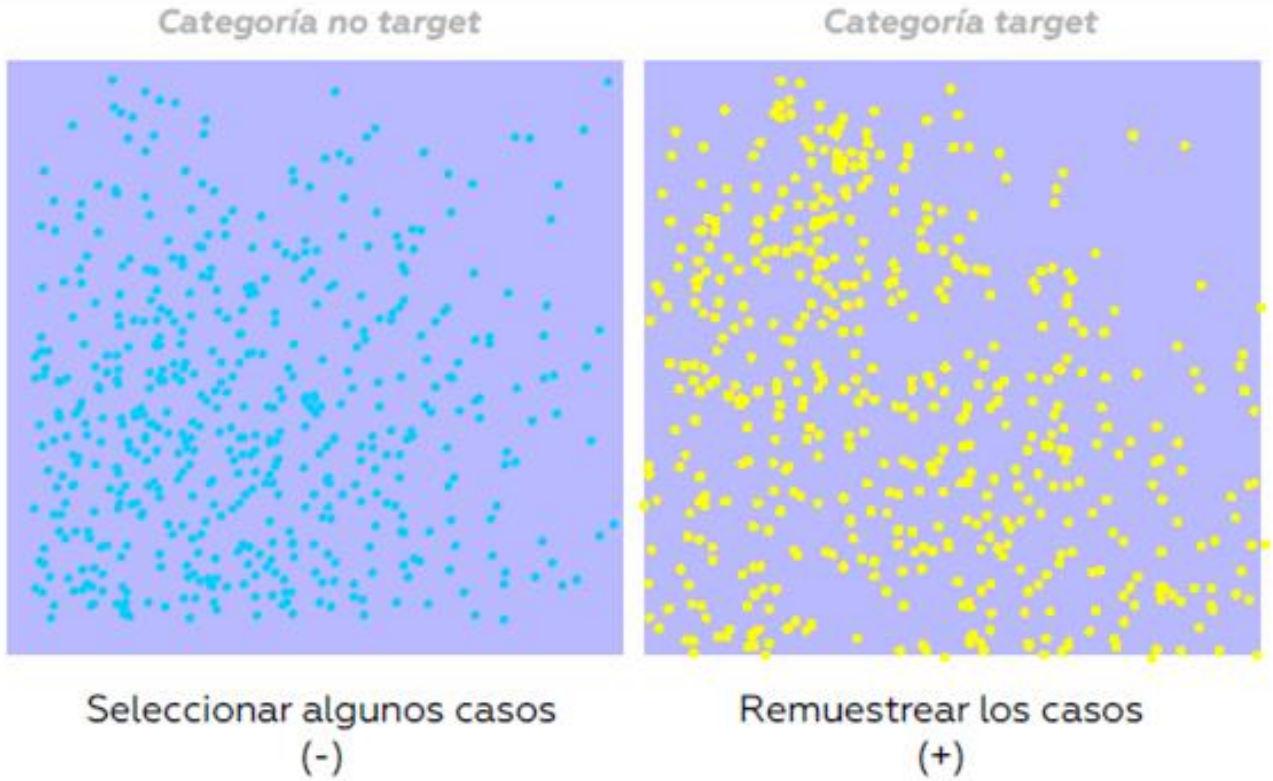
Se crean muestras considerando los casos target separados de los casos no target

Feature engineering

Balanceo de Datos

Muestreo de eventos raros

Una práctica habitual de modelización predictiva es construir modelos usando una muestra con una proporción del suceso primario diferente de la población de la población original



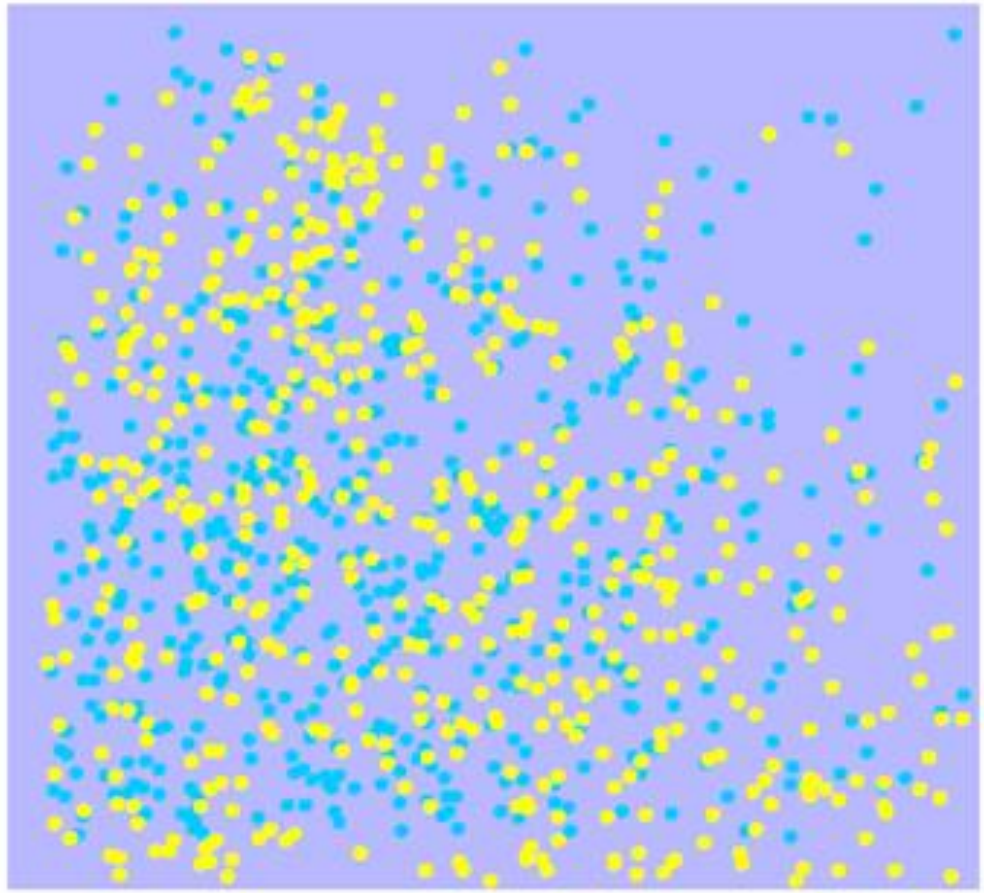
Feature engineering

Balanceo de Datos

Estrategias de Balanceo

Existen varias manera o metodologías para balancear o equilibrar las clases, cada una dependiendo de la proporción de elementos en cada una de las clases del tipo de problema que estamos abordando. Entre las más usadas tenemos:

- ❑ Undersampling
- ❑ Oversampling
- ❑ SMOTE



Feature engineering

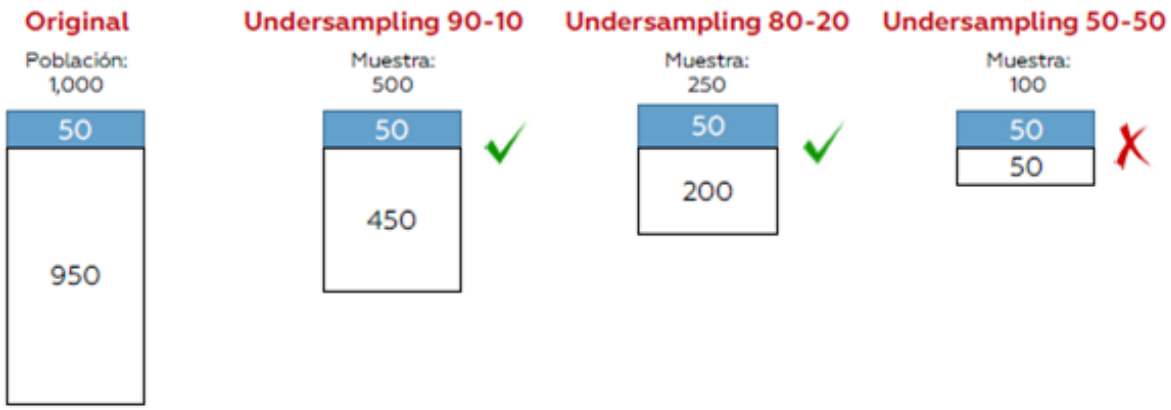
Balanceo de Datos

Undersampling

El proceso undersampling, consiste en seleccionar todas las observaciones **target** y un número menos de observaciones **no target**.

Una práctica común es seleccionar una misma cantidad, para quedar en una proporción 50/50 pero sólo se recomienda cuando la cantidad de las observaciones target es muy grande. En la mayoría de los casos, basta con reducir la proporción del *no target*.

Una **desventaja**, es que podrían eliminarse registros potencialmente importantes para el proceso de modelado o aprendizaje.

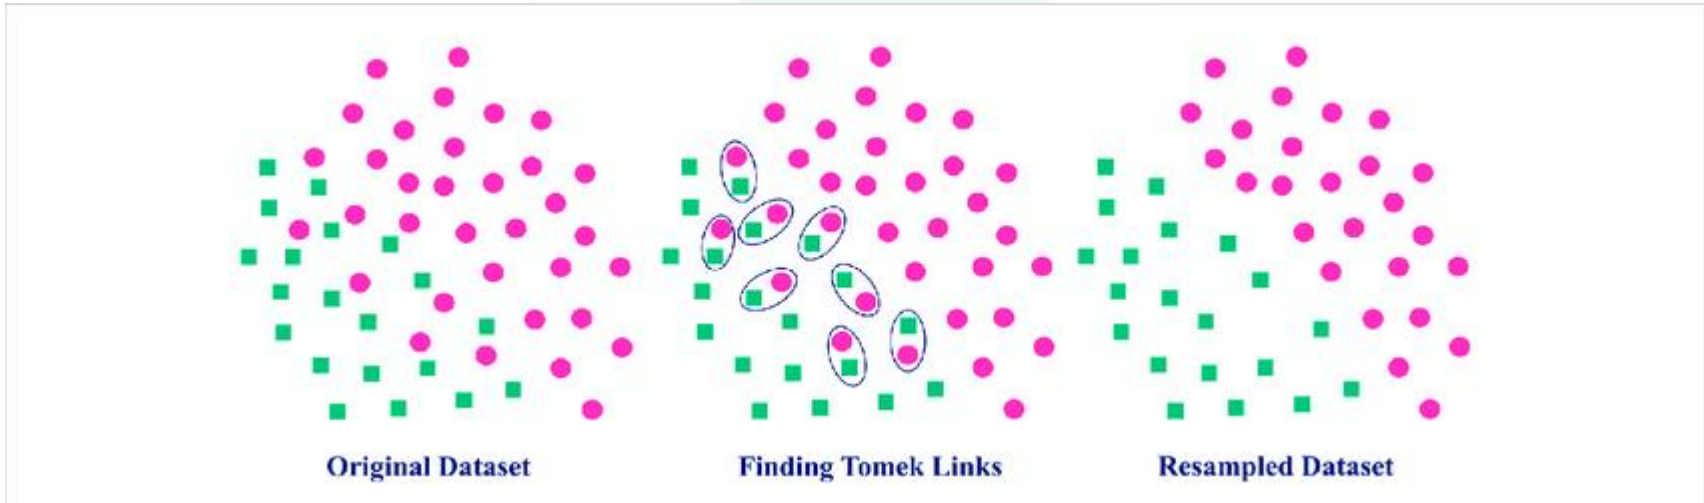


Feature engineering

Balanceo de Datos

Tomek Links

Elimina registros de la clase mayoritaria que se encuentren cerca a la frontera de decisión de las clases.

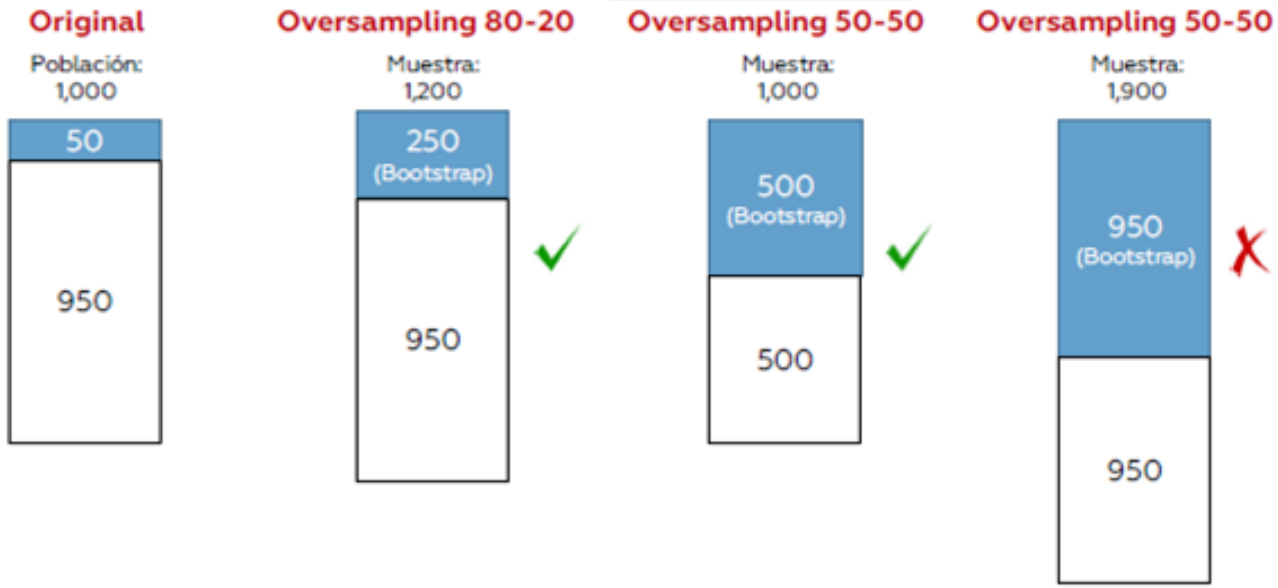


Feature engineering

Balanceo de Datos

Oversampling

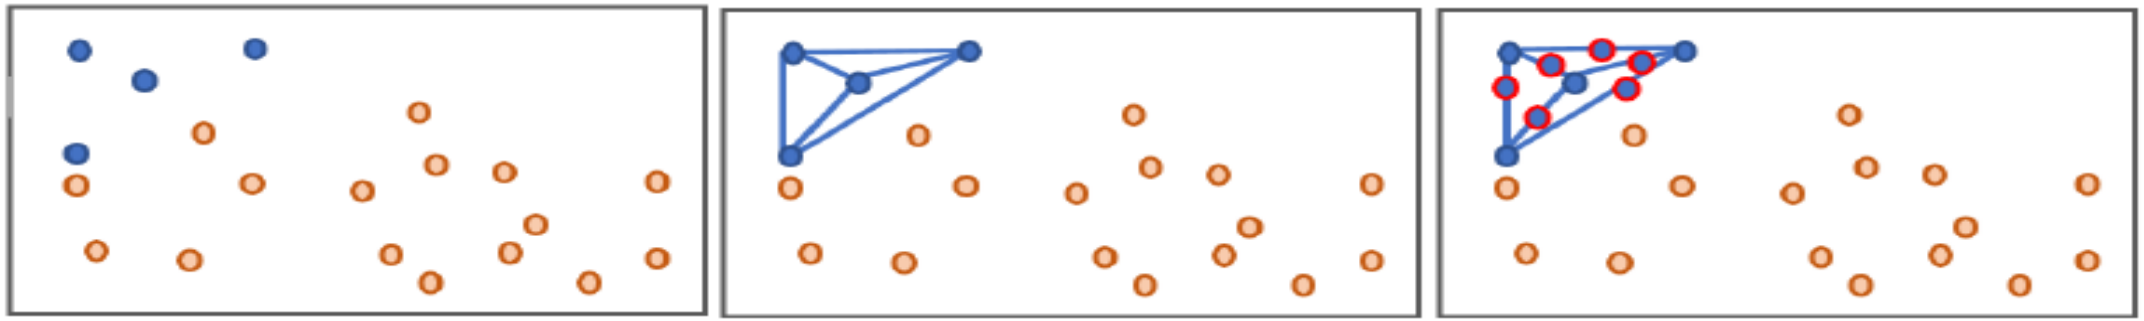
- EL proceso Oversampling, consiste en ampliar el número de observaciones *target* mediante remuestreo. Se duplican aleatoriamente los registros.
- **Desventaja:** Si son registros multiplicados muchas veces, el patron resulta forzado.



Balanceo de Datos

SMOTE

Selecciona una instancia de la clase minoritaria aleatoriamente y encuentra k vecinos cercanos de la misma clase. Los registros nuevos son creados eligiendo uno de los k vecinos y creando una combinación convexa entre ambos.



Feature engineering

Balanceo de Datos

SMOTE

Es una implementación de Oversampling, en el cual se generan nuevas observaciones *target* sintéticas del método KMM.

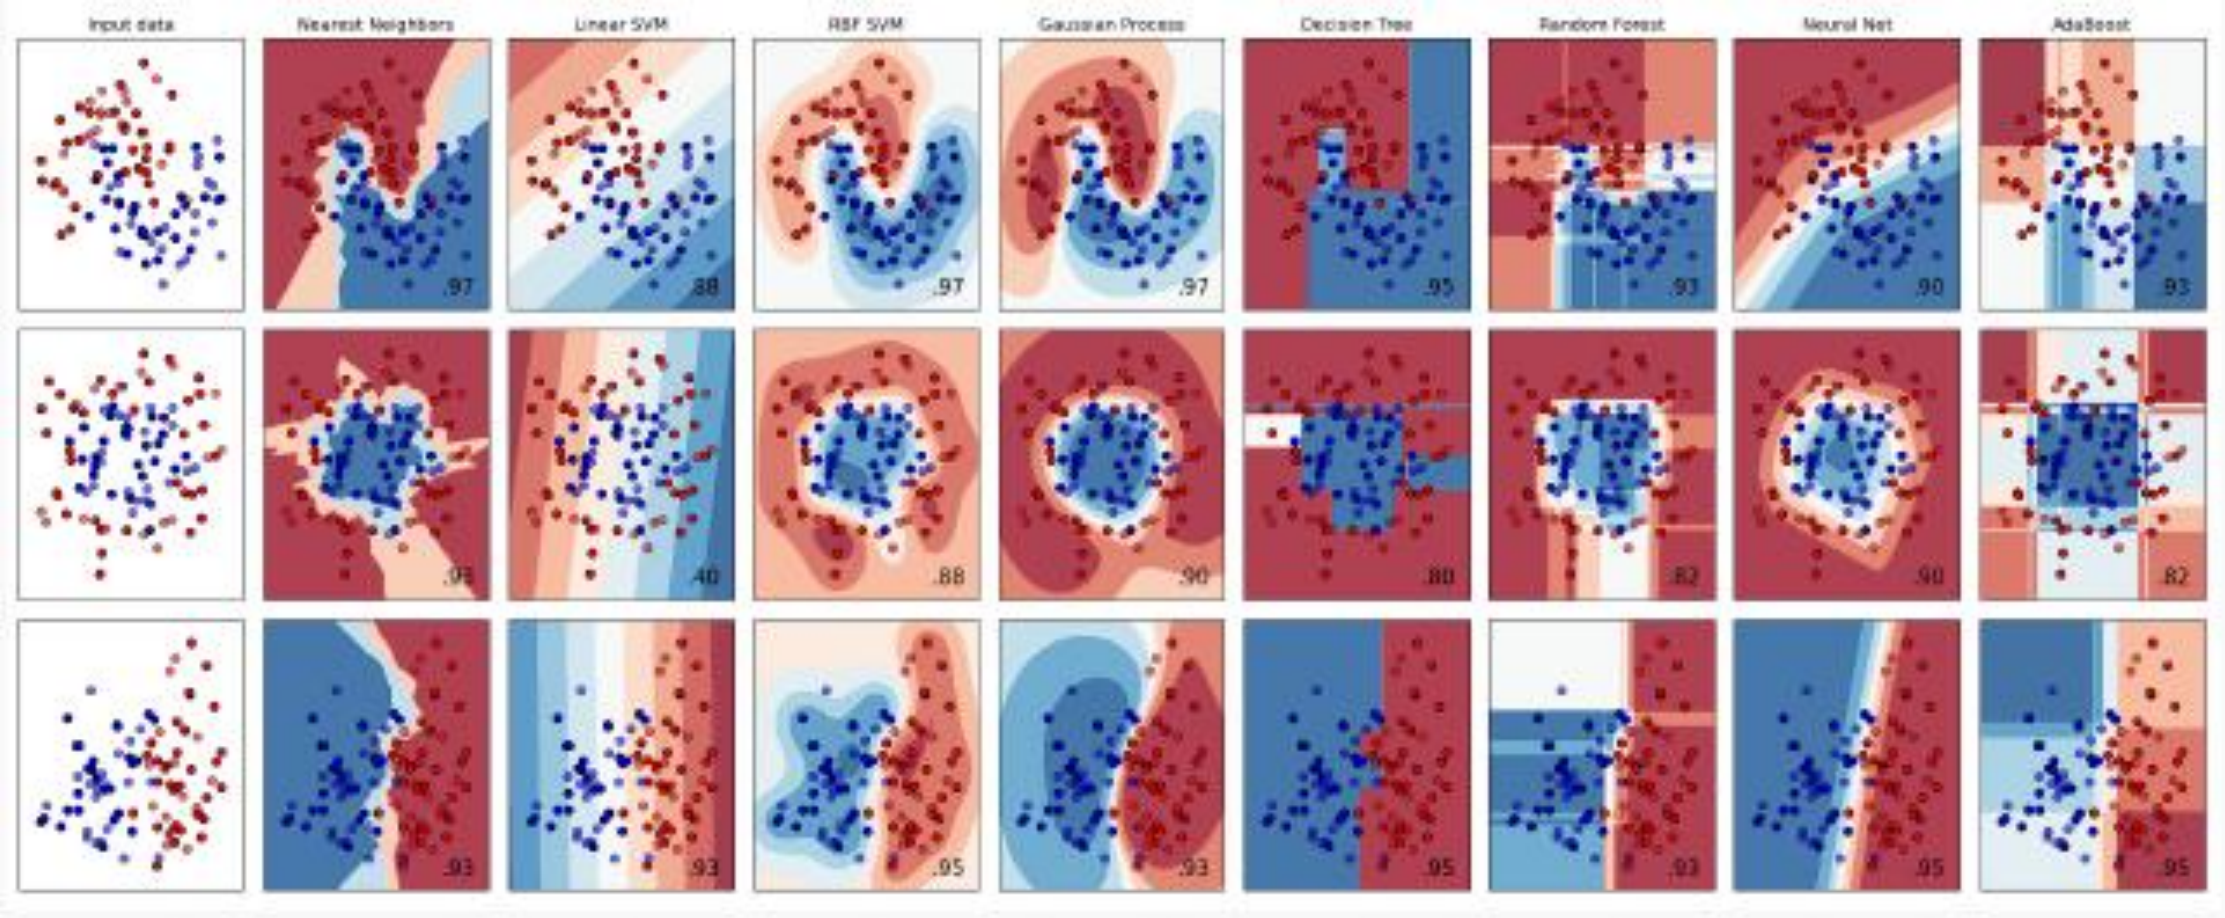
Desventaja: Para muestras muy grandes puede ser computacionalmente costoso. Adicionalmente, también podría agregar patrones espurios o no robustos.



Feature engineering

Balanceo de Datos

Entrenamiento



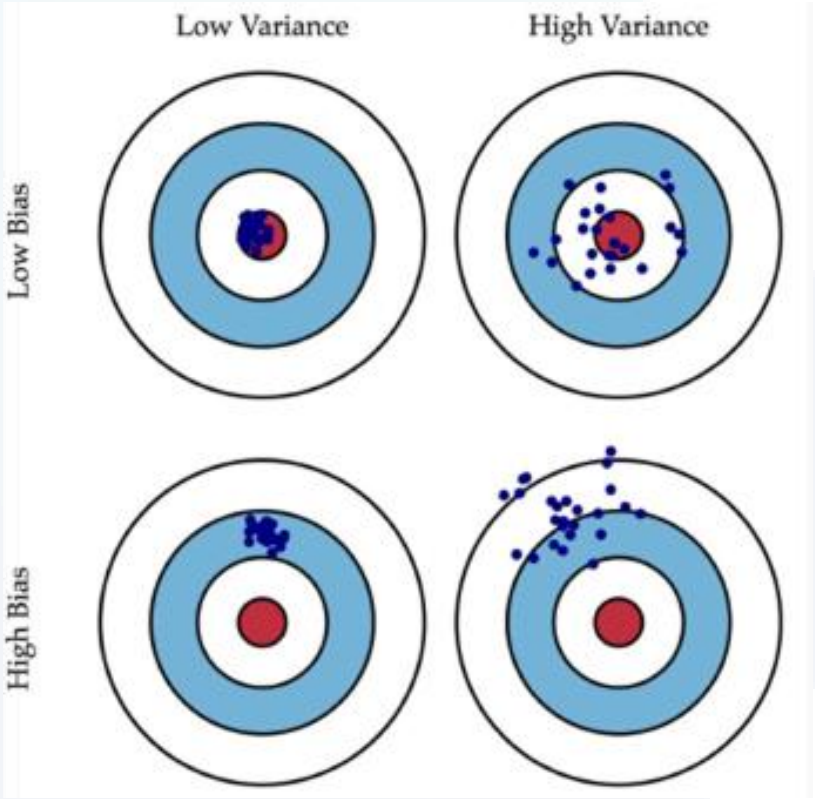
Feature engineering

Observaciones en el desarrollo del modelo

Un modelo predictivo intenta **estimar** la realidad. Debido a esto nunca va a ser 100% exacto.

El error obtenido proviene de tres fuentes:

1. **Bias:** Diferencia entre la predicción y el valor real.
2. **Varianza:** Error debido a la variabilidad de la predicción promedio del modelo.
3. **Error irreductible:** Ruido presente en la generación de muestras.

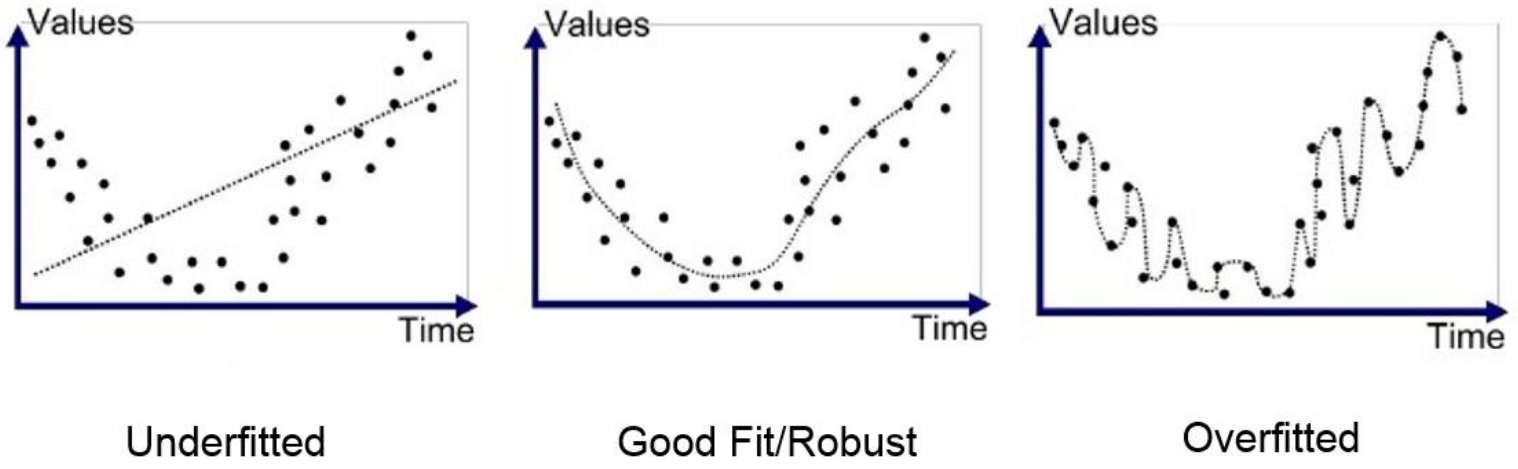


Feature engineering

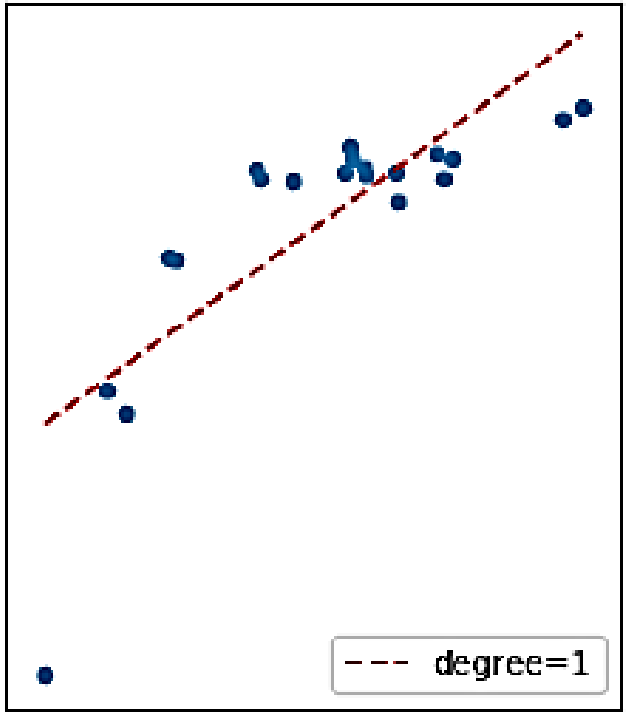
Overfitting and underfitting

Overfitting: Cuando un modelo se sobreajusta demasiado a los datos de entrenamiento no generaliza sus resultados adecuadamente.

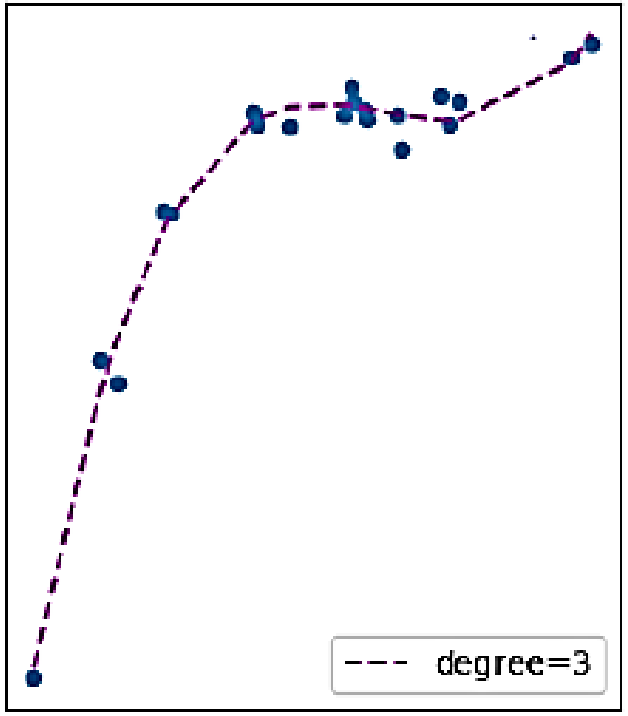
Underfitting: Cuando el modelo se ajusta muy ligeramente a los datos no se realiza una buena predicción.



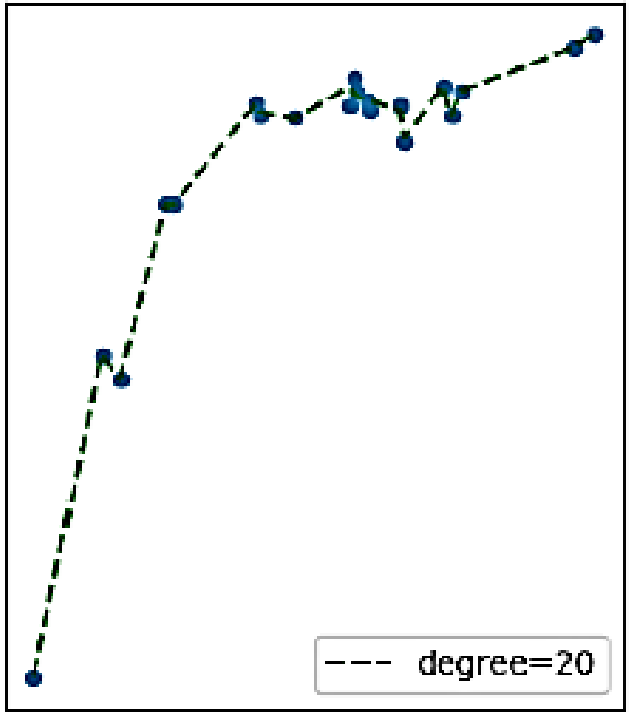
Overfitting and underfitting



Underfit
High Bias
Low Variance



Correct Fit
Low Bias
Low Variance

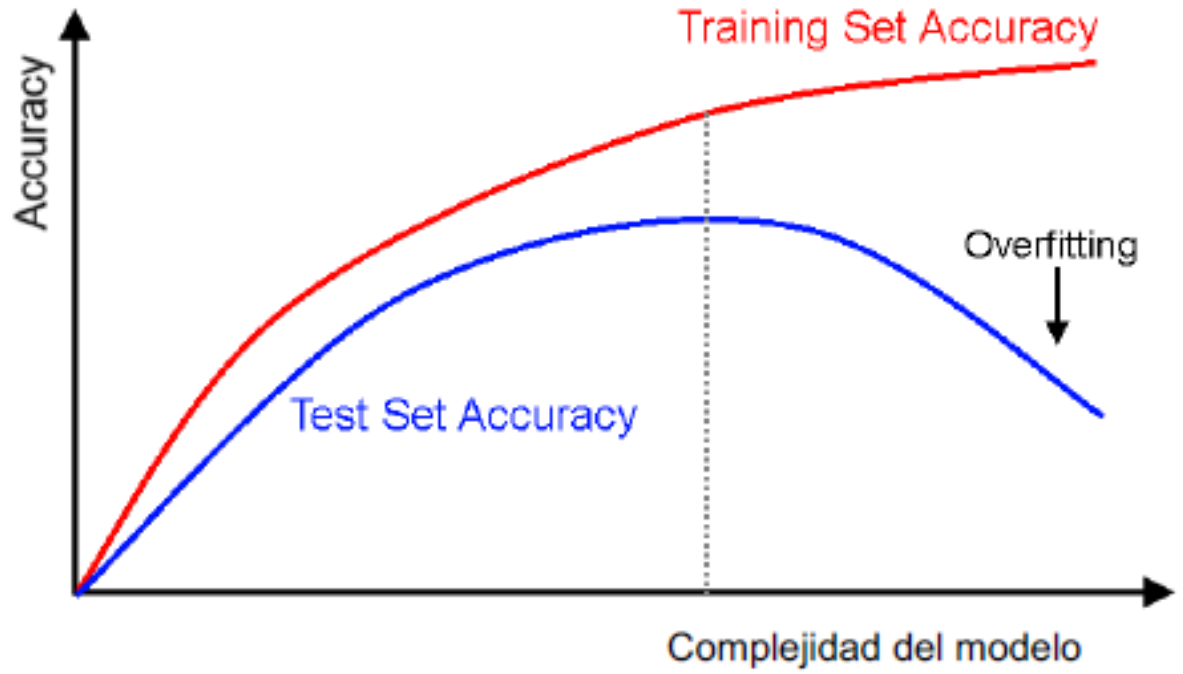


Overfit
Low Bias
High Variance

Feature engineering

Overfitting and underfitting

Para encontrar el equilibrio entre overfitting y underfitting es necesario observar los resultados en los conjuntos de train y test.

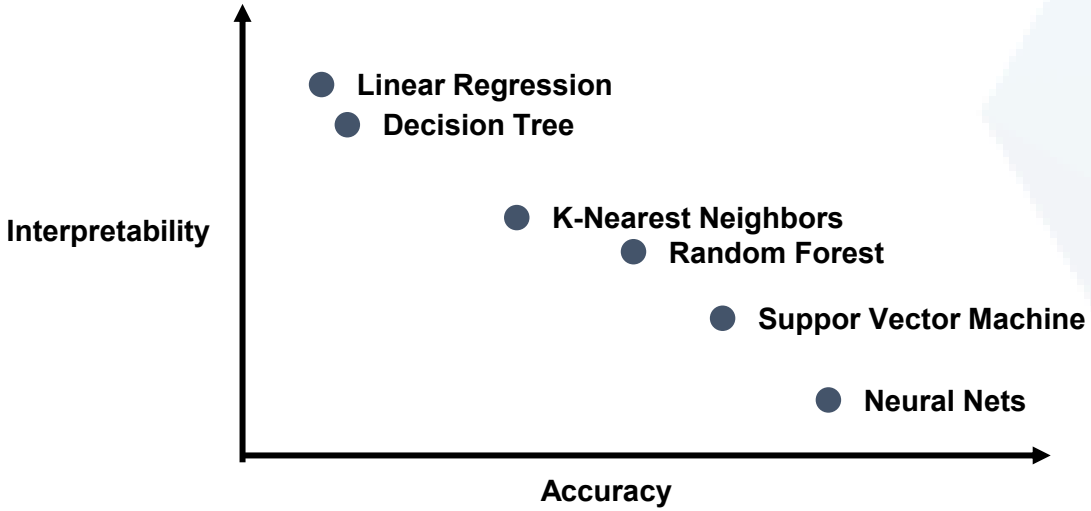


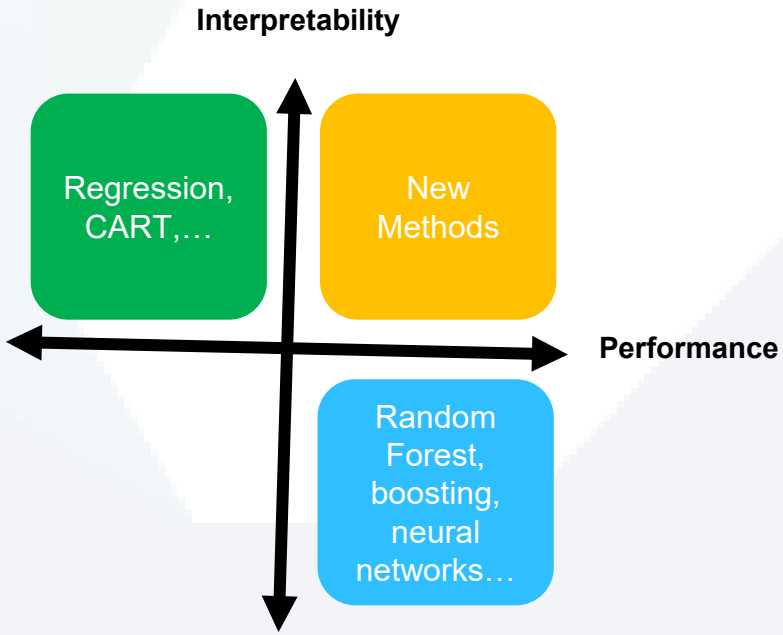
¿Cómo combatir el overfitting

- Utilizar modelos simples
- Utilizar conjuntos de pruena y validación
- Cross- validation
- Regularización
- Obtener una mayor muestra de datos
- Algoritmos ensamblados
- Detección temprana

Overfitting and underfitting

Complejidad vs Intrepretabilidad





ANALÍTICA AVANZADA

Gracias

Team

Futura Data &
Analítica Avanzada