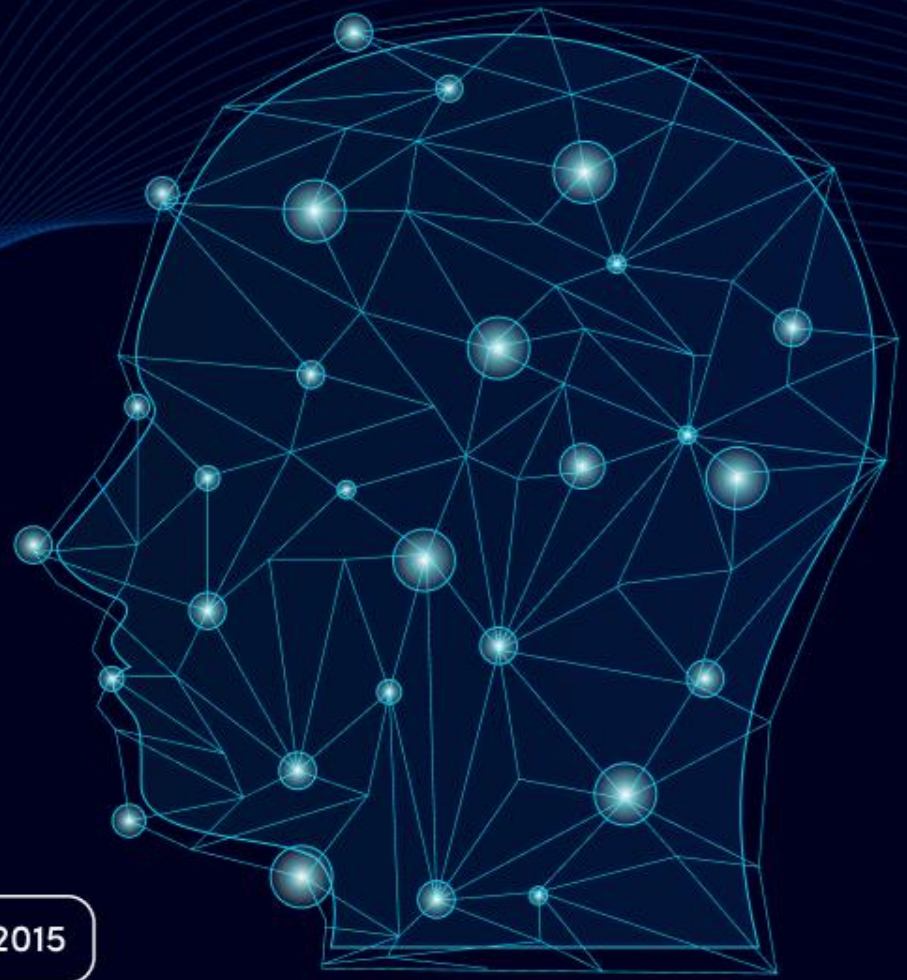
FUTURA
ANALITICA AVANZADA

PROGRAMA

Data Science for Business

Aprendizaje práctico y aplicado, con certificación ISO 9001 que garantiza calidad y excelencia



Mentores Top

Aprendizaje **100% aplicado**

Certificación **ISO 9001:2015**

FUTURA
ANALITICA AVANZADA

BIENVENIDOS

FUTURA

DATA Y ANALITICA AVANZADA

Nos comprometemos con ayudarte a **impulsar** tu carrera profesional y tu empresa.

+20
Empresas satisfechas

+10
Mentores expertos

PROGRAMA
Data Science For Business

Reglas



Por favor, al ingresar a la sala MEET, usa tu **nombre y apellido** al inicio para identificarte



Se **puntual** en cada sesión.



Para estar más concentrados, es recomendable **mantener el micrófono en silencio** durante la sesión.



Usaremos el **chat para las preguntas**. Si necesitas hablar, puedes encender el micrófono cuando sea necesario



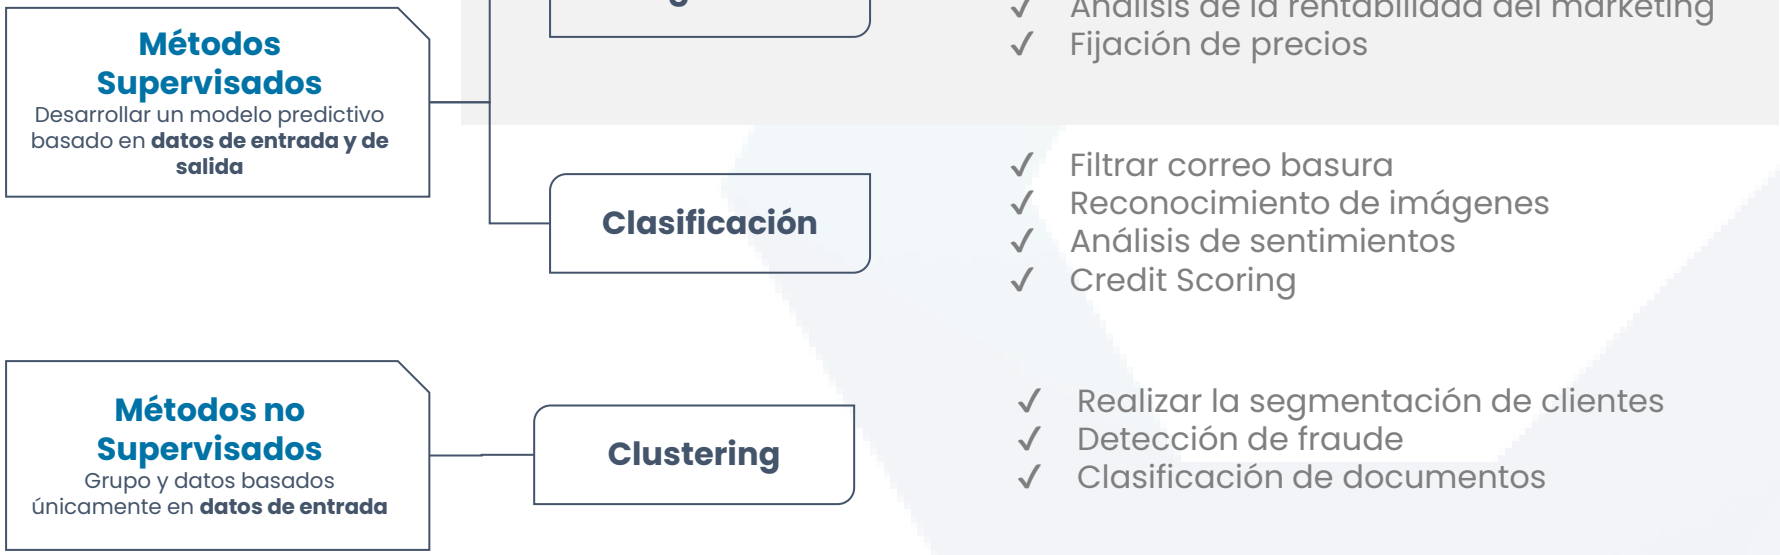
Completa las **tareas asignadas** a tiempo

Requisitos mínimo para obtener la certificación

Calificación

Asistencia	20%
Quiz de clase	30%
Trabajo Final Módulo	50%

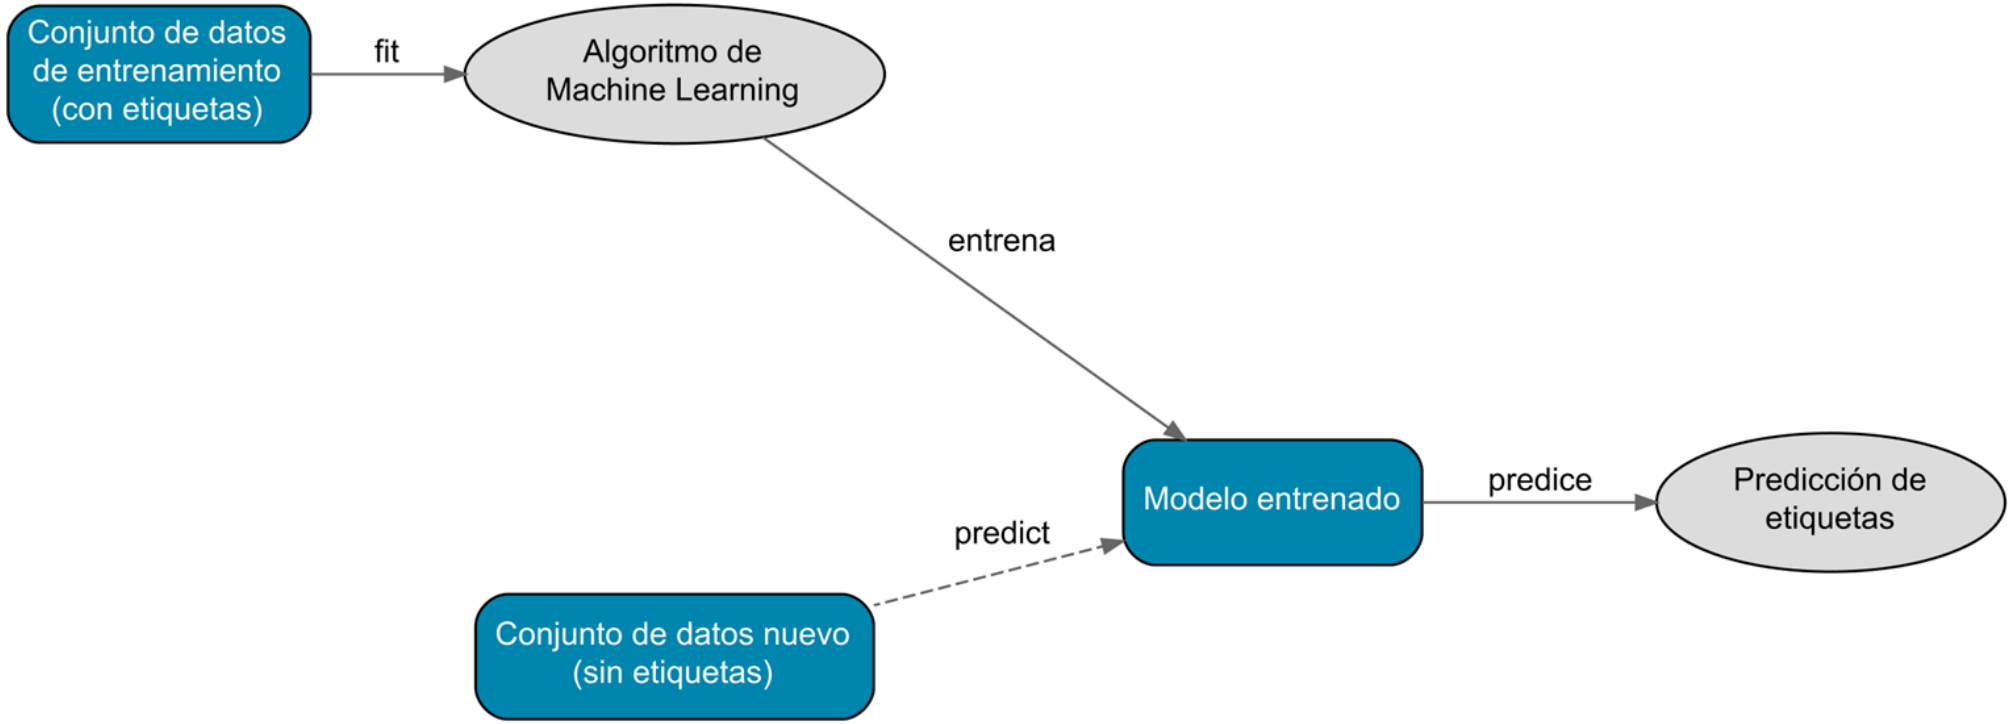
Mapa Aprendizaje



ANALÍTICA AVANZADA

Métodos Supervisados para Regresión_

Entendiendo los métodos Supervisados



Metodología de Desarrollo de algoritmos supervisados

1. Entendimiento del Problema

- Definición de Objetivos
- Identificación de Preguntas clave
- Comprensión de los requisitos de negocio
- Búsqueda de Stakeholders y definición de sus expectativas.

2. Análisis Exploratorio

- Evaluación de la calidad de los datos.
- Análisis descriptivo y estadístico.
- Visualización de datos para identificar patrones.
- Tratamiento de datos faltantes y outliers.
- Transformación y normalización de datos.
- Codificación de variables categóricas.

3. Balanceo de datos

- Técnicas de remuestreo.
- Uso de métricas apropiadas para datos desequilibrados.
- Análisis de impacto del desequilibrio en el modelo.

4. Selección de Variables

- Técnicas estadísticas para selección de variables.
- Métodos basados en Machine Learning para la selección de atributos.
- Importancia de características y eliminación de redundancias.

5. Modelamiento y entrenamiento

- Construcción de modelos predictivos.
- Evaluación de modelos utilizando cross-validation.
- Interpretación de resultados y coeficientes del modelo.
- Identificación de drivers clave y su influencia.

6. Validación Técnica

- Pruebas de rendimiento del modelo (precisión, recall, F1-score).
- Validación de resultados con stakeholders.
- Alineación de resultados del modelo con objetivos del negocio.

7. Implementación

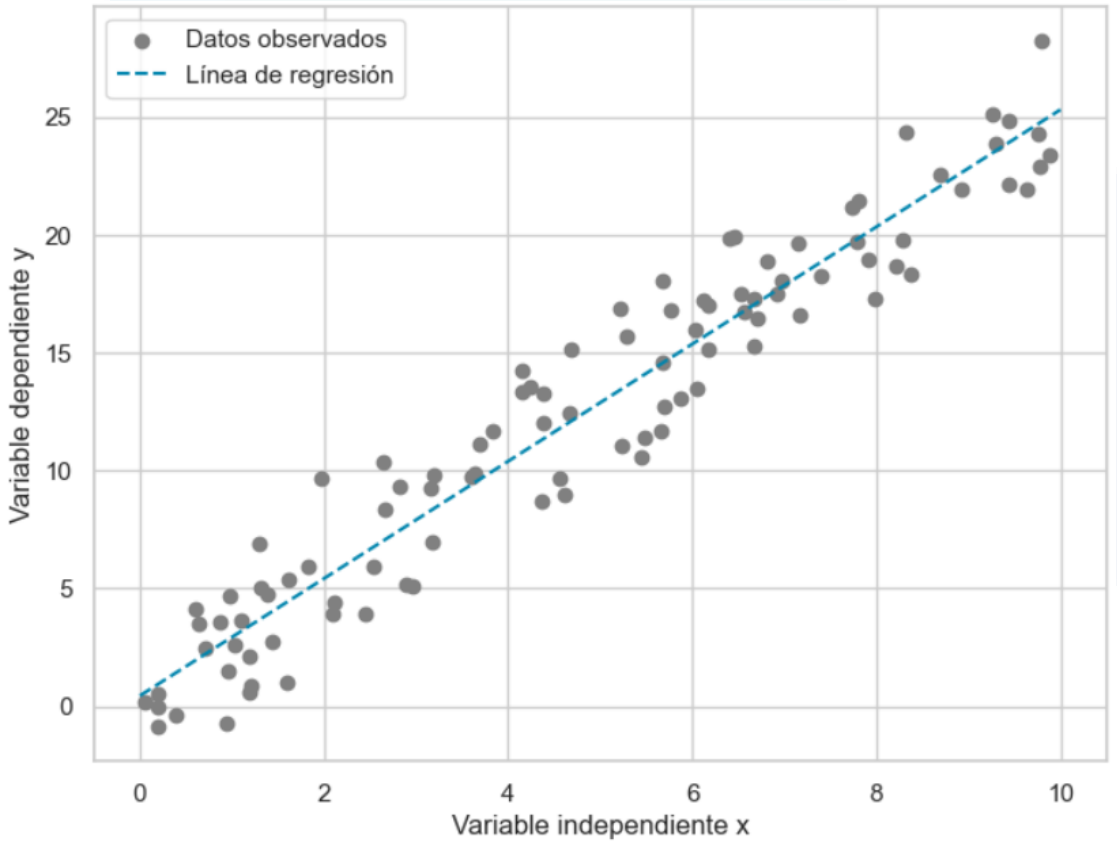
- Desarrollo de estrategias de implementación.
- Monitoreo y mantenimiento del modelo.
- Planes para la actualización y recalibración periódica del modelo

Aprendizaje Supervisado: Regresión

En un modelo de regresión, nuestro objetivo es predecir una **variable dependiente continua**.

La visualización muestra cómo, a partir de una variable independiente *x*, se intenta estimar la variable dependiente *y.*

La línea de mejor ajuste, representando el modelo, se determina mediante la **minimización del error cuadrático** entre los valores reales y las predicciones del modelo, ofreciendo así una predicción óptima dentro del contexto de los datos observados



Aprendizaje Supervisado: Términos

Cantidad de **muestras**

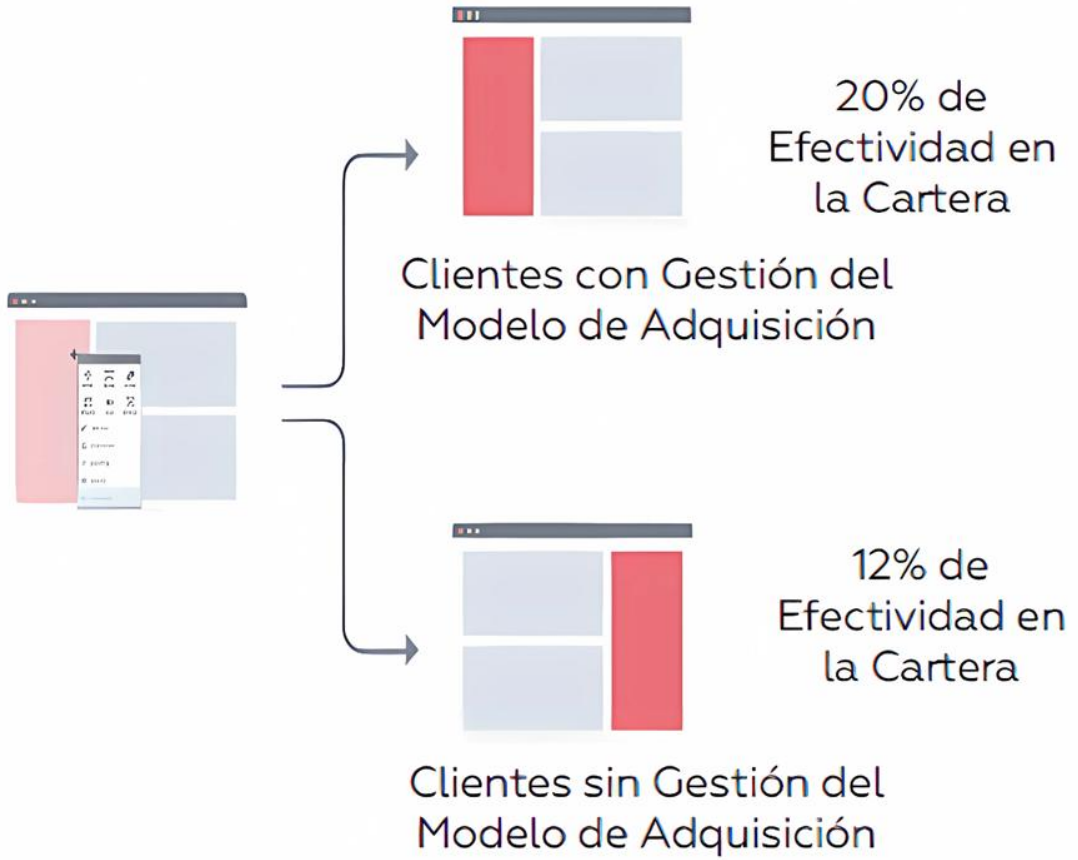
Sueldo	Antiguedad en el Sistema financiero	Edad	Capacidad de endeudamiento	Pagó el prestamo
				Sí
				Sí
				Sí
				No
				No

Características
(Features, atributos, dimensiones**)**

Etiqueda
(Label / **Target)**

Validación técnica y de negocio mediante un piloto





Implementación de una solución analítica supervisada

Probabilidad	N° Clientes	N° Sucesos VD	% Sucesos VD/ N° Clientes
0,9	10 000	100	36%
0,8	10 000	60	22%
0,7	10 000	40	14%
0,6	10 000	33	12%
0,5	10 000	20	7%
0,4	10 000	10	4%
0,3	10 000	5	2%
0,2	10 000	5	2%
0,1	10 000	3	1%
0	10 000	3	1%
Total	100 000	279	100%



GRUPOS DE EJECUCIÓN	N° CLIENTES	% SUCESOS ACUMULADOS	EFECTIVIDAD	LIFT
RECOMENDADO	**30 000**	**200**	**0,67%**	**2,39**
MEDIO	30 000	63	**0,21%**	0,75
BAJO	40 000	16	**0,04%**	0,14
TOTAL	**100 000**	**279**	**0,28%**	

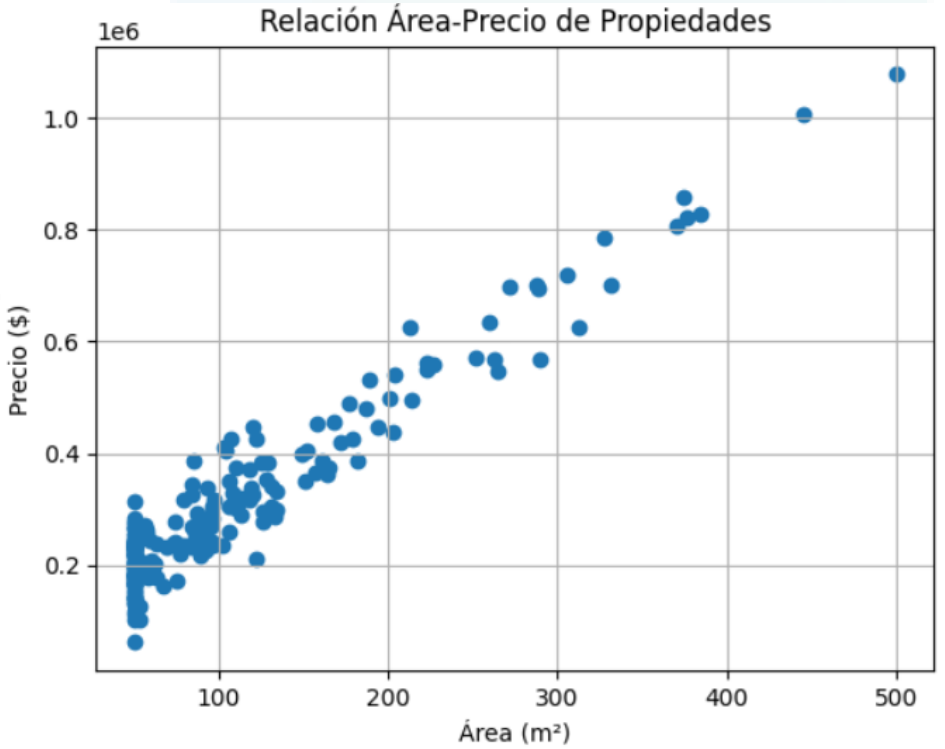
ANALÍTICA AVANZADA

Regresión Lineal Simple y Múltiple_

Regresión Lineal: Empecemos con un ejemplo

Imaginemos que tenemos una base de datos con precios de casas

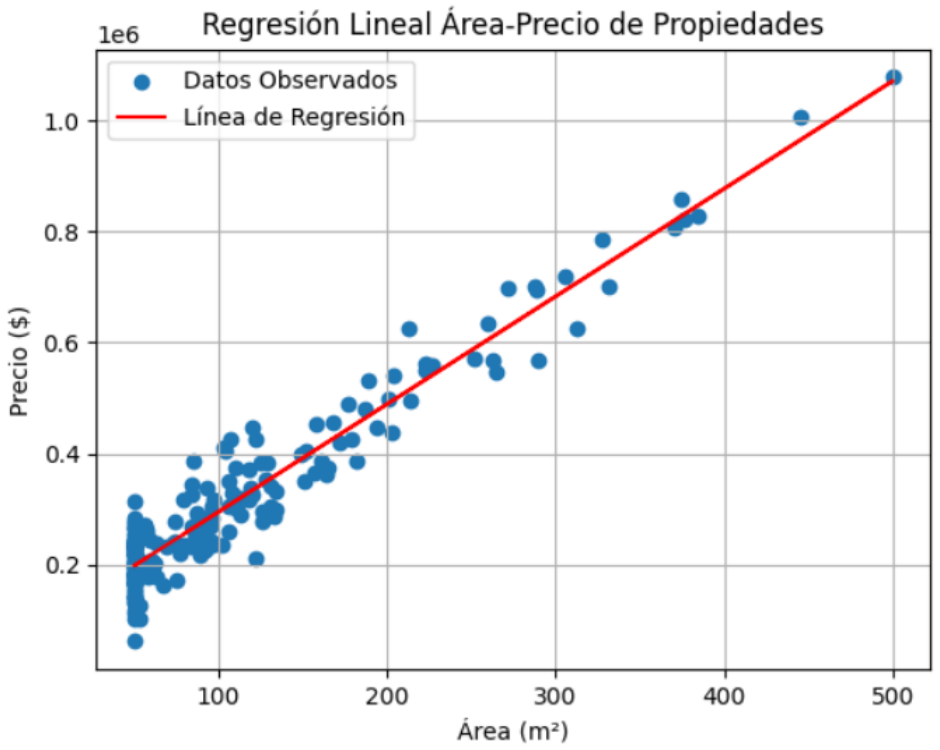
Área	Precio
132.3	319,000
141.5	389,000
71.2	199,000
277.4	599,000
338.7	750,000
330.5	810,000
422.9	890,000
367.6	895,000
251.3	429,000



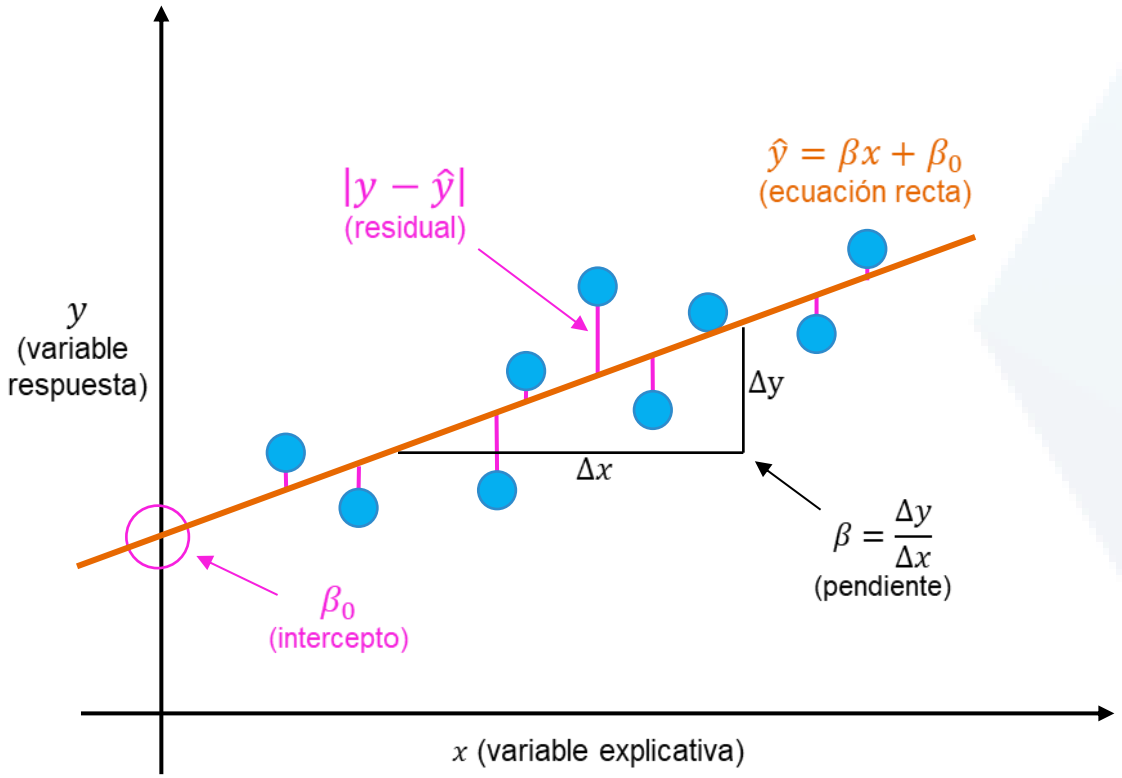
Cuál sería el precio de una casa de $150m^2$

Regresión Lineal Simple

- Es un método de aprendizaje Supervisado
- Es un método de regresión porque estimamos un valor numérico real
- Se predice la variable de respuesta con una variable explicativa



Regresión Lineal Simple



Eligiendo la mejor recta

$$J(\boldsymbol{\beta}) = \frac{1}{2}\sum_{1}^{n}(\hat{\boldsymbol{y}} - \boldsymbol{y})^2$$

$$\hat{\boldsymbol{y}} = \boldsymbol{\beta x} + \boldsymbol{\beta_0}$$

y: valor real

Utilizando un algoritmo de optimización, se eligen los **mejores betas** para minimizar la función de costo.

Regresión Lineal Simple: Interpretación del modelo

$$\widehat{Y} = 600 + 300x$$

- $b = 300$ → Cambio en Y por cada unidad de cambio en x. Por cada año de experiencia laboral, el sueldo mensual aumenta $300\ USD$.
- $a = 600$ → Valor medio de Y cuando $x = 0$. Sueldo medio de aquellas personas sin experiencia laboral.

  Una persona con 3 años de experiencia laboral, ¿qué sueldo mensual tendrá?

  $$X = 3 \Rightarrow \hat{Y} = 600 + 300 * 3 = 1{,}500$$
- $\widehat{Y} = 1500$ → Valor promedio previsto para todos los sujetos que han obtenido en la variable x un valor de x_i. Las personas con 3 años de experiencia tienen un sueldo promedio de $1{,}500\ USD$

Si una persona con 3 años de experiencia laboral tiene un sueldo mensual de $1{,}700\ USD$, ¿cuál será su error asociado?

$$e = Y - \hat{Y} = 1{,}700 - 1{,}500 = 200$$

- El modelo estimó un sueldo de $1{,}500\ USD$ para una persona con 3 años de experiencia laboral. Si esta persona concreta tiene un sueldo de $1{,}700\ USD$, esta diferencia de $200\ USD$ es el error; aquello que el modelo no explica

Estimación por mínimos cuadrados ordinarios

Para modelos lineales podemos derivar respecto a los parámetros (por ello computamos el error cuadrático), igual a cero y despejar, sin embargo, para modelos más complicados será necesario recurrir a un proceso de optimización (por ejemplo *gradient descent*)

$$S(\{\beta = \beta_0, \beta_1\}) = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} [y_i - \beta_0 - \beta_1 x_i]^2$$

- **Estimando el intercepto β_0:**

$$\frac{\partial S(\beta)}{\partial \beta_0} = -2 \sum_{i=1}^{n} [y_i - \beta_0 - \beta_1 x_i] = 0$$

$$\Rightarrow -2 \sum_{i=1}^{n} y_i - 2n\hat{\beta}_0 + 2\hat{\beta}_1 \sum_{i=1}^{n} x_i = 0$$

$$n\hat{\beta}_0 = \sum_{i=1}^{n} y_i - \hat{\beta}_1 \sum_{i=1}^{n} x_i$$

$$\Rightarrow \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- **Estimando el intercepto β_1:**

$$\frac{\partial S(\beta)}{\partial \beta_1} = -2 \sum_{i=1}^{n} [y_i - \beta_0 - \beta_1 x_i] \times x_i = 0$$

$$\Rightarrow -2 \sum_{i=1}^{n} x_i y_i - 2\hat{\beta}_0 \sum_{i=1}^{n} x_i + 2\hat{\beta}_1 \sum_{i=1}^{n} x_i^2 = 0$$

$$-n\overline{xy} + n(\bar{y} - \hat{\beta}_1 \bar{x})\bar{x} + n\hat{\beta}_1 \overline{x^2} = 0$$

$$-\overline{xy} + \bar{x}\bar{y} - \hat{\beta}_1 \bar{x}^2 + \hat{\beta}_1 \overline{x^2} = 0$$

$$\hat{\beta}_1 (\overline{x^2} - \bar{x}^2) = \overline{xy} - \bar{x}\bar{y}$$

$$\Rightarrow \hat{\beta}_1 = \frac{\overline{xy} - \bar{x}\bar{y}}{\overline{x^2} - \bar{x}^2} = \frac{S_{xy}}{S_{xx}}$$

Estimación por máxima verosimilitud

Objetivo

Estimamos los parámetros de un modelo de regresión lineal bajo las siguientes condiciones:

- Las variables X_1, X_2, X_3, X_n son no aleatorias.
- Los **errores** ε_i son variables aleatorias independientes con media cero y varianza σ^2 constante. (es decir, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$).
- Los errores ε_i y ε_j $(i \neq j)$ son independientes entre si. Es decir, $Cov(\varepsilon_1, \varepsilon_2) = 0$

Por lo tanto, la función de probabilidad condicional de Y para cada x viene dada por la distribución normal:

$$p(y|X = x; \beta_0, \beta_1, \sigma^2)$$

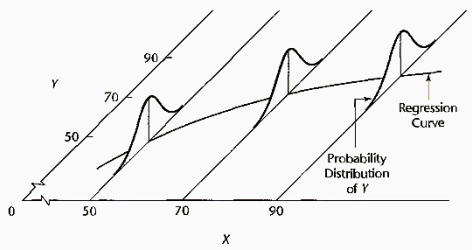
Para un conjunto de observaciones $\{(x_1, y_1), (x_2, y_2), (x_3, y_3), \dots (x_n, y_n)\}$, la función de verosimilitud del modelo se expresa como:

$$\prod_{i=1}^{n} p(y|X = x; \beta_0, \beta_1, \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(y - X\beta)^t (y - X\beta)} = L(\varepsilon; \beta, \sigma^2)$$

Supuestos equivalentes

Otra forma de cumplir los supuestos es dirigiendo no a los errores sino a la **variable** y_i siguientes condiciones:

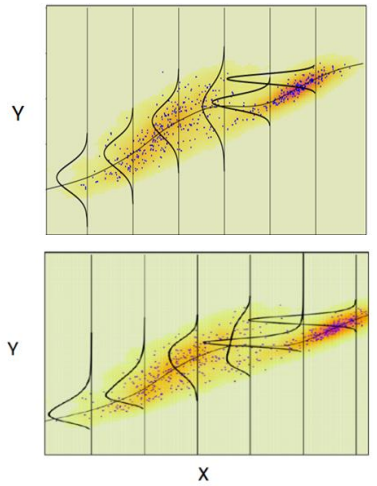
- La variable respuesta y tiene distribución normal
- La varianza de la respuesta y es constante
- Las observaciones son independientes
- Relación lineal entre la variable respuesta y las covariables.



La figura muestra con claridad el supuesto de normalidad de la variable Y, la dependencia de la media μ con X y la varianza constante

La figura muestra dos ilustraciones donde los supuestos no se cumplen.

- En la gráfica de arriba se observa que la *varianza de las distribuciones no es constante*
- En la gráfica de abajo la *distribución no es la normal.*



Estimación por máxima verosimilitud

Método de Estimación

Utilizamos la función de verosimilitud de la distribución normal de errores para estimar los parámetros del modelo $L(\varepsilon; \beta, \sigma^2)$. La maximización de la log-verosimilitud, que es computacionalmente más eficiente que trabajar directamente con la verosimilitud, se describe como:

$$\ln L(\beta, \sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2}(y - X\beta)^t(y - X\beta)$$

Resolviendo las ecuaciones de primer orden (derivadas de la log-verosimilitud con respecto a β y σ^2):

$$\frac{\partial \ln L}{\partial \beta} = -\frac{1}{2\sigma^2}(-2X^t y + 2X^t X\beta) = 0 \ldots (1)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{1}{2\sigma^2} + \frac{1}{2\sigma^4}(y - X\beta)^t(y - X\beta) = 0 \ldots (2)$$

Donde obtenermos los estimadores de máxima verosimilitud:

$$\hat{\beta} = (X^t X)^{-1} X^t y \qquad \hat{\sigma}^2 = \frac{\sum_1^n \left(y_i - X\hat{\beta}\right)^2}{n}$$

Este método proporciona una solución analítica para los estimadores de los coeficientes del modelo de regresión lineal, asumiendo normalidad en los errores.

Regresión Lineal

Componentes de la variación

Para definir **constantes** y para poder indicar a otros programadores que un determinado valor debe ser tratado como una **constante** es necesario utilizar la convención de que su nombre ha de ir en **mayúsculas**.

$$\sum_{i=1}^{N}(Y-\bar{Y})^2=\sum_{i=1}^{N}(\hat{Y}-\bar{Y})^2+\sum_{i=1}^{N}(Y-\hat{Y})^2$$

- Suma de cuadrados **total** = Suma de Cuadrados **Explicada** + Suma de Cuadrados **No Explicada**
- Variación Total = **Variación Explicada** + Variación **No Explicada**

Variabilidad explicada por la regresión

Variabilidad debida al error

$$SS_T = SS_R + SS_{Res}$$

Contraste de significación global (ANOVA)

Prueba F para la significancia del modelo (general)

Muestra si hay una relación lineal entre todas las variables x (consideradas en forma conjunta) e y. Usa el estadístico de prueba F.

Hipótesis:

$\boldsymbol{H_o}: \boldsymbol{\beta_1 = \beta_2 = \beta_3 = \cdots = \beta_n}$ $(No\ hay\ relación\ lineal)$

$\boldsymbol{H_A}: \boldsymbol{Al\ menos\ un\ \beta_i \neq 0}$ $(Existe\ relación\ lineal\ entre\ (y) y\ al\ menos\ un\ x_i)$

A partir de la información muestral se puede calcular el numerador y denominador del estadístico F_0

Fuente de variación	Suma de cuadrados	Grados de libertad	Cuadrado medio	Fo	Valor-P
Regresión	SS_R	k	$MS_R = \frac{SS_R}{k}$	MS_R/MS_{Res}	
Residual	SS_{Res}	$n-k-1$	$MS_{Res} = \frac{SS_{Res}}{n-k-1}$		
Total	SS_T	$n-1$			

$$SS_T = \sum y_i^2 - \frac{(\sum y_i)^2}{n}$$

$$SS_R = \hat{\beta}^T X^T y - \frac{(\sum y_i)^2}{n}$$

$$SS_{Res} = SS_T - SS_R$$

The statistic follows $F_0 \sim F_{k,n-k-1}$

Regresión Lineal Simple

Contraste de Significación global (ANOVA)

La tabla Anova es el estándar estadístico para resumir las principales características de un modelo de regresión

Fuente	SS	DF	MS
Modelo	1591.9902	1	1591.9902
Residuales	851.469256	72	11.8259619
Total	2443.45946	73	33.4720474

Suma de residuales al cuadrado

Número de Obs	74	
F(1,72)	134.62	Significancia global
Prob > F	0.0000	
R-2	0.6515	
R-2 Ajustado	0.6467	R^2 y R^2 – ajustado
Root MSE	3.4389	

VAR	Coef	Err. Sta.	t	P>|t|	[95% Inter. de conf.]		
X_	-.0060087	.0005179	-11.60	0.000	-.0070411	-.0049763	Intervalo de confianza
_cons	39.44028	1.614003	24.44	0.000	36.22283	42.65774	

Coeficiente beta

Significancia individual (estadístico t)

P-value

Regresión Lineal Simple

Métricas de evaluación para la regresión lineal

Coeficiente de determinación

Esta medida nos indica la proporción de variabilidad que explica el modelo lineal

$$R^2 = \frac{Variabilidad\ Explicada}{Variabilidad\ total}$$
$$= \frac{SS_R}{SS_T} = 1 - \frac{SS_{RES}}{SS_T}$$

Coeficiente de determinación Ajustado

Cada vez que añado una variable al modelo, aunque no ajuste nada, me reduce los grados de libertad, con lo que aumenta el ajuste. Por ello es mejor corregir dicho coeficiente con los grados de libertad.

Un modelo con tantas variables dependientes como datos ajustaría perfectamente, aunque las variables independientes no tengan nada que ver.

$$\bar{R}^2 = 1 - \frac{\frac{SS_R}{n-k-1}}{\frac{SS_T}{n-1}}$$

Propiedades de R^2

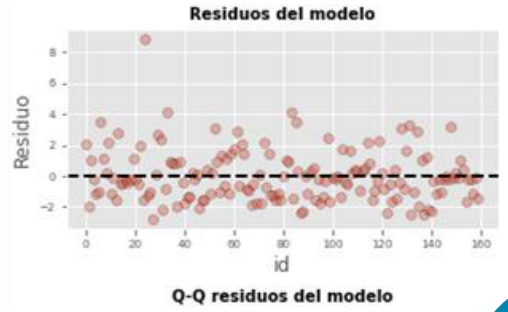
- R^2 toma valores entre 0 y 1
- Conforme R^2 se vaya aproximando a 1, significa que el modelo lineal explica major la situación
- Conforme R^2 se vaya aproximando a 0, significa que el modelo lineal no es adecuado para explicar información

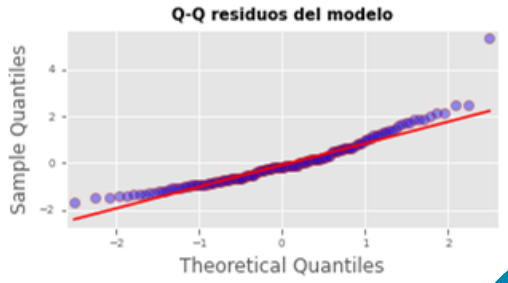
Observación

- Un coeficiente de determinación diferente de 0 no significa que haya relación lineal entre las variables. Por ejemplo

Regresión Lineal

Supuestos paramétricos para la Regresión Lineal

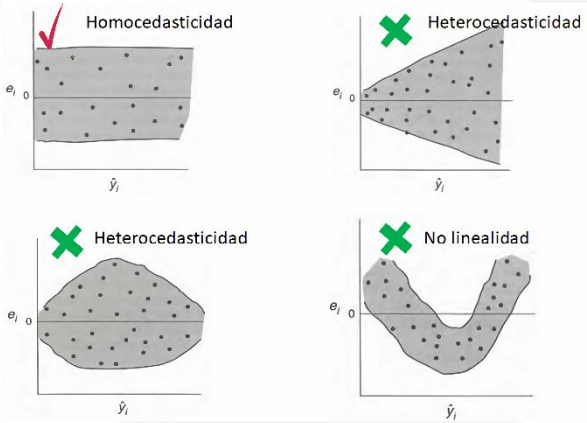




01

Independencia (no autocorrelación)

Entre los residuals ε_i , mediante el test estadístico de *Durbin Watson (DW)* o el test de *Breusch-Godfre*, debemos Validar la independencia entre los residuales



02

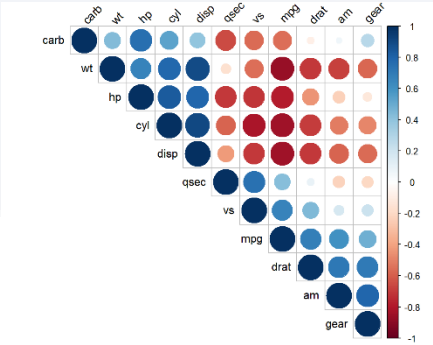
Homocedasticidad

Los residuos, al graficarse contra los valores predichos, deben dispersarse al azar alrededor del cero y mostrar variabilidad constante a lo largo del eje X.

03

Normalidad

Comprobamos si los residuos siguen una distribución normal empleando dos test estadísticos: Shapiro-Wilk test y D'Agostino's K-squared test

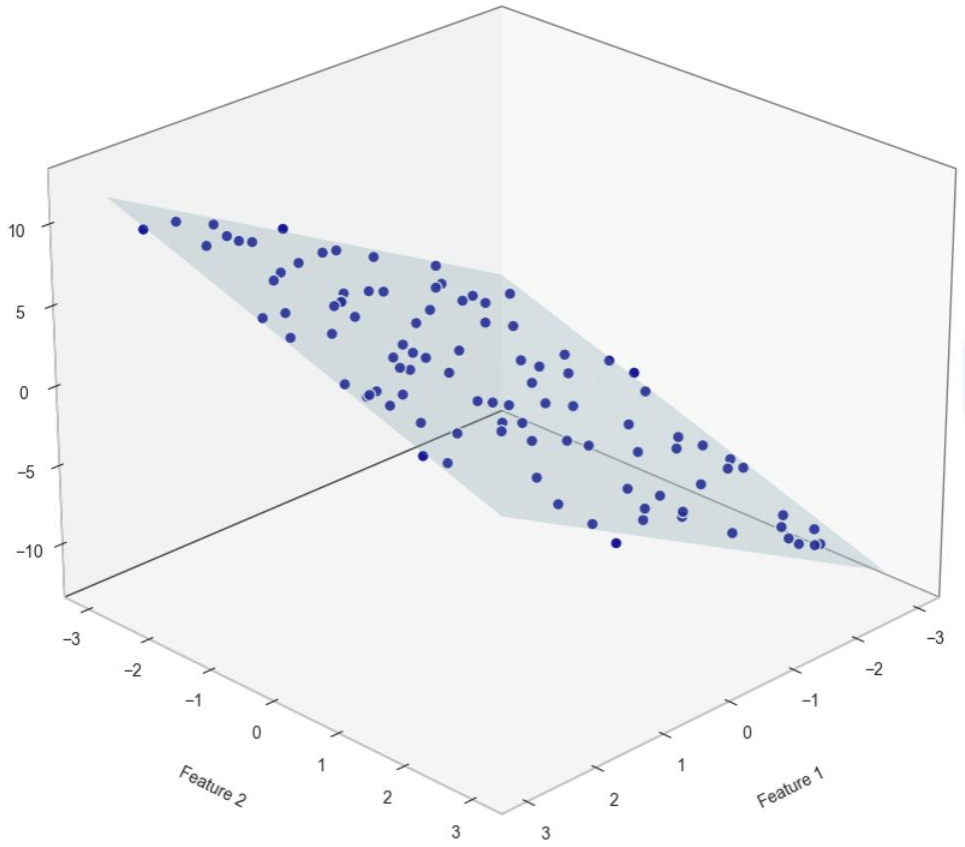


04

No linealidad (evitar multicolinealidad)

En modelos lineales los predictores deben ser independientes, no debe haber colinealidad entre ellos.

Regresión Lineal Multiple



Podemos generalizar la idea de la regresión simple utilizando múltiples variables explicativas

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_j x_j + \varepsilon$$

La función de costo sigue siendo la misma, lo que cambia es la estimación $\hat{y}$

$$J(\beta) = \frac{1}{2}\sum_{1}^{n}(\hat{y} - y)^2$$

Regresión Lineal Múltiple: multicolinealidad

Multicolinealidad

La multicolinealidad ocurre cuando el predictor está linealmente relacionado con uno o varios de los otros predictores del modelo.
Las consecuencias es no poder identificar de forma precisa el efecto individual que tiene cada predictor sobre la variable respuesta, lo que se traduce en un incremento de la varianza de los coeficientes de regresión estimados hasta el punto de que resulta imposible establecer su significancia estadística.

Cómo reconocerlo:

- Si el R^2 es alto pero los coeficientes son no significativos, es un indicio.
- Si existe correlación entre variables, si en su mayoría son mayores a 0.5, es un indicio.

Factor de Inflación de la Varianza (VIF)

$$VIF_{\widehat{\beta_j}} = \frac{1}{1 - R^2}$$

$VIF = 1$, ausencia total
$1 < VIF < 5$, moderado
$5 < VIF < 10$, muy afectado

Posibles soluciones para la multicolinealidad

Algunas de las posibles soluciones al problema de multicolinealidad son las siguientes:

- Optimización del Diseño Muestral: Maximizar la información obtenida de las variables recopiladas.
- Eliminación de Variables Redundantes: Descartar predictores que contribuyan a la multicolinealidad.
- Ampliación de la Muestra: Incrementar el número de observaciones si es posible.
- Aplicación de Restricciones: Emplear métodos como mínimos cuadrados restringidos para incorporar conocimientos previos y estabilizar las estimaciones.

Regresión Lineal Múltiple:

Variables Cualitativas

- Muchas veces en el modelo de regresión aparecen factores factores cualitativos (sexo, raza, estado civil, etc…). En estos casos la información relevante se puede representar con la ayuda de variables ficticias/dummies.
- Las variables ficticias son variables binarias que toman valore 0 , 1.
- Al definir una variable ficticia debemos decidir a qué acontecimiento se le asigna el valor 1, y a cuál el 0.

Ejemplo:

Supóngase que se pretende transformar la variable **"medios de transporte más comunes"**de tres categorías: 1 = autobús, 2 = tren y 3 = avión.

La conversión podría efectuarse por medio de dos variables dicotómicas F1 ,F2 y F3. Los valores que estas tomarían para representar cada categoría serían los siguientes:

Categoría	F1	F2	F3
Autobús	1	0	0
Tren	0	1	0
Avión	0	0	1

Regresión Espúria

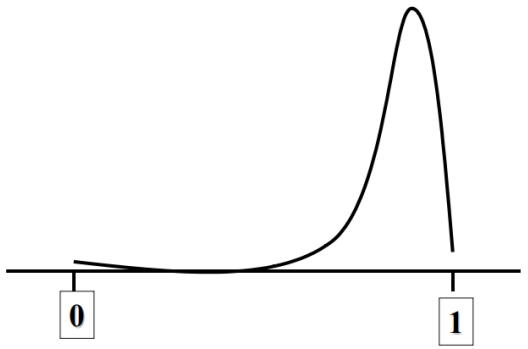
La relación espúrea da la impresión de la existencia de un vínculo apreciable entre dos grupos que es inválido cuando se examina objetivamente. Es una relación en la cual dos acontecimientos no tienen conexión lógica, aunque se puede implicar que la tienen debido a un tercer factor no considerado aún (llamado "factor de confusión" o "variable escondida").

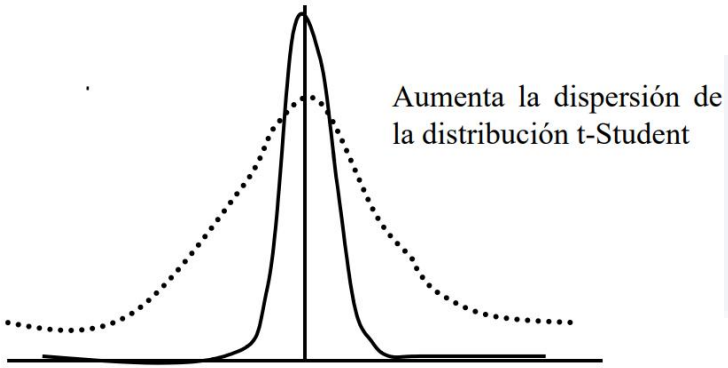
Ejemplo: examinando las ventas de helados de una ciudad. Estas son más altas cuando la tasa de sofocamientos es mayor. Sostener que la venta de helados causa los sofocamientos sería implicar una relación espuria entre las dos. En realidad, una ola de calor puede haber causado ambas. La ola de calor es un ejemplo de variable escondida.

Problemas de la regresión espúrea:

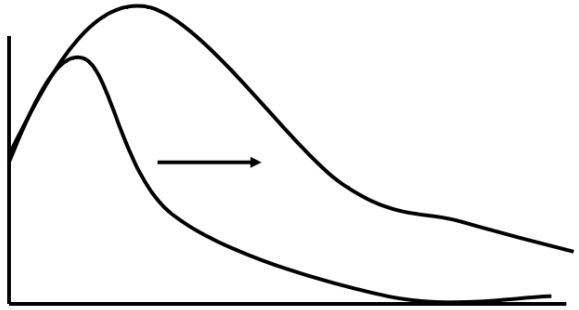
1) Los estimadores son estadísticamente significativos, presentando estadísticos t y F elevados, que rechazan la hipótesis nula.
2) El valor de la R2 es muy cercano al valor de 1, indicando que el modelo es adecuado
3) El estadístico DW tiende a cero. ***Una regla para determinar si la regresión es falsa DW << R2***

Los valores de R^2 tienden a agruparse alrededor de 0.95





Se presentan valores muy altos de t-calculado



Se presentan valores muy altos del estadístico F

Algunos problemas con los modelos de regresión

La **regresión Lineal** trata de modelar la relación entre una variable continua y una o más variables independientes mediante el ajuste de una ecuación lineal. Tres de las limitaciones que aparecen en la práctica al tratar este tipo de modelos (ajustados por mínimos cuadrados ordinaros) son:

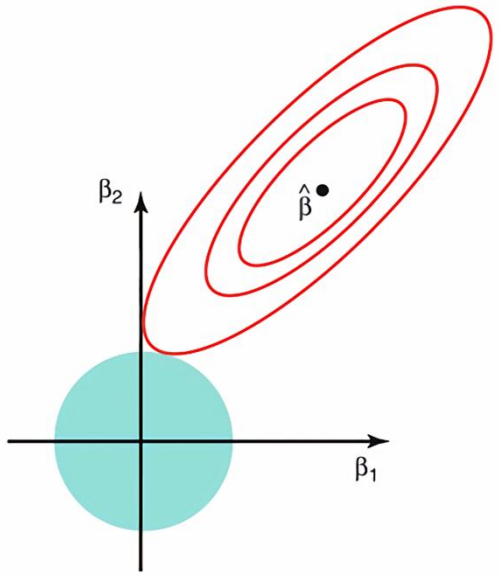
- Se ven perjudicados por la incorporación de predictores correlacionados (Multicolinealidad)
- No realizan selección de predictores, todos los predictores se incorporan en el modelo aunque no aporten información relevante.
- No pueden ajustarse cuando el número de predictores es superior al número de observaciones.

Una forma de atenuar el impacto de esos problemas es utilizar estrategias de regularización como **Ridge, Lasso o Elastic Net**, que fuerzan a que los coeficientes del modelo tiendan a cero, minimizando así el riesgo de **overfitting** , reduciendo varianza, atenuando el efecto de la correlación entre predictores y reduciendo la influencia en el modelo de los predictores menos relevantes

ANALÍTICA AVANZADA

Regresión Regularizada: Lasso, RidgeY Elastic Net

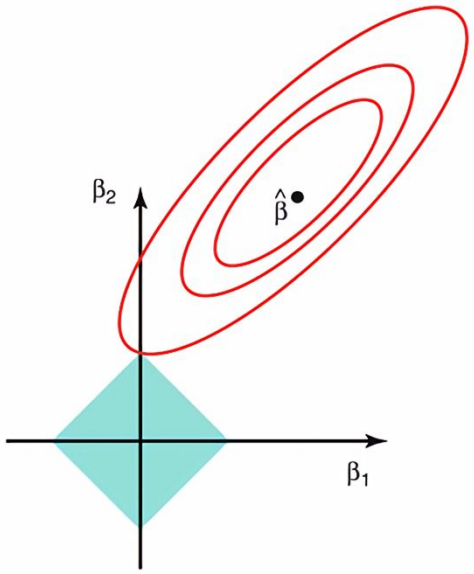
Regresión Regularizada: Ridge



$$\underbrace{\sum_{i=1}^{n}\left(y_i - x_i^T\beta\right)^2}_{\text{Mínimos cuadrados}} + \underbrace{\lambda\sum_{j=1}^{p}\beta_j^2}_{\text{Penalización Ridge}}$$

- Es útil cuando existe colinearidad entre las variables utilizadas para el entrenamiento.
- El factor λ (lambda) sirve para controlar la intensidad de la regularización. Se utiliza la norma de regularización $L2$.
- La elección de este parámetro involucra un balance entre los componentes de sesgo y varianza del error cuadrático medio al estimar β.

Regresión Regularizada: Lasso



$$\underbrace{\sum_{i=1}^{n}\left(y_i - x_i^T\beta\right)^2}_{\text{Mínimos cuadrados}} + \underbrace{\lambda\sum_{j=1}^{p}|\beta_j|}_{\text{Penalización Lasso}}$$

- Permite reducir a valores cercanos a cero los coeficientes de las variables menos relevantes
- Se utiliza para la reducción de la dimensionalidad.
- El factor λ (lambda) controla el nivel de regularización.
- Lasso es una técnica de regresión lineal regularizada, como Ridge, con la leve diferencia en la penalización. (Norma L1 en lugar de L2)

Regresión Regularizada: Lasso

- Para valores crecientes de λ, los coeficientes β_j se contraen hacia cero como en Ridge (shrinkage), con la diferencia de que algunos de ellos se anulan.
- Esto es, Lasso produce estimación y selección de variables en forma continua y simultánea, siendo especialmente útil en el caso $p \geq n$
- En los últimos años se han presentado algunas generalizaciones y extensiones de las técnicas presentadas anteriormente, especialmente diseñadas para ciertas situaciones particulares

Regresión Regularizada: Elastic Net

Es una combinación de Ridge y Lasso. Se decide, que peso se le da a cada método de penalización y se implementa la regresión.

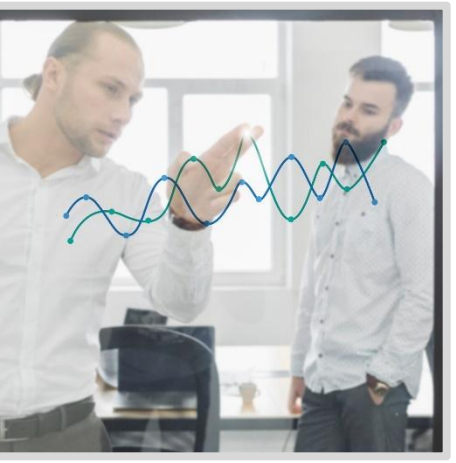
$$\underbrace{\sum_{i=1}^{n}\left(y_i - x_i^T\beta\right)^2}_{\text{Mínimos cuadrados}} + \underbrace{\lambda_1 \sum_{j=1}^{p}\beta_j^2}_{\text{Penalización Ridge}} + \underbrace{\lambda_2 \sum_{j=1}^{p}|\beta_j|}_{\text{Penalización Lasso}}$$

$$\hat{\beta^e} = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^{n}\left(y_i - x_i^T\beta\right)^2 + \frac{1-\alpha}{2}\lambda \sum_{j=1}^{p}\beta_j^2 + \alpha\lambda \sum_{j=1}^{p}|\beta_j|$$

Donde λ es un parámetro de precisión

- Si $\lambda = 0$, regresión lineal tradicional $(\hat{\beta^e} = \hat{\beta})$
- Si $\lambda = \infty$, $\hat{\beta^e} = 0$
- Si $\alpha = 0$, entonces $\hat{\beta^e} = \hat{\beta^{ridge}}$
- Si $\alpha = 1$, entonces $\hat{\beta^e} = \hat{\beta^{lasso}}$

Regresiones



1

Regresión Lineal Simple

$$y = \beta_0 + \beta_1 x_1$$

2

Regresión Lineal Múltiple

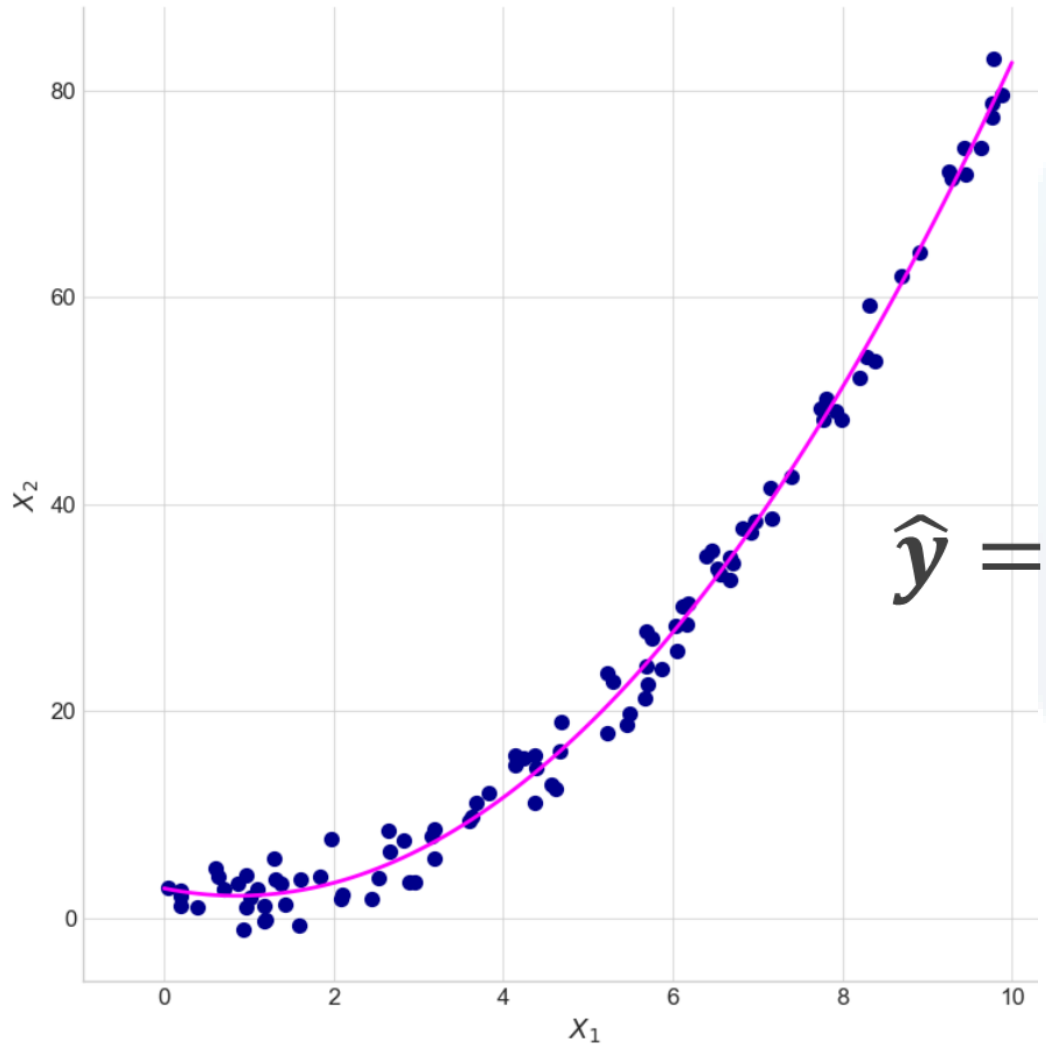
$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

3

Regresión Lineal Polinómica

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + \cdots + \beta_n x_1^n$$

Regresión Polinómica



$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2$$

ANALÍTICA AVANZADA

Gracias

Team

Futura Data &
Analítica Avanzada